GLM-4.6V-Flash (vLLM local, FP8) · P1–P3 · temp 0,1 · top_p 0,6 · top_k 2 · rep 1,1

F0 · infraestrutura
sonda visual 20/20 + 20/20
thinking off = 4 tokens

F1 · piloto 240 memes × 2 braços × 3 paráfrases
(1 440 chamadas) → escolhe think_off

F1b · estabilidade entre seeds 42/43/44 (P1)
flip 1/240 = 0,0042 → G1 aprovado

F2 · referência no treino (3 386 memes, 10 158 chamadas)
confiantes es 0,6912 < 0,70 → G2 FALHOU

por que a P3 diverge?

Doc 26 · fatorial 2×2 da estrutura do prompt
pré-registrado, ainda não executado

continuação exploratória

Doc 27 · peso r = 1 − D (distância ao p_GLM)
G4 aprovado · F5: ΔICM-Soft +0,0074, p = 0,107 → nulo

dose maior

Doc 28 · peso r^4
F5: eval_loss +0,0988, p = 0,029 → pior

usar o GLM direto

o viés é do thinking off?

Doc 29 · mistura GLM corrigido por quantis
RASCUNHO (só teste offline split-half)

Doc 30 · think_on no treino inteiro (10 158 chamadas)
YES 0,711 vs humanos 0,555 → viés PERSISTE

pedido do orientador: testar outro LLM

Seleção dos extremos (treino)
1Y5N 388 · 3Y3N 518 · 5Y1N 645 = 1 551 memes
visualizador local para avaliação manual

Doc 31 · think_off (between_tools, effort medium)
smoke 3 → piloto 180 → completo 4 653 pedidos
1Y5N voto YES 0,286 → PARCIAL

Claude Sonnet 5.5 (Message Batches API) · mesmos P1–P3, imagens e textos