LLMs multimodais como anotadores de referência para sexismo em memes

GLM-4.6V-Flash e Claude Sonnet 5.5 — metodologia e resultados dos docs 25 a 31

Jonathan Santos da Silva · EXIST 2026 (Task 2.1) · versão de 2026-10-22

Parte A: Metodologia (implementação) · Parte B: Relatório de resultados

Metodologia: LLMs multimodais como anotadores de referência para sexismo em memes (GLM-4.6V-Flash e Claude Sonnet 5.5)

*Documento de método dos docs 25 a 31 (`EXIST_MEMES/glm_annotator/`), escrito em 2026-10-22 para servir de base aos capítulos de implementação e de resultados da tese. Os resultados numéricos estão no documento irmão, `RELATORIO_GLM_CLAUDE.md`. Aqui o foco é **como** cada passo foi feito.*

---

0. Como ler este documento

Convenção de marcação, a mesma de `NOTAS_PARA_TESE.md`:

- `[MEDIDO]`: número observado, com o artefato que o produziu.
- `[HIPÓTESE]`: interpretação plausível, ainda não testada. Não escrever como fato.
- `[LIMITAÇÃO]`: restrição a declarar explicitamente no texto da tese.

Estatuto de cada documento. Os experimentos têm estatutos diferentes, que precisam ser mantidos na tese:

doc	pergunta	estatuto	executado?
25	um LLM multimodal serve de "anotador de referência" para ponderar anotadores humanos?	**pré-registro confirmatório**	sim, até a F2 (portão G2 falhou; encerrado)
26	a divergência da paráfrase P3 vem da estrutura do prompt? (fatorial 2×2)	exploratório, pré-registrado	**ainda não** (pré-registrado em 2026-10-08; aguarda o servidor)
27	ponderar anotadores pela distância ao soft label do GLM melhora o modelo de memes?	exploratório (continuação declarada do 25)	sim, com retreino (F5)
28	uma dose maior da mesma ponderação (peso r^4) muda o resultado?	exploratório	sim, com retreino
29	misturar o GLM, corrigido por quantis, diretamente no soft label ajuda?	**rascunho**, aguardando o orientador	não (só teste offline *split-half*)
30	o viés de YES do GLM some com o raciocínio (thinking) ligado?	descritivo, com regra de decisão	sim
31	o viés de YES é do GLM ou aparece também em outro LLM (Claude)?	descritivo, com regra de decisão	sim, braço `think_off` nos memes extremos (o braço `think_on` está definido, mas não rodou)

Disciplina comum a todos. Cada documento foi escrito **antes** da execução e congelado. Uma mudança posterior entra só como seção nova datada, com o motivo, sem editar o original. Os números nunca são apagados: um resultado intermediário que depois é substituído continua registrado, com a data.

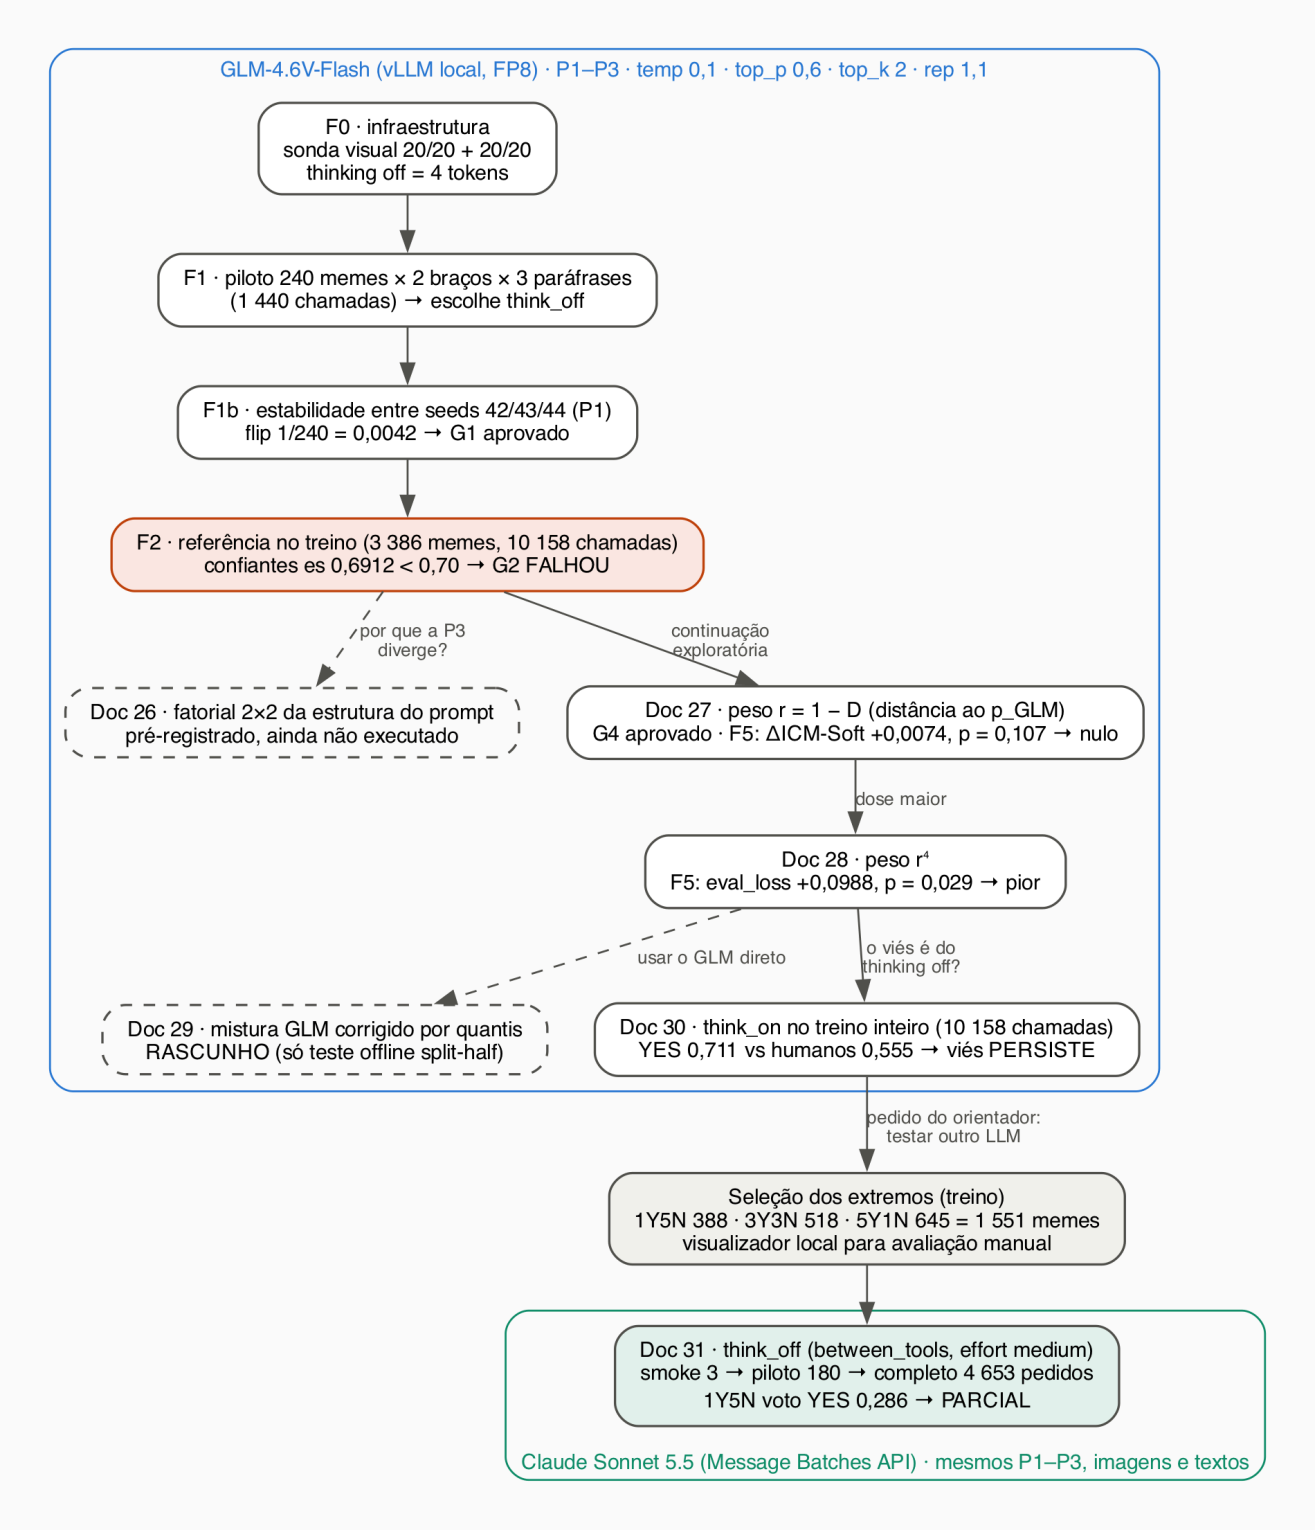


Figura M1 — Encadeamento dos documentos. Caixas tracejadas: desenhado, mas não executado. Fonte: `glm_reference/reports/fluxo_experimentos.png` *(gerado de* `fluxo_experimentos.dot`*).*

---

1. Dados

- **Corpus:** EXIST 2026, Task 2 (memes), arquivo `EXIST_MEMES/Dataset/memes/training/EXIST2026_training.json`. São 3 984 memes, cada um com 6 votos humanos na Task 2.1 (`labels_task2_1`: YES/NO), ids dos anotadores, gênero e faixa etária.

Os memes estão em inglês (`en`) ou espanhol (`es`).

- **Soft label humano:** `p_h` = fração de YES entre os 6 votos (0, ⅙, …, 1).
- **Split:** o mesmo do modelo de memes, congelado em `reliability/outputs/split_taskA_frozen.json` (`random_state=42`, `test_size=0,15`, estratificado pelo voto majoritário). **Treino: 3 386 memes · validação: 598.** O `run_probe.py` recalcula o split com `build_frozen_split` e exige igualdade antes de exportar `glm_reference/train_ids.json` e `val_ids.json`. Todos os experimentos com LLM usam **só o treino**. A validação nunca é anotada por LLM e nunca muda de label.
- **Painéis de anotadores:** 887 anotadores. A coleta tem 151 painéis fixos de 6 pessoas (~26 memes por painel), e 868 dos 887 anotadores estão em um único painel (`SPEC_25.md` §0).

Distribuição dos votos humanos no treino `[MEDIDO — calculado de EXIST2026_training.json + train_ids.json em 2026-10-22]`:

nº de YES (de 6)	0	1	2	3	4	5	6	total
memes	316	**388**	458	**518**	585	**645**	476	3 386
en	170	210	242	260	291	310	232	1 715
es	146	178	216	258	294	335	244	1 671

Em negrito, os três grupos "extremos" usados nos docs 31 em diante (§6).

---

2. Princípios de desenho

1. **Pré-registro com portões de falha dura.** Parâmetros e limiares vão para `glm_reference/config.json` e são conferidos por `assert` no início de cada fase (`common.assert_config()`). Um portão reprovado impede, em código, que a fase seguinte rode.
2. **Separação entre construir a referência e auditar os humanos.** Nas fases que constroem a referência do GLM (F0–F2), nenhum voto humano é lido. A função que sorteia o piloto recebe só ids e idiomas, e um `assert` sobre `inspect.signature` garante isso. Assim a referência não é ajustada aos anotadores que vai auditar.
3. **Retentativa só para falha de transporte** (timeout, conexão, HTTP 5xx e 429), até 3 vezes com *backoff*. **Nunca** por falha de parse ou resposta truncada: repetir até "dar certo" seria seleção. Um erro HTTP 4xx é determinístico e fica gravado com `label="?"`.
4. **Execução retomável e sem refazer chamadas.** Cada chamada concluída vira uma linha num JSONL (append + flush). Antes de chamar, o cliente pula toda chave `(meme_id, braço, paráfrase, seed)` já gravada. Chamada gravada nunca é refeita.
5. **Implementação validada antes de rodar:** casos calculados à mão (Apêndice A dos SPECs 25 e 27, `tests/test_weights.py`), teste do parser com strings fixas e um teste ponta a ponta contra um servidor falso. No Claude, testes com cliente falso no scratchpad (`test_claude_ref.py`, `test_reencode.py`).

---

3. Uma chamada, do meme ao voto (comum ao GLM e ao Claude)

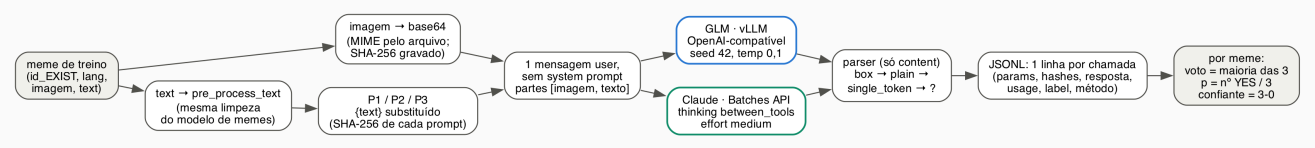


Figura M2 — O mesmo caminho vale para os dois modelos; muda só o cliente. Fonte: `glm_reference/reports/fluxo_chamada.png`.

3.1 Entrada

- **Imagem:** o arquivo original do meme (`DATA / path_memes`), enviado em base64 com o MIME deduzido pela extensão (`mimetypes`). O SHA-256 do arquivo vai para o registro de cada chamada.
- **Texto:** o campo `text` do meme, limpo por `memes_core.pre_process_text`, a mesma limpeza usada pelo modelo de memes da tese. O texto fica no idioma original, sem tradução.
- **Mensagem:** uma única mensagem `user`, **sem system prompt**, com as partes na ordem `[imagem, texto]`. A instrução é sempre em inglês.

3.2 Os três prompts (paráfrases P1–P3)

Para medir a sensibilidade do julgamento à redação, cada meme é perguntado com três paráfrases da mesma definição. `{text}` é substituído pelo texto limpo (`str.replace`, não `format`, para que chaves no texto do meme não quebrem o prompt). Cada prompt termina com quebra de linha: no GLM com thinking desligado, o template de chat acrescenta `/nothink` ao fim da mensagem.

Proveniência (`SPEC_25.md` §4): a P1 adapta a pergunta mostrada aos anotadores de tweets do EXIST 2023 (visão geral estendida, Seção 3.3) e a regra de escopo dos memes do EXIST 2026 (visão geral, Seção 2.1: "*it is sexist itself, describes a sexist situation or criticizes a sexist behavior*"). As frases "*A meme that condemns or reports sexism is still YES*" e "*Judge the image and the text together*" não vêm do EXIST: tornam a regra explícita. A P2 e a P3 dizem o mesmo com outra redação e outra ordem.

`[LIMITAÇÃO]` As diretrizes de anotação de memes do EXIST não são públicas. A P1 é a melhor aproximação pública, não a instrução original dos anotadores.

P1 — SHA-256 `eda963068a2270d49f149c082a8989ca310a68ca655a9c635efb4464a112cd54`

```
Is the meme sexist, in any form, or does it describe situations in which such
discrimination occurs (i.e., it is sexist itself, describes a sexist situation or
criticizes a sexist behavior)?

YES: the meme is sexist itself, describes a sexist situation or criticizes a sexist
behavior.
NO: the meme does not prejudice, underestimate or discriminate women.
A meme that condemns or reports sexism is still YES.

Remember that sexism may be expressed in different forms! It may sound friendly, funny,
offensive, hateful or even violent. Sexism comprises any form of oppression or prejudice
against women because of their sex. This discrimination can be based on different beliefs
such as stereotypes, the belief that men are superior to women or irrational hatred of
women (misogyny). Note that misogyny is a radical/hate-driven sexism.

Judge the image and the text together. Text extracted from the meme (English or Spanish, do
not translate it):
{text}

Answer with one word: YES or NO.
```

P2 — SHA-256 `7265b449b1dda235dc97a3396d75b869928c5141d6c8711834f17e968c552800`

```
Sexism is any form of oppression or prejudice against women because of their sex. It can
sound friendly, funny, offensive, hateful or violent, and it can rest on stereotypes, on
the belief that men are superior to women, or on hatred of women (misogyny, the radical,
hate-driven form of sexism).

Look at the meme, image and text together. Label it YES if it is sexist itself, if it
describes a sexist situation, or if it criticizes a sexist behavior. A meme that condemns
or reports sexism also counts as YES. Label it NO if it does not prejudice, underestimate
or discriminate women.

Text extracted from the meme (English or Spanish, keep it in its original language):
{text}

Answer with one word: YES or NO.
```

P3 — SHA-256 `e9663f15f8be12d651c299af89d57628088dca46d9e56e3eb591c2d284a69136`

```
Text extracted from the meme (English or Spanish, original language):
{text}

Task: decide whether this meme, considering the image and the text together, contains
sexist expressions or behaviors. This includes memes that are sexist themselves, memes that
describe a sexist situation, and memes that criticize or condemn a sexist behavior. Sexism
means any oppression or prejudice against women because of their sex, whether it sounds
friendly, funny, offensive, hateful or violent, including stereotypes, the belief that men
are superior to women, and misogyny.

Is this meme sexist under this definition? Answer with one word: YES or NO.
```

A P3 difere da P1 em cinco pontos ao mesmo tempo: (1) o texto do meme vem **antes** da instrução; (2) o enquadramento é "*Task: decide whether…*"; (3) a pergunta é se o meme "*contains sexist expressions or behaviors*"; (4) não há definição do NO; (5) termina com "*Is this meme sexist under this definition?*" (`SPEC_26.md` §0).

3.3 Parser

O parser (`client.parse`) olha **só** a resposta final (`content`), nunca o raciocínio. São quatro passos, nesta ordem:

1. `box`: o primeiro trecho `<|begin_of_box|>…<|end_of_box|>` (formato do GLM), normalizado (strip, maiúsculas, sem pontuação nem `*`), se for YES ou NO;
2. `plain`: o `content` inteiro normalizado é YES ou NO (formato típico do Claude);
3. `single_token`: exatamente um dos dois rótulos aparece como palavra isolada;
4. senão `label="?"`, com o motivo: `empty`, `length` (resposta truncada), `both` (YES e NO presentes), `other` (recusa ou texto sem rótulo). Os erros de API ficam como `error`, e as recusas do Claude como `refusal`.

O Claude usa o mesmo `client.parse`, recebendo `"length"` quando a parada é por `max_tokens` e o `stop_reason` nos demais casos.

3.4 Registro

Cada chamada gera uma linha JSONL com: `meme_id`, `lang`, `arm`, `paraphrase`, `seed`, `params` (todos os parâmetros enviados), `prompt_sha256`, `image_sha256`, `content`, `reasoning_content`, `finish_reason`, `usage`, `latency_s` (GLM), `label`, `parse_method`, `error`, `timestamp` e `server_model`. O Claude acrescenta `batch_id`, `refusal_category` e `image_reencoded`. Arquivos: `glm_reference/raw/think_off.jsonl`, `glm_reference/raw/think_on.jsonl` e `claude_reference/raw/claude-sonnet-5-5_think_off.jsonl`.

3.5 Agregação por meme

- **Voto do modelo:** a maioria dos rótulos parseados, quando pelo menos 2 concordam (com 3 paráfrases não há empate); senão, sem voto.
- **Soft label do modelo:** `p_LLM` = nº de YES / 3 ∈ {0, ⅓, ⅔, 1}, definido só quando as três paráfrases foram parseadas.
- **Confiante:** as três paráfrases parseadas e iguais (padrão 3-0).
- **Taxa de YES por paráfrase (`yes_rate`):** fração de YES entre as chamadas parseadas.

---

4. GLM-4.6V-Flash: configuração

item	valor	motivo / fonte
modelo	`glm-4.6v-flash` (checkpoint `cont1037/GLM-4.6V-Flash-FP8-DYNAMIC`, contexto 32 768)	servidor do grupo
servidor	vLLM `0.29.1rc1.dev452+g3df4ae153`, API compatível com OpenAI, em `http://193.136.195.31:8000/v1`	`config.json → runtime.server_version`
cliente	Mac local, Python 3.13.5, SDK `openai` 2.14.0, `AsyncOpenAI` com semáforo	`SPEC_25.md` §1
`temperature` · `top_p` · `top_k` · `repetition_penalty`	**0,1 · 0,6 · 2 · 1,1**, enviados explicitamente (`top_k` e `repetition_penalty` via `extra_body`)	decisão do autor (temp) e model card (demais); mandar explícito torna a configuração auditável
`seed`	42 na referência; 43 e 44 no teste de estabilidade	`config.json`

item	valor	motivo / fonte
thinking desligado	`extra_body={"chat_template_kwargs": {"enable_thinking": False}}`	o template acrescenta `/nothink`
`max_tokens`	16 384 (thinking ligado) · 256 (desligado)	2 048 truncava o raciocínio no teste inicial
timeout	600 s (ligado) · 60 s (desligado)	
concorrência	**4** (o pré-registro dizia 8; adendo §19 de 2026-10-07, antes de qualquer chamada: servidor partilhado)	a mesma em todos os braços, porque a ordem de lote pode alterar resultados numéricos no vLLM

`[LIMITAÇÃO]` O checkpoint é quantizado (FP8). A sonda visual da F0 mostra que a visão **funciona**, não que é tão boa quanto a do modelo BF16, que não foi testado.

`[LIMITAÇÃO]` Infraestrutura: imagens que geram mais de ~6 084 tokens de encoder são recusadas pelo servidor com HTTP 400 (cache de encoder do vLLM). Isso afetou 5 dos 3 386 memes de treino (15 chamadas), em todos os braços. Esses memes ficam sem referência do GLM.

4.1 F0 — Infraestrutura e testes de fumaça (portão G0)

teste	procedimento	critério
G0.1 servidor	`GET /v1/models` e `GET /version`	modelo listado; versão gravada
G0.2 thinking desligado	3 memes do piloto com P1 e `enable_thinking=False`	raciocínio vazio e `completion_tokens ≤ 32` nas 3
G0.3 **sonda visual**	20 primeiros memes do piloto com o prompt "*Describe the image in one sentence. Do not transcribe its text.*", uma vez com a imagem real e outra com um PNG branco de 512×512 gerado em memória	revisão manual: as descrições da imagem branca descrevem algo vazio **e** ≥ 16/20 descrições reais correspondem ao meme
G0.4 vazão	latência e chamadas/min com concorrência 4	só registro

Por que a sonda visual. Checkpoints quantizados podem degradar a torre de visão sem erro visível: o modelo continua respondendo em formato válido, decidindo só pelo texto. Como o texto do meme também vai no prompt, essa falha passaria por todas as métricas de classificação. A imagem branca é o controle negativo. As chamadas da F0 não entram nos JSONL do experimento.

4.2 F1 — Piloto e escolha do modo de raciocínio (portão G1)

- **Amostra:** 240 memes de treino, 120 `en` + 120 `es`. Por idioma, os ids ordenados como string; um único `numpy.random.default_rng(2026)`; `rng.choice` sem reposição. O sorteio usa só id e idioma, nunca votos (`glm_reference/pilot_ids.json`).
- **Braços:** `think_on` e `think_off` × P1–P3 × seed 42 = **1 440 chamadas**.
- **Métricas sem rótulo humano** (total, en, es): `parse_rate`, `length_rate`, `yes_rate`, `paraphrase_agreement` (fração de memes confiantes), recusas, fração de raciocínios com caracteres CJK, mediana de `completion_tokens` e de latência.
- **Regra de escolha (fixada antes):** um braço é elegível se `parse_rate ≥ 0,98` e `paraphrase_agreement ≥ 0,70` **em cada idioma**, e `0,05 ≤ yes_rate ≤ 0,95`. Se os dois forem elegíveis, fica o `think_off`, salvo um ganho de concordância > 0,05 do `think_on`. A escolha se baseia na **consistência do modelo consigo mesmo** sob reformulação do prompt, e não na concordância com os humanos, o que tornaria a referência circular.

- **Por que 70 % de memes confiantes:** cada anotador vota em ~26 memes; tirando os unânimes, sobram ~20. Com 70 % confiantes, ficam ~14 por anotador para estimar o desvio; o erro-padrão de uma proporção com 14 memes já chega a 0,13. O valor é escolha do autor, não vem da literatura.

4.3 F1b — Estabilidade entre seeds

- **Procedimento:** braço escolhido (`think_off`), P1, seeds **42, 43 e 44** nos 240 memes do piloto (480 chamadas novas; a seed 42 vem do piloto).
- **Métrica:** `flip_rate` = fração de memes cujos três rótulos (um por seed) não são todos iguais. Um `?` conta como flip. Calculada no total e por idioma.
- **Portão G1:** `flip_rate ≤ 0,10` no total.
- `[LIMITAÇÃO]` Com `temperature=0,1` e `top_k=2`, a geração é quase determinística por construção. Um flip baixo era esperado: o teste mede o ruído de amostragem residual, não a robustez do julgamento. A robustez é o que a concordância entre paráfrases mede.

4.4 F2 — Referência no treino completo (portão G2)

- **Chamadas:** `think_off` × P1–P3 × seed 42 nos 3 386 memes de treino = 10 158. As 720 do piloto (`think_off`, seed 42) foram reaproveitadas pela chave de retomada, então foram **9 438 chamadas novas** (`SPEC_25.md` §18).
- **Saída:** `glm_reference/glm_votes.csv` (`meme_id, lang, label_p1..p3, glm_vote, glm_confident`).
- **Portão G2:** `parse_rate ≥ 0,98` **e** fração de memes confiantes ≥ 0,70, os dois em cada idioma. Se falhar, o experimento para (§11 do SPEC_25).
- Pela regra, as fases F3 (pesos), F4 (checagens) e F5 (retreino) do doc 25 só rodariam com o G2 aprovado.

4.5 Doc 26 — Fatorial 2×2 da estrutura do prompt (pré-registrado, ainda não executado)

Desenhado para separar dois dos cinco fatores em que a P3 difere da P1: a ordem (texto do meme antes ou depois da instrução) e o enquadramento ("pergunta direta" ou "*Task: decide whether…*"). Seriam 4 células × 240 memes do piloto = 960 chamadas `think_off`, seed 42, com um controle de ruído (`D(direct_after, P1 original) ≤ 0,02`) e a medida `R = D(célula, P1) / D(P3, P1)` (R ≥ 0,5: o fator explica a maior parte da divergência da P3). Os textos exatos das quatro células e os SHA-256 estão em `SPEC_26.md` §3. **Ainda não executado** (pré-registrado em 2026-10-08; aguarda o servidor GLM): não existem `raw/factorial26.jsonl` nem `reports/factorial26_summary.md`, e não há resultado para citar.

4.6 Doc 27 — Ponderação de anotadores pela distância ao soft label do GLM

Continuação **exploratória**, aprovada pelo orientador em 2026-10-09 e declarada como motivada pela falha do G2. Não reabre o doc 25. Nenhuma chamada nova: reaproveita `glm_votes.csv`.

Referência: `p_GLM,i` = fração de YES entre P1, P2 e P3 do meme `i`. Os memes 2-1 deixam de ser descartados.

Memes que entram no cálculo do desvio: os não unânimes entre os humanos **e** com as três paráfrases parseadas. Ficam fora os unânimes (6-0) e os 5 memes sem referência.

Fórmulas (`weights.py`, funções puras; `SPEC_27.md` §3 e §8):

- desvio do anotador `a` no meme `i`: `d_ai = |1[voto_a = YES] − p_GLM,i|` ∈ {0, ⅓, ⅔, 1};

- peso de consenso, *leave-one-out*: `w_ai = 1 − H(fração de YES entre os outros 5 votos)`, com `H` a entropia binária em bits. Com 5 outros votos: 5-0 → 1,000; 4-1 → 0,278; 3-2 → 0,029. Discordar do GLM quando os outros cinco concordam entre si pesa muito; discordar num meme em que eles se dividem quase não pesa;
- desvio do anotador: `D_a = Σ_i w_ai·d_ai / Σ_i w_ai`;
- peso do voto: `r_a = 1 − D_a` (sem meme incluído ou com `Σw = 0`: `r_a = 1`);
- novo soft label de **todo** meme de treino: `p_new = Σ_a r_a·1[voto_a = YES] / Σ_a r_a`. Os memes unânimes mantêm 0 ou 1 por construção, e um painel com todos os `r` iguais não muda nada (as duas propriedades viram `assert`).

`[LIMITAÇÃO]` Num meme 2-1, todo anotador leva pelo menos ⅓ de desvio, o que cria um piso em `D_a`. Os `D` do doc 27 não estão na mesma escala que os do doc 25.

Checagens descritivas (F4, `checks.py` → `reports/checks_summary.md`):

- (a) linha de base dos pares: a mesma fórmula com `p_outros` (fração de YES dos outros 5) no lugar do GLM, e ρ de Spearman(r_glm, r_peer);
- (b) o peso só mede o limiar do anotador? ρ(D_glm, taxa de YES do anotador) e ρ(D_glm, |taxa de YES do anotador − média de p_GLM nos mesmos memes|);
- (c) `r` por gênero × idade, com IC 95 % por *bootstrap* de anotadores (2 000 reamostragens, `default_rng(2026)`);
- (d) quanto os labels se movem: `share_moved` = fração de memes com $|\Delta p| \geq 1/12$ (meio voto) e mudanças de rótulo duro;
- (e) o GLM confiante contraria um meme unânime? Com 30 casos sorteados para revisão manual;
- (f) acordo do voto do GLM com o rótulo duro humano, empates fora;
- (g) precisão por anotador: `n_included`, massa `Σw` e largura do IC 95 % de `D_glm` por *bootstrap* dos memes;
- (h) fração da massa `Σw` vinda de memes 2-1;
- (i) hesitação do GLM × divisão humana, com IC 95 % para a diferença de proporções (aproximação normal). Só se diz "mais" quando o IC exclui zero (`SPEC_27.md` §16B: com votos aleatórios sintéticos, a comparação crua dava "mais" por puro ruído).

Portão G4: retreino só se `share_moved ≥ 0,05` **e** ρ(r_glm, r_peer) < 0,8.

F5 — retreino (disparado pelo autor na VM):

- modelo de memes da tese (`memes_model.ipynb`: XLM-RoBERTa-large + CLIP ViT-L/14, fusão por concatenação em 1024-d), sem nenhuma edição de código; muda só `ARM` e `SEED` na célula 6;
- braços `glmbase` (cópia byte a byte do `soft_labels_taskA_raw.json`, com tag própria para não colidir com runs antigas) e `glmw` (Task 2.1 de treino trocada por `p_new`). Validação sempre com os labels originais, conferida por SHA-256. Tasks 2.2 e 2.3 intocadas;
- seeds pareadas **42, 7 e 2025**, 15 épocas;
- **estado primário:** E = argmin(`eval_loss`), a época escolhida pela loss e nunca pela métrica (`SPEC_27.md` §16A, P3). O estado final é secundário (regra de simetria);
- **teste:** Δ = glmw − glmbase por seed; média; t pareado **bilateral**, df = 2. Para p < 0,05 é preciso |t| > 4,30. Métrica primária: Task A ICM-Soft-Norm. Secundárias: ICM-Norm *hard* e `eval_loss`; Tasks B e C para dano colateral;
- **critério de sucesso:** Δ médio de ICM-Soft-Norm > 0, p < 0,05 **e** `eval_loss` sem piora. Um nulo se registra como "efeito não detectado com 3 seeds", nunca como "efeito zero";

- **controle `glmshift`** (definido depois da F4, antes da F5): nos memes não unânimes, `p_ctrl = clip(p_old + Δ̄, 0, 1)`, com Δ = deslocamento médio que o glmw produziu (+0,0705), sem ponderar anotador nenhum. Pela regra fixada, só seria treinado se o glmw satisfizesse o critério.
- **Determinismo do treino:** o notebook fixa as seeds de python/numpy/torch/cuda, usa `cudnn.benchmark=False`, `use_deterministic_algorithms(True)` e `CUBLAS_WORKSPACE_CONFIG=:4096:8`, faz re-seed imediatamente antes de instanciar o modelo e imprime um *fingerprint* SHA-256 dos pesos. `[MEDIDO]` Três execuções de `glmbase` seed 7 deram `eval_loss` idêntica época a época.

4.7 Doc 28 — Dose maior: peso r^4

Exploratório, motivado pelo nulo do doc 27. Muda só o peso do voto: `p_new = Σ r⁴·1[YES] / Σ r⁴`, com o mesmo `r_glm` do doc 27 (`annotator_weights.csv`, SHA-256 conferido). Elevar à 4ª potência preserva a ordem dos anotadores e amplia a distância entre eles (o dobro do `r` vira 16× o peso). O BASE foi reaproveitado do doc 27, porque o treino é determinístico.

Triagem com 1 seed (42), limites fixados antes: continuar para as seeds 7 e 2025 se |Δ hard| ≥ 0,03, |Δ soft| ≥ 0,02 ou |Δ `eval_loss`| ≥ 0,03, em qualquer direção (o dobro dos Δ da seed 42 no doc 27). A confirmação usa a mesma análise do doc 27, e um efeito negativo significativo também é registrado.

4.8 Doc 29 — Mistura do GLM corrigido por quantis (rascunho, não aprovado)

Proposta, aguardando o orientador. **Nenhum label foi gerado e nenhuma run foi feita.** `doc29.py build` não deve ser rodado antes da aprovação.

- **Ideia:** usar o GLM diretamente no label, depois de corrigir o viés de YES: `p_novo = 0,5·p_h + 0,5·q(p_GLM)`, braço `glmq50`.
- **Correção por quantis `q`:** ordenam-se os `p_h` dos 3 381 memes com referência; os níveis do GLM (254, 241, 739 e 2 147 memes em 0, ⅓, ⅔ e 1) ocupam blocos consecutivos dessa fila, e `q(nível)` = média dos `p_h` do bloco. O mapa medido é `q(0)=0`, `q(⅓)=0,124`, `q(⅔)=0,303`, `q(1)=0,756`; a média de `q(p_GLM)` iguala a humana (0,5549). O GLM decide a **ordem**, e os humanos decidem a **escala**.
- **Controle `smooth50`:** `p_novo = 0,5·p_h + 0,5·0,555`, a mesma mistura sem informação do GLM, para separar "o GLM informa" de "suavizar ajuda".
- **Teste offline *split-half*** (`splithalf_29.py` → `reports/splithalf_29.md`): em cada meme de treino, as 20 divisões 3 contra 3 dos anotadores, nos dois sentidos; uma metade (pura ou misturada) prevê a fração de YES da outra; métricas MSE e entropia cruzada (com p cortado em [0,001; 0,999]); IC 95 % da diferença `glmq50 − smooth50`.

4.9 Doc 30 — GLM com thinking ligado no treino inteiro

- **Pergunta:** o viés de YES do GLM (`think_off`: 80,4 % de YES no treino, contra 55,5 % dos humanos) é efeito do raciocínio desligado?
- **Execução:** `run_reference_think_on.py`, braço `think_on`, P1–P3, seed 42, os 3 386 memes de treino. Parâmetros idênticos aos do doc 25. As 720 chamadas `think_on` do piloto foram reaproveitadas, então foram 9 438 novas. Grava `glm_votes_think_on.csv`, sem tocar em nenhum artefato dos docs 25–29.
- **Regra (fixada antes):** o viés **persiste** se a taxa de YES do `think_on` for ≥ média humana + 0,10 (≥ 0,655). Nesse caso, o passo seguinte é testar outros modelos, como pediu o orientador.
- **Descritivos fora da regra:** acerto contra a maioria humana (empates fora), Spearman(p_GLM, p_h), YES quando os humanos dizem NO, NO quando dizem YES, e a distribuição de p_GLM.

5. Custos de execução do GLM (medidos)

`[MEDIDO — timestamps e usage de raw/think_off.jsonl e raw/think_on.jsonl, chamadas com seed 42]`

braço	latência mediana por chamada	tokens gerados (mediana · máx)	tokens de entrada (mediana)	9 438 chamadas da referência completa (concorrência 4)
`think_off`	0,66 s	4 · 207	724	**0,78 h** (2026-10-08)
`think_on`	16,0 s	169 · 2 084	720	**12,7 h** (2026-10-12 a 13)

O servidor é do grupo, então o custo monetário marginal é zero. A vazão medida na F0 foi de 73,6 chamadas/min (latência mediana de 2,5 s nas descrições da sonda).

---

6. Seleção dos memes extremos e visualizador

Motivação. Os docs 27–30 mostraram que o GLM diz YES muito mais que os humanos. Para comparar modelos onde a resposta humana é mais clara, o foco passou aos casos extremos de concordância humana no treino.

Seleção (`select_extremes.py`, só lê arquivos já gravados, sem chamada a modelo):

- grupos definidos pelo número de YES humanos na Task 2.1: **1Y5N** (1 YES, 5 NO; n = 388), **3Y3N** (empate; n = 518) e **5Y1N** (5 YES, 1 NO; n = 645), total **1 551 memes**;
- grupos escolhidos pelo autor em 2026-10-19; os unânimes (0-6 e 6-0) não entram (para o GLM contra memes unânimes, ver também a checagem (e) do doc 27);
- a ordem dentro de cada grupo é embaralhada com `default_rng(2026)`, de modo que os N primeiros de cada grupo formam uma amostra aleatória (o piloto do Claude usa isso);
- saídas: `glm_reference/extremes/extremes.csv` (votos humanos e rótulos P1–P3 do GLM off e on), `extremes.json` (o mesmo, mais imagem, texto, demografia e o raciocínio do GLM `think_on`) e `reports/extremes.md`.

Nível de referência humano em cada grupo: por construção, a fração de YES esperada de um anotador típico é ⅙ ≈ 0,167 no 1Y5N, 0,5 no 3Y3N e ⅚ ≈ 0,833 no 5Y1N.

Visualizador local (`viewer.py` + `viewer.html`): servidor HTTP da biblioteca padrão, só em `127.0.0.1:8765`, com uma única *thread* (evita corrida ao gravar). Mostra imagem, texto, votos humanos com gênero e idade, e as respostas do GLM off/on com o raciocínio. Tem abas por grupo, filtros (idioma, "GLM discorda da maioria", "off e on diferem", "não avaliados") e um **modo cego**, que esconde os votos humanos e dos modelos até o avaliador dar o próprio rótulo (teclas Y/N/A). A avaliação é gravada na hora em `extremes/avaliacao.json` e `.csv`, com troca atômica de arquivo. Serve para revisão qualitativa dos casos; nenhuma métrica deste relatório depende dela.

---

7. Claude Sonnet 5.5 (doc 31)

7.1 Pergunta e regra pré-registrada

Pergunta: o viés de YES é do GLM ou aparece também em outro LLM multimodal, com os mesmos prompts, imagens e textos?

Pré-registro aprovado pelo autor em 2026-10-19, antes do piloto (`SPEC_31.md`). Antes da aprovação rodou apenas o `--smoke`: 3 chamadas síncronas no meme 110096, só para checar a chave e os parâmetros, sem nada gravado.

Métrica principal: voto YES do Claude no grupo 1Y5N (5 de 6 humanos dizem NO).

- **≥ 0,40:** o Claude também tem o viés, que portanto não é exclusivo do GLM. O valor 0,40 fica abaixo do GLM com thinking ligado (0,51) com folga de 0,1.
- **≤ 0,25:** o viés é, em boa parte, do GLM. O valor 0,25 está perto do esperado de um anotador humano típico (0,167).
- **Entre os dois:** parcial; reportar sem conclusão forte.

Secundária: o voto YES no 3Y3N comparado com 0,5. Mesma leitura por idioma.

7.2 Modelo e parâmetros

item	valor	motivo
modelo	`claude-sonnet-5-5`	o Claude 5.5 de porte médio que permite desligar o thinking; o Opus 5.5 não permite (400 em qualquer `effort`)
thinking (braço `think_off`)	`thinking: {"type": "between_tools"}`	no Sonnet 5.5, `disabled` é rejeitado (400). Pelo nome, `between_tools` limita o raciocínio às trocas com ferramentas, e aqui não há ferramentas. Confirmado empiricamente: 0 dos 4 716 registros com raciocínio; saída média de 4,0 tokens
`effort`	`medium`, explícito	o padrão muda por modelo
`max_tokens`	256	igual ao GLM `think_off`
amostragem	**padrão da API**: os modelos 5.5 rejeitam temperature/top_p/top_k fora do padrão e não têm `seed`	ver §8
mensagem	idêntica ao GLM: 1 mensagem `user`, sem system prompt, partes `[imagem base64, texto]`; mesmos P1–P3 e mesmo texto limpo	
braço `think_on`	definido (`thinking: adaptive`, resumo do raciocínio gravado, `max_tokens` 16 000), **não executado**	
SDK	`anthropic` 1.15.0, Python 3.13.5, no Mac	

7.3 Execução pela Message Batches API

- **Por que *batch*:** metade do preço e sem limite prático de concorrência; o resultado sai em até 24 h (na prática, de 3 min a ~4 h por lote, §7.6).

- **Pedidos:** um por (meme, paráfrase), com `custom_id = "<meme_id>_p<1|2|3>"`. Os lotes são fatiados em até 150 MB (o limite da API é 256 MB e 100 000 pedidos).
- **Estado e retomada:** cada lote enviado vai para `claude_reference/batches.json` (id, modelo, braço, data, `custom_ids`, idioma e SHA-256 da imagem de cada meme), com gravação atômica. Rodar o mesmo comando de novo recolhe os lotes terminados e envia só o que falta; um Ctrl+C ou uma queda de rede não perdem nada. Cada execução envia no máximo uma vez.
- **Coleta** (`collect`): `succeeded` → resposta parseada (§3.3). `errored` com `invalid_request` (4xx, determinístico) → registro `?` com `parse_method="error"`. Outros erros (servidor, expirado, cancelado) não são gravados e voltam a ser enviados, a mesma regra de "retentativa só para transporte" do GLM.
- **Recusas:** `stop_reason == "refusal"` vira `?` com `parse_method="refusal"` e a `refusal_category`. Por decisão de desenho, **sem `fallbacks`** para outro modelo (que, de resto, a Batch API não aceita): trocar de modelo nos casos difíceis mudaria o anotador no meio da medição.
- **Ordem pré-registrada:** `--smoke` (3 chamadas síncronas, nada gravado) → piloto `--per-group 20` (60 memes, 180 pedidos, lote `msgbatch_01FkUCMPxzxwLmcQuaPTbDST`) → todos os 1 551 memes.
- **Comandos** (da raiz do repositório, com `ANTHROPIC_API_KEY` exportada no terminal e nunca gravada no repositório):

```
python3 EXIST_MEMES/glm_annotator/claude_reference.py --model claude-sonnet-5-5 --arm
think_off --smoke
python3 EXIST_MEMES/glm_annotator/claude_reference.py --model claude-sonnet-5-5 --arm
think_off --per-group 20
python3 EXIST_MEMES/glm_annotator/claude_reference.py --model claude-sonnet-5-5 --arm
think_off
```

A chave da conta não estava associada a um *workspace*, e a API exigiu o cabeçalho `anthropic-workspace-id`, passado pela variável `ANTHROPIC_CUSTOM_HEADERS`. Isso é só infraestrutura, sem efeito no método.

7.4 Tratamento de imagens (diferenças em relação ao GLM)

1. **Limite de 5 MB por imagem.** Só o meme 210851 (5,1 MB) passa do limite. Ele é reduzido para 1 568 px no maior lado e enviado como JPEG de qualidade 90, que é o tamanho a que o Claude reduz as imagens de qualquer forma. O SHA-256 registrado continua sendo o do arquivo original. Declarado no pré-registro.
2. **Desvio datado de 2026-10-19 (escrito antes de ver qualquer resposta reenviada).** Na rodada completa, 21 memes (63 pedidos) voltaram com `invalid_request_error: Could not process image`. São JPEGs válidos, que o PIL e o GLM leem sem erro. Esses memes foram **reenviados uma única vez** com a imagem decodificada e reconvertida para PNG (os mesmos pixels, sem nova compressão). Os registros reenviados têm `image_reencoded: true`, e os registros de erro originais continuam no JSONL (4 716 linhas = 4 653 pedidos + 63 reenvios). A regra era: se falhasse de novo, ficaria `?` definitivo. Os 63 foram processados. Na análise vale o último registro de cada chave.

7.5 Métricas e relatório

`claude_reference.py` calcula, por grupo × (total, en, es): fração de YES humana; voto YES do GLM off, do GLM on e do Claude; fração de YES do Claude nas paráfrases; parse rate; recusas. Grava em `glm_reference/reports/claude_claude-sonnet-5-5_think_off_extremes.md`. As métricas adicionais deste relatório (concordância entre paráfrases, paráfrase dissidente, acordo com a maioria humana, κ, McNemar, cruzamentos) foram calculadas em 2026-10-22 a partir dos mesmos arquivos e são **descritivas, pós-hoc**: não fazem parte da regra do §7.1. As figuras vêm de `plot_doc31.py`.

7.6 Custo e tempo (medidos)

- **Preço:** Sonnet 5.5 custa US$ 2 por milhão de tokens de entrada e US$ 10 por milhão de saída; a Batch API cobra 50 %.
- **Tokens** `[MEDIDO — usage dos 4 653 registros finais]`: entrada média de 1 121,7 tokens por pedido (mediana 874, mín. 279, máx. 5 311, quase tudo imagem); saída média de 4,0 tokens (máx. 70).
- **Custo real:** ≈ **US$ 5,31** pelos 4 653 pedidos, ≈ US$ 0,00114 por pedido (≈ US$ 0,0034 por meme com 3 paráfrases). A estimativa do `--smoke` (US$ 2,43) era baixa porque usava um único meme de imagem pequena.
- **Tempo por lote** (do envio ao fim do processamento): 180 pedidos → 3 min; 666 → 125 min; 875 → 85 min; 816 → 127 min; 787 → 229 min; 972 → 246 min; 357 → 134 min; 63 (reenvio PNG) → 4 min. Com os lotes processados em paralelo, a rodada completa levou ~4 h de relógio. O tempo depende da fila da API, não do tamanho do lote.

---

8. O que é comparável entre GLM e Claude

aspecto	GLM-4.6V-Flash	Claude Sonnet 5.5	igual?
memes	treino inteiro (3 386) e os 1 551 extremos	**só os 1 551 extremos**	as comparações diretas usam só os extremos
imagem	arquivo original	arquivo original; 1 meme reduzido (5 MB) e 21 reconvertidos para PNG	quase
texto e prompts	P1–P3, texto limpo por `pre_process_text`	idênticos (mesmos SHA-256)	sim
formato da mensagem	1 `user`, sem system prompt, `[imagem, texto]`	idem	sim
raciocínio	`think_off` (`enable_thinking=False`) e `think_on`	só `think_off` (`between_tools`)	só o braço off é comparável
amostragem	temp 0,1 · top_p 0,6 · top_k 2 · rep 1,1 · seed 42	padrão da API, sem seed	**não**
repetição entre seeds	sim (F1b: seeds 42, 43, 44)	**impossível** (a API não tem seed)	não
parser e agregação	`client.parse`; maioria das 3; confiante = 3-0	idênticos	sim
falhas de imagem	5 memes sem resposta (cache de encoder)	0 no fim (após o reenvio PNG)	não afeta os extremos, salvo 1 meme do 5Y1N sem voto do GLM
execução	servidor local, síncrono, concorrência 4	Batch API, assíncrono	sem efeito nas respostas

`[LIMITAÇÃO]` **Não há teste de estabilidade entre seeds para o Claude**, e não é possível fazer um equivalente ao F1b: a API não expõe `seed` nem permite fixar a temperatura. O que se pode medir é a variação entre **duas execuções idênticas** (reenviar os mesmos pedidos e contar quantos rótulos mudam). Isso não foi feito; ver as pendências no relatório.

---

9. Definições das métricas e dos testes

- **Voto YES (taxa):** fração dos memes do grupo cujo voto (maioria das 3 paráfrases) é YES. O denominador é o número de memes do grupo, incluindo os sem voto.
- **IC 95 % de Wilson** para uma proporção k/n: `(p̂ + z²/2n ± z·√(p̂(1−p̂)/n + z²/4n²)) / (1 + z²/n)`, com z = 1,96.
- **Fração de YES nas paráfrases:** YES / respostas parseadas, juntando P1, P2 e P3.
- **Concordância entre paráfrases (fração 3-0):** memes com as três paráfrases parseadas e iguais / memes do grupo.
- **Paráfrase dissidente:** nos memes 2-1, a paráfrase que ficou sozinha.
- **Acordo com a maioria humana nos extremos** (pós-hoc): NO no 1Y5N (maioria humana NO), YES no 5Y1N (maioria humana YES) e a média das duas, que equivale a uma acurácia balanceada nesses dois grupos. Um meme sem voto conta como erro. O 3Y3N não tem maioria e fica fora.
- **Acordo e κ de Cohen** entre dois modelos: `κ = (p_o − p_e) / (1 − p_e)`, sobre os memes com voto dos dois.
- **Teste de McNemar exato** (bilateral) para a diferença de taxas de YES pareadas entre dois modelos: binomial nos pares discordantes (b = só o primeiro diz YES, c = só o segundo diz YES).
- **`flip_rate`:** fração de memes cujos rótulos nas seeds 42, 43 e 44 não são todos iguais (`?` conta como flip).
- **Spearman:** correlação de Pearson dos ranks (pandas), sem SciPy, conforme o pré-registro.
- **F5:** Δ por seed, média, desvio-padrão, t pareado bilateral com df = 2 (`analyze_f5.py`, que reaproveita `stats` e `p_two_sided` de `reliability/analyze_arm_experiment.py`).

---

10. Artefatos e reprodução

arquivo	conteúdo
`glm_annotator/SPEC_25.md` … `SPEC_31.md`	pré-registros, adendos e resultados datados
`glm_annotator/NOTAS_PARA_TESE.md` · `EXPLICACAO_METODOS.md` · `RUNBOOK.md`	notas para a tese (docs 25–28), explicação dos métodos de ponderação com exemplo numérico, passo a passo
`glm_annotator/client.py` · `prompts.py` · `common.py`	cliente GLM, parser, retomada; prompts e hashes; caminhos e parâmetros
`glm_annotator/run_probe.py` · `run_pilot.py` · `run_reference.py` · `run_reference_think_on.py`	F0, F1/F1b, F2, doc 30
`glm_annotator/weights.py` · `checks.py` · `analyze_f5.py` · `doc28.py` · `control_glmshift.py` · `splithalf_29.py`	docs 27, 28 e 29
`glm_annotator/select_extremes.py` · `viewer.py` · `viewer.html`	extremos e visualizador
`glm_annotator/claude_reference.py` · `plot_doc31.py`	doc 31 e suas figuras
`glm_reference/config.json`	parâmetros fixados, portões, versões, SHA-256 dos arquivos de labels
`glm_reference/raw/*.jsonl` · `claude_reference/raw/*.jsonl`	uma linha por chamada
`glm_reference/glm_votes.csv` · `glm_votes_think_on.csv` · `extremes/extremes.csv`	votos agregados
`glm_reference/reports/`	relatórios e figuras de cada fase
`claude_reference/batches.json`	estado dos lotes do Claude

Todos os números deste documento vêm dos artefatos acima. O que não tem fonte não está aqui.

Relatório: GLM-4.6V-Flash e Claude Sonnet 5.5 como anotadores de sexismo em memes — resultados

*Resultados dos docs 25 a 31 (`EXIST_MEMES/glm_annotator/`), consolidados em 2026-10-22. O **como** de cada passo (prompts, parâmetros, fórmulas, testes) está em `METODOLOGIA_GLM_CLAUDE.md`, e as seções citadas como "Metodologia §x" referem-se a ele. Convenção: `[MEDIDO]` (com artefato), `[HIPÓTESE]`, `[LIMITAÇÃO]`. Os decimais seguem a vírgula portuguesa no texto; as figuras usam ponto.*

---

0. Resumo

1. **O GLM como referência para ponderar anotadores (doc 25) falhou no portão pré-registrado.** No treino completo, as três paráfrases concordaram em 72,7 % dos memes em inglês e em **69,1 % em espanhol**, abaixo do mínimo de 70 % (faltaram 15 memes). O julgamento é estável entre seeds (1 flip em 240 memes), mas depende da redação: uma única paráfrase (P3) responde por 75 % das discordâncias.
2. **As continuações exploratórias não melhoraram o modelo de memes.** Ponderar anotadores pela distância ao GLM (doc 27) deu Δ ICM-Soft-Norm = +0,0074 (p = 0,107; `eval_loss` pior nas 3 seeds). Com a dose maior r^4 (doc 28), a `eval_loss` piorou significativamente (+0,0988, p = 0,029). O diagnóstico: o peso mediu o **limiar de YES** de cada anotador (ρ = −0,676), porque o GLM diz YES demais.
3. **O viés de YES do GLM persiste com o raciocínio ligado** (doc 30): 0,711 de YES no treino, contra 0,804 com ele desligado e 0,555 dos humanos.
4. **Nos 1 551 memes extremos, o Claude Sonnet 5.5 tem muito menos viés que o GLM.** No grupo em que 5 de 6 humanos dizem NO (1Y5N), o voto YES foi de **0,286** no Claude, contra 0,719 no GLM com thinking desligado e 0,510 com ele ligado. Pela regra pré-registrada, o resultado é **PARCIAL** (entre 0,25 e 0,40): o viés é em grande parte do GLM, mas o Claude também fica acima dos humanos (0,286 contra 0,167 no 1Y5N; 0,689 contra 0,5 no empate).
5. **O Claude é mais consistente entre paráfrases** (as três concordam em 83,6 % dos extremos, contra 69,8 % no GLM off), e a P3 deixa de ser a fonte dominante de discordância. O custo foi de ≈ US$ 5,31 pelos 4 653 pedidos.

Parte I — GLM-4.6V-Flash

1. F0 — Infraestrutura e visão (doc 25)

`[MEDIDO — glm_reference/probe_vision.csv; config.json → runtime.gates]`

- **Sonda visual (G0.3):** com a imagem branca, 20/20 descrições do tipo "*a blank white square with no visible content*", sem nenhuma cena alucinada. Com a imagem real, 20/20 descrições correspondentes ao meme (revisão manual do autor em 2026-10-07). **Aprovado.**
- **Thinking desligado (G0.2):** 3/3 respostas sem raciocínio, com 4 tokens (`<|begin_of_box|>YES<|end_of_box|>`).
- **Vazão (G0.4):** 73,6 chamadas/min com concorrência 4; latência mediana de 2,5 s nas descrições.

2. F1 — Piloto e escolha do modo de raciocínio

`[MEDIDO — reports/pilot_summary.md; 1 440 chamadas, 240 memes, seed 42]`

braço	escopo	parse	`yes_rate`	concordância entre paráfrases	tokens gerados (mediana)	latência mediana
`think_on`	total	1,000	0,700	0,758	171	15,7 s
`think_on`	en	1,000	0,694	0,767	154,5	15,3 s
`think_on`	es	1,000	0,706	0,750	176	17,2 s
`think_off`	total	1,000	0,793	0,750	4	0,71 s
`think_off`	en	1,000	0,797	0,775	4	0,65 s
`think_off`	es	1,000	0,789	**0,725**	4	0,82 s

Zero respostas truncadas, recusas ou erros de API; zero raciocínios com caracteres CJK. Os dois braços foram elegíveis. O ganho de concordância do `think_on` (0,758 − 0,750 = 0,008) ficou abaixo do limiar de 0,05, e por isso foi **escolhido o `think_off`**, ~22× mais rápido.

Achado — raciocinar não aumentou a consistência. Com o thinking ligado, o modelo produziu cadeias de raciocínio reais (mediana de 753 caracteres, nenhuma vazia) e concordou entre paráfrases praticamente na mesma taxa.

Sensibilidade à redação, já no piloto `[MEDIDO — raw/<braço>.jsonl, análise de 2026-10-07]`:

braço	YES em P1	YES em P2	YES em P3	paráfrase dissidente nos memes não confiantes
`think_off`	0,838	0,887	**0,654**	P1 2 · P2 14 · **P3 44** (de 60)
`think_on`	0,771	0,754	**0,575**	P1 13 · P2 9 · **P3 36** (de 58)

3. F1b — Estabilidade entre seeds

`[MEDIDO — reports/pilot_summary.md; raw/think_off.jsonl; 480 chamadas novas, P1, seeds 42/43/44]`

escopo	`flip_rate`
total	**0,0042** (1/240)
en	0,0000 (0/120)
es	0,0083 (1/120)

Um único meme mudou de rótulo: o `110614` (NO · YES · NO nas seeds 42 · 43 · 44). Em 237/240 memes, o texto da resposta foi idêntico caractere a caractere nas três seeds. **G1 aprovado** (limite 0,10).

Achado — a redação pesa ~60× mais que a amostragem. Nos mesmos 240 memes, trocar a seed muda o rótulo em 0,4 % deles (1/240), enquanto trocar a paráfrase (mesma seed) produz respostas divergentes em 25 % (60/240). Uma referência de prompt único teria parecido estável, escondendo uma dependência de redação de 25 %. `[LIMITAÇÃO]` Com temp 0,1 e top_k 2, o flip baixo era esperado por construção.

4. F2 — Referência completa: portão G2 falhou

`[MEDIDO — reports/reference_summary.md; glm_votes.csv; 10 158 chamadas]`

escopo	memes	parse	confiantes (3-0)	exigido
total	3 386	0,9985	0,7091	—
en	1 715	0,9983	**0,7265** (1 246)	≥ 0,70 ✓
es	1 671	0,9988	**0,6912** (1 155)	≥ 0,70 ✗ (mínimo 1 170: faltaram 15 memes)

- **Não é falha de infraestrutura:** as 15 chamadas não parseadas são HTTP 400 em 5 memes (3 en, 2 es), por imagens de 6 090 a 6 144 tokens, acima do cache de encoder (6 084). Mesmo contando os 2 memes em espanhol como confiantes, seriam 1 157 < 1 170.
- **O piloto superestimou a confiança:** 0,750 → 0,709 no total; 0,725 → 0,691 em espanhol.
- **A dependência de redação se confirmou:** YES por paráfrase de P1 0,861 · P2 0,913 · **P3 0,636**. Nos 980 memes não confiantes, a dissidente foi P1 em 39, P2 em 207 e **P3 em 734 (75 %)**.
- **Distribuição da referência** (`SPEC_27.md` §1): 3-0 YES 0,634 · 3-0 NO 0,075 · 2-1 YES 0,218 · 2-1 NO 0,071 · sem resposta 0,001.

Leitura pré-registrada: a referência não sustenta a ponderação dos anotadores, e o doc 25 terminou aqui, sem calcular pesos e sem GPU.

`[HIPÓTESE]` A P3 (texto antes da instrução; "*contains sexist expressions or behaviors*") induz uma leitura mais restritiva. O fatorial que separaria ordem e enquadramento (doc 26) foi pré-registrado e aguarda o servidor; ainda não há resultado para citar.

5. Doc 27 — Ponderação pela distância ao soft label do GLM

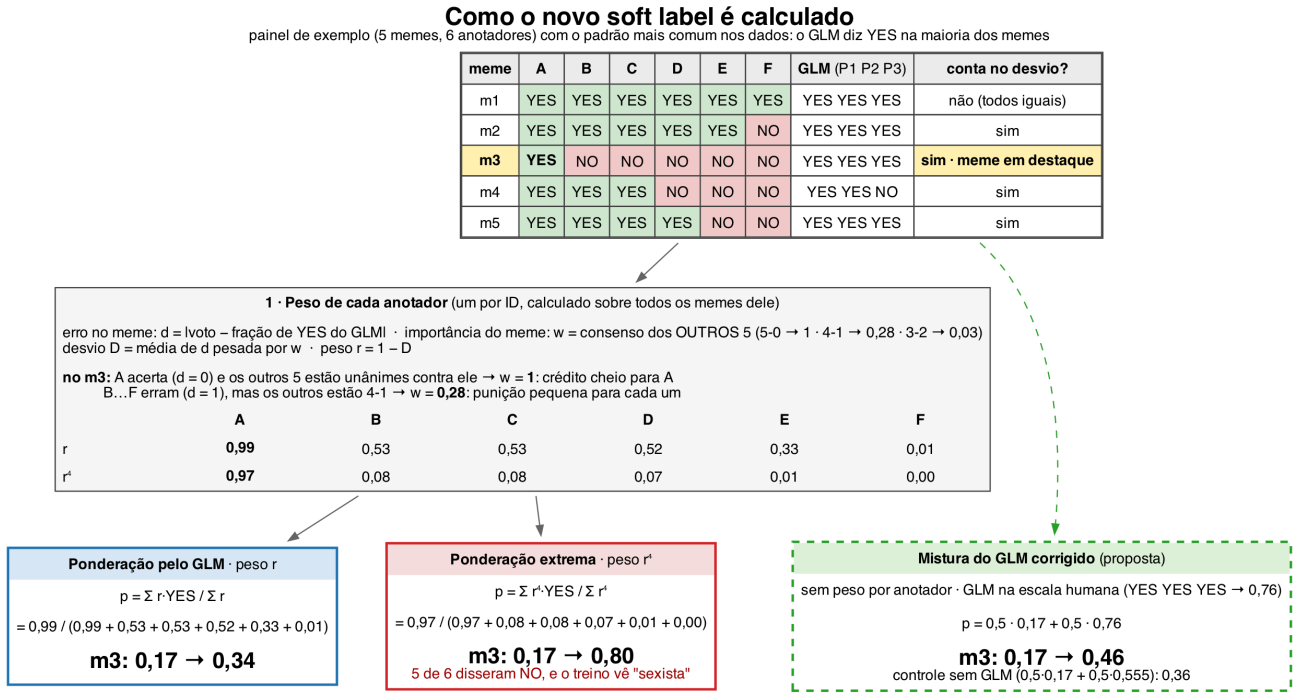


Figura R1 — Os três métodos de label aplicados a um painel de exemplo: ponderação por r (doc 27), por r⁴ (doc 28) e a mistura corrigida proposta (doc 29, não executada). Fonte: `reports/soft_label_metodos.png`.

Pesos (F3') `[MEDIDO — config.json; annotator_weights.csv]`: 887 anotadores, `r_glm` de 0,021 a 1,0 (mediana 0,562); 3 381 memes com referência; validação idêntica ao `raw` (hash).

Checagens (F4) `[MEDIDO — reports/checks_summary.md]`:

checagem	resultado
(a) ρ(r_glm, r_peer)	**0,5008** (n = 887): o GLM não reproduz o consenso dos pares
(b) ρ(D_glm, taxa de YES do anotador)	**−0,6760**
(b) ρ(D_glm, |limiar do anotador − limiar do GLM|)	**0,7104**
(d) `share_moved` (|Δp| ≥ 1/12)	**0,3461** (en 0,3469 · es 0,3453)
(d) mudanças de rótulo duro	554: empate→YES 409 · empate→NO 109 · NO→YES 36 · **YES→NO 0**
(e) GLM 3-0 contrariando meme unânime	56/608 = 0,0921
(f) acordo do voto do GLM com o rótulo duro humano (empates fora)	0,7073 (6-0 0,8278 · 5-1 0,7083 · 4-2 0,6148)
(g) memes incluídos por anotador	mediana 17 (mín. 7 · máx. 45); largura mediana do IC 95 % de D_glm: **0,456**
(h) massa Σw vinda de memes 2-1	0,2879
(i) divisões humanas 4-2/3-3 nos memes GLM 2-1 vs 3-0	0,522 vs 0,436; diferença **+0,086** (IC 95 % [+0,049; +0,123])

r por gênero × idade (c): mulheres e faixas etárias mais altas recebem peso maior (F 46+: 0,596 [0,559; 0,630]; M 18–22: 0,461 [0,425; 0,496]). Pelo contraste com `r_peer`, que é quase plano, o padrão vem do GLM. `[HIPÓTESE]` Esses grupos dizem mais YES, e o peso favorece quem diz YES, como mostra (b).

Portão G4 aprovado (0,3461 ≥ 0,05 e 0,5008 < 0,8). **Retreino (F5)** `[MEDIDO — reports/f5_report.md; estado primário E = argmin eval_loss = época 3 nas 6 runs]`:

métrica	Δ 42	Δ 7	Δ 2025	média	t	p
A ICM-Soft-Norm (primária)	+0,0040	+0,0057	+0,0126	**+0,0074**	2,81	0,107
A ICM-Norm *hard*	+0,0160	−0,0079	−0,0019	+0,0021	0,29	0,802
`eval_loss` (↓ melhor)	+0,0148	+0,0096	+0,0035	**+0,0093** (pior)	2,83	0,105

Tasks B e C sem sinal (|Δ| ≤ 0,005, p > 0,4). No estado final (secundário): ICM-Soft-Norm A −0,0052 (p = 0,237) e `eval_loss` +0,0432 (p = 0,038). **Critério não satisfeito: efeito não detectado com 3 seeds.** O controle `glmshift` não rodou, pela regra fixada.

6. Doc 28 — Peso r^4

Efeito nos labels de treino: deslocamento médio para o YES de +0,120 (doc 27: +0,054); 62,5 % dos memes mudam meio voto ou mais; 849 rótulos duros mudam (19 de YES para NO).

Triagem (seed 42) `[MEDIDO — reports/doc28_screen.md]`: hard −0,0778, soft −0,0492, `eval_loss` +0,1269, todos além dos limites, e por isso seguiu para as outras seeds.

Confirmação `[MEDIDO — reports/f5_report_glmw4.md]`:

métrica	Δ 42	Δ 7	Δ 2025	média	t	p
A ICM-Soft-Norm (primária)	−0,0492	−0,0222	−0,0026	**−0,0247**	−1,83	0,209
A ICM-Norm *hard*	−0,0778	−0,0350	−0,0257	−0,0462	−2,88	0,102
`eval_loss` (↓ melhor)	+0,1269	+0,1014	+0,0680	**+0,0988** (pior)	5,79	**0,029**

No estado final (secundário): ICM-Soft-Norm A −0,0465 (3/3 seeds, p = 0,002) e `eval_loss` +0,2884 (p < 0,001). **Efeito negativo registrado.** `[LIMITAÇÃO]` Na seed 42, a época escolhida (2) quase empatou com a 4 (diferença de 0,0007 na loss): não citar o Δ da seed 42 isolado.

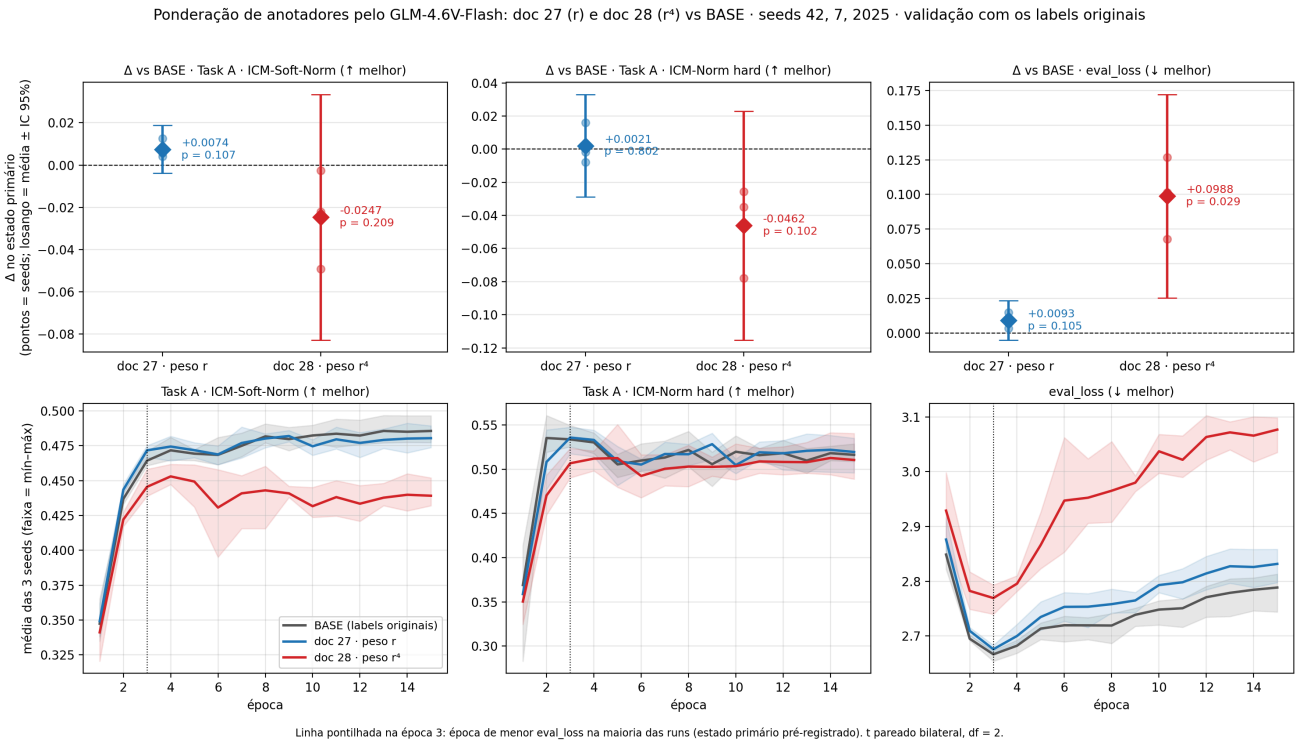


Figura R2 — Δ contra o BASE no estado primário (em cima) e curvas por época (embaixo), docs 27 e 28. Fonte: `reports/doc27_28_resultados.png`.

Leitura dos docs 27–28. A ponderação pelo GLM desloca a calibração para o YES, em vez de selecionar anotadores mais fiáveis. Quanto mais forte o deslocamento, mais os labels de treino se afastam dos labels humanos da validação, e pior o modelo fica. `[HIPÓTESE]` Que o efeito seja **só** o deslocamento é uma inferência: o controle que a testaria (`glmshift`) não rodou.

7. Doc 29 — Mistura corrigida por quantis (rascunho; só o teste offline)

`[MEDIDO — reports/splithalf_29.md; 3 381 memes, 20 divisões por meme; nenhum modelo treinado]`

previsor da outra metade (3 anotadores)	MSE ↓	entropia cruzada ↓
só a metade (humano puro)	0,1193	1,1079
0,5·metade + 0,5·0,555 (`smooth50`)	0,0916	**0,6112**
0,5·metade + 0,5·GLM sem correção	0,1062	0,8563
0,5·metade + 0,5·q(GLM) (`glmq50`)	**0,0885**	0,6242
só q(GLM)	0,1154	0,7240

`glmq50 − smooth50`: MSE −0,0031 (IC 95 % [−0,0043; −0,0019]); entropia cruzada +0,0130 (IC 95 % [+0,0077; +0,0182]). O GLM corrigido tem alguma informação sobre a opinião humana, mas o ganho além da suavização cega é pequeno, e o sinal se inverte conforme a métrica. **Proposta não aprovada; nenhum label foi gerado.**

8. Doc 30 — Thinking ligado no treino inteiro

`[MEDIDO — reports/think_on_vs_off.md; config.json → runtime.doc30; 10 158 chamadas think_on, parse 0,9985]`

escopo	humanos (média p_h)	YES `think_off`	YES `think_on`	Δ (on − off)	confiantes `think_on`	voto igual on/off
total	0,555	0,804	0,711	−0,093	0,747	0,853
en	0,542	0,793	0,708	−0,085	0,764	0,875
es	0,568	0,817	0,715	−0,102	0,730	0,831

p_GLM (0 / ⅓ / ⅔ / 1): `think_on` 608 / 255 / 596 / 1 922 · `think_off` 254 / 241 / 739 / 2 147.

Decisão pela regra pré-registrada: o viés de YES PERSISTE (0,711 ≥ 0,655).

Descritivo extra (3 381 memes com referência; acerto sem os empates 3-3):

braço	acerto vs maioria humana	Spearman(p_GLM, p_h)	YES quando os humanos dizem NO (n = 1 161)	NO quando os humanos dizem YES (n = 1 702)
`think_off`	0,707	0,496	0,674	0,032
`think_on`	0,753	0,501	0,488	0,082

O thinking desloca o limiar do GLM (o falso YES cai de 67 % para 49 %), mas quase não muda a **ordenação** dos memes (Spearman 0,496 → 0,501). Custo: 12,7 h de servidor para 9 438 chamadas, contra 0,78 h com o thinking desligado.

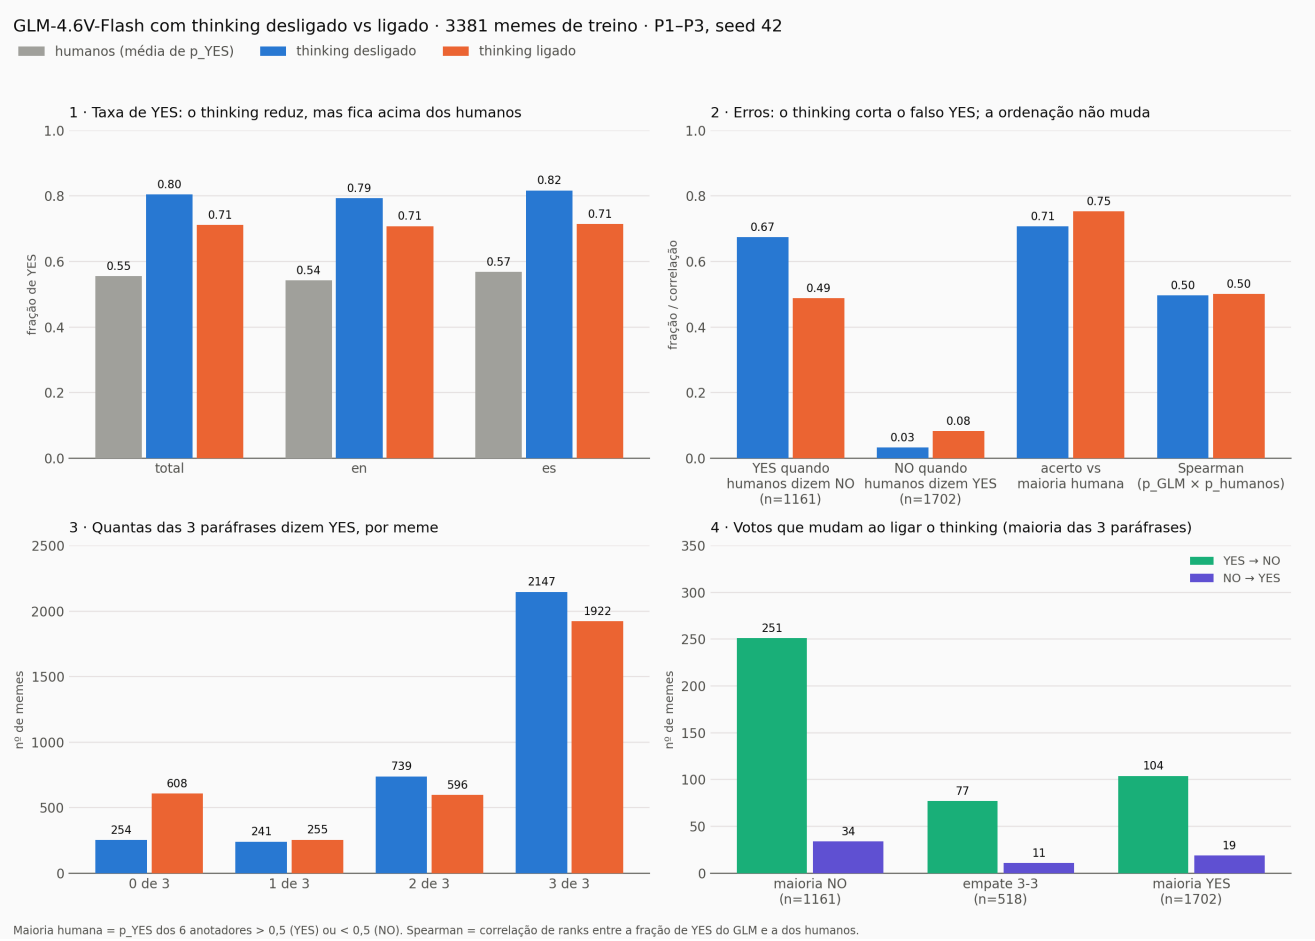


Figura R3 — Doc 30. Fonte: `reports/doc30_think_on_vs_off.png`.

Parte II — Memes extremos: GLM × Claude

Escopo de comparação. O Claude rodou **só** nos 1 551 memes extremos do treino (1Y5N n = 388, 3Y3N n = 518, 5Y1N n = 645; Metodologia §6). Todas as tabelas desta parte comparam os três anotadores nos **mesmos** memes. Os números do GLM no treino completo (Parte I, §8) não são diretamente comparáveis a estes e aparecem só como contexto, na §15.

9. Regra pré-registrada (SPEC_31 §3) — PARCIAL

`[MEDIDO — claude_reference/raw/claude-sonnet-5-5_think_off.jsonl; reports/claude_claude-sonnet-5-5_think_off_extremes.md]`

Voto YES do Claude no 1Y5N = **111/388 = 0,286** (IC 95 % de Wilson: 0,243–0,333). O valor fica entre 0,25 e 0,40, então a decisão é **PARCIAL**. O intervalo inteiro está abaixo do limite de 0,40 e cruza o de 0,25.

Histórico da métrica, registrado com as datas em `SPEC_31.md` §5:

- piloto (20 memes por grupo): 0,200, que não aplica a regra porque o IC 95 % ia de ~0,06 a ~0,44;
- rodada completa antes do reenvio PNG: 108/388 = 0,278, com 8 memes do 1Y5N sem voto;
- final: 111/388 = 0,286.

10. Voto YES por grupo e idioma

`[MEDIDO — extremes.csv + JSONL do Claude; voto = maioria das 3 paráfrases; k/n e IC 95 % de Wilson]`

grupo	idioma	n	humanos	GLM off	GLM on	Claude
1Y5N	total	388	0,167	0,719 (279) [0,672; 0,761]	0,510 (198) [0,461; 0,560]	**0,286 (111) [0,243; 0,333]**
1Y5N	en	210	0,167	0,643 (135) [0,576; 0,705]	0,471 (99) [0,405; 0,539]	0,271 (57) [0,216; 0,335]
1Y5N	es	178	0,167	0,809 (144) [0,745; 0,860]	0,556 (99) [0,483; 0,627]	0,303 (54) [0,241; 0,374]
3Y3N	total	518	0,500	0,880 (456) [0,850; 0,906]	0,753 (390) [0,714; 0,788]	**0,689 (357) [0,648; 0,728]**
3Y3N	en	260	0,500	0,865 (225)	0,765 (199)	0,704 (183)
3Y3N	es	258	0,500	0,895 (231)	0,740 (191)	0,674 (174)
5Y1N	total	645	0,833	0,964 (622) [0,947; 0,976]	0,918 (592) [0,894; 0,937]	**0,924 (596) [0,901; 0,942]**
5Y1N	en	310	0,833	0,961 (298)	0,916 (284)	0,919 (285)
5Y1N	es	335	0,833	0,967 (324)	0,919 (308)	0,928 (311)
todos	total	1 551	0,555	0,875 (1 357)	0,761 (1 180)	0,686 (1 064)

No 5Y1N, 1 meme não tem voto do GLM (imagem recusada pelo servidor) e conta no denominador. O Claude tem voto em todos os 1 551.

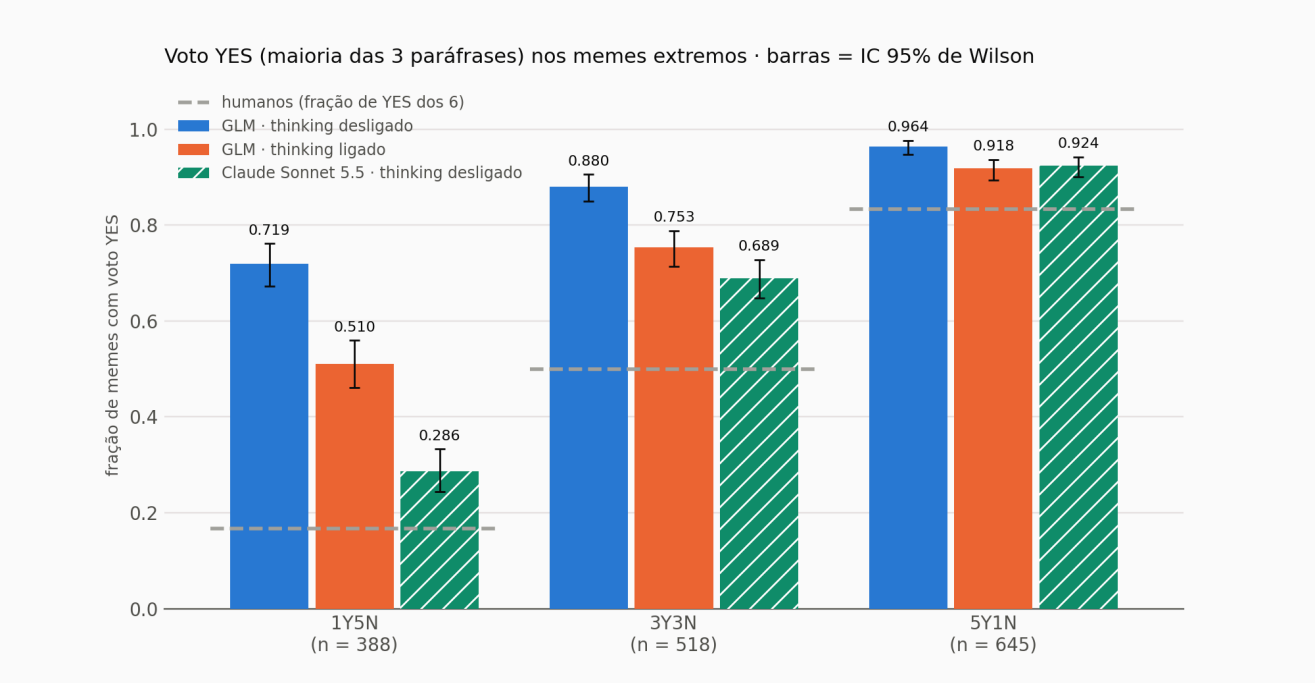


Figura R4 — Voto YES por grupo, com IC 95 % de Wilson; tracejado = fração de YES humana do grupo. Fonte: `reports/doc31_voto_yes.png` *(*`plot_doc31.py`*).*

Leitura. No 1Y5N, o Claude reduz o voto YES do GLM off em 0,433 (0,719 → 0,286) e o do GLM on em 0,224. Os intervalos não se sobrepõem. No 5Y1N, os três ficam acima de 0,833 e o Claude fica no nível do GLM on. No 3Y3N, os três ficam acima de 0,5, o que é um viés para o YES nos memes ambíguos, menor no Claude. A diferença entre idiomas é pequena no Claude (1Y5N: en 0,271 · es 0,303) e grande no GLM off (en 0,643 · es 0,809).

11. Paráfrases: taxa de YES por prompt e concordância (descritivo, pós-hoc)

`[MEDIDO — mesmos arquivos; taxas sobre respostas parseadas]`

Fração de YES por paráfrase:

escopo	anotador	P1	P2	P3	todas
1 551 extremos	GLM off	0,886	0,932	**0,645**	0,821
1 551 extremos	GLM on	0,794	0,791	**0,598**	0,728
1 551 extremos	Claude	0,720	0,677	0,638	0,678
1Y5N	GLM off	0,742	0,825	0,376	0,648
1Y5N	GLM on	0,572	0,557	0,348	0,492
1Y5N	Claude	0,340	0,278	0,258	0,292
3Y3N	GLM off	0,892	0,944	0,614	0,817
3Y3N	GLM on	0,786	0,793	0,566	0,715
3Y3N	Claude	0,726	0,693	0,614	0,678
5Y1N	GLM off	0,969	0,986	0,832	0,929
5Y1N	GLM on	0,935	0,930	0,775	0,880
5Y1N	Claude	0,944	0,904	0,885	0,911

Concordância entre paráfrases (fração de memes 3-0) e paráfrase dissidente:

anotador	1Y5N	3Y3N	5Y1N	todos	memes 2-1: dissidente P1 · P2 · P3
GLM off	0,523	0,651	0,842	**0,698**	21 · 89 · **357** (76 % P3)
GLM on	0,683	0,689	0,797	0,732	79 · 64 · **271** (65 % P3)
Claude	**0,802**	**0,807**	**0,881**	**0,836**	75 · 80 · 99 (39 % P3)

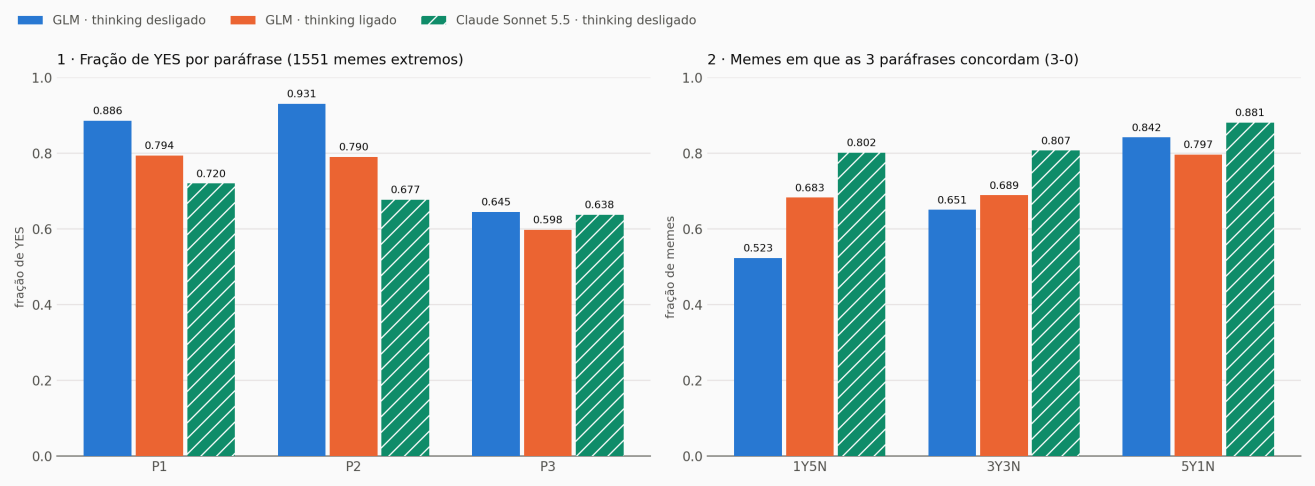


Figura R5 — Fração de YES por paráfrase (esquerda) e concordância 3-0 por grupo (direita). Fonte: `reports/doc31_parafrases.png`.

Leitura.

- **O Claude é mais consistente sob reformulação do prompt**, em todos os grupos, e isso apesar de rodar sem temperatura fixa nem seed.
- No GLM, a P3 é um caso à parte: responde YES ~25 pontos abaixo de P1/P2 e é a dissidente em três quartos dos casos. No Claude, as três paráfrases ficam a menos de 0,09 umas das outras, e as discordâncias se repartem entre elas.
- Curiosamente, a taxa de YES da P3 é quase a mesma nos três anotadores (0,598–0,645). O que separa os modelos é sobretudo P1 e P2.
- `[HIPÓTESE]` A redação da P3 (texto antes da instrução, pergunta sobre "*contains sexist expressions or behaviors*") puxa o GLM para um limiar mais próximo do humano, enquanto a P1/P2, com a regra explícita "*A meme that condemns or reports sexism is still YES*", empurra o GLM para o YES. O Claude parece aplicar o mesmo critério nas três redações. Não testado: é o que o doc 26 mediria.

12. Acordo com a maioria humana (descritivo, pós-hoc)

`[MEDIDO — 1Y5N: maioria humana NO; 5Y1N: maioria humana YES; o 3Y3N não tem maioria e fica fora; meme sem voto = erro]`

anotador	idioma	NO no 1Y5N (n = 388)	YES no 5Y1N (n = 645)	acurácia nos dois grupos (n = 1 033)	média das duas (acurácia balanceada)
GLM off	total	0,281	0,964	0,708	0,623
GLM off	en	0,357	0,961	0,717	0,659
GLM off	es	0,191	0,967	0,698	0,579
GLM on	total	0,490	0,918	0,757	0,704
GLM on	en	0,529	0,916	0,760	0,722

anotador	idioma	NO no 1Y5N (n = 388)	YES no 5Y1N (n = 645)	acurácia nos dois grupos (n = 1 033)	média das duas (acurácia balanceada)
GLM on	es	0,444	0,919	0,754	0,682
Claude	total	**0,714**	0,924	**0,845**	**0,819**
Claude	en	0,729	0,919	0,842	0,824
Claude	es	0,697	0,928	0,848	0,812

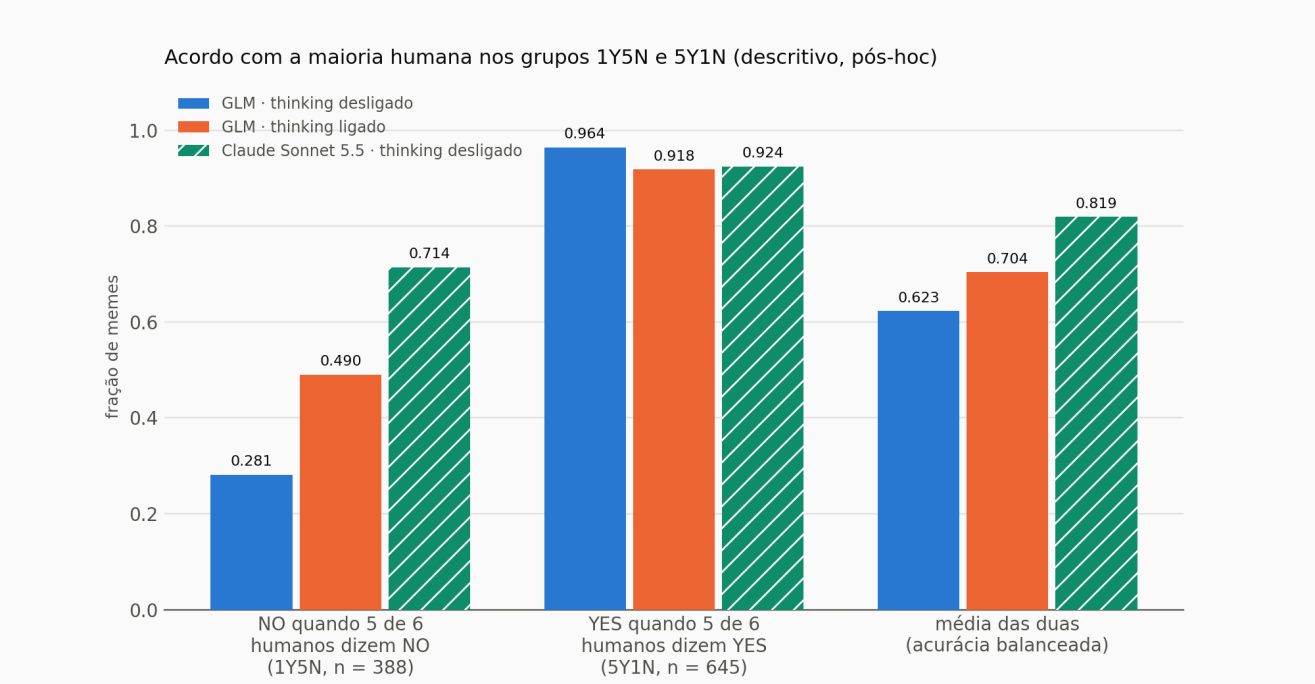


Figura R6 — Fonte: `reports/doc31_acerto.png`.

Leitura. Os três anotadores reconhecem bem um meme que 5 de 6 humanos chamam de sexista (≥ 0,918). A diferença está toda no lado do NO: o GLM off só concorda com a maioria NO em 28 % dos memes 1Y5N (19 % em espanhol), e o Claude em 71 %. `[LIMITAÇÃO]` Estes números valem só para os extremos. Não são comparáveis ao "acerto vs maioria humana" do doc 30 (0,707/0,753), que inclui as divisões 6-0, 4-2 e 2-4.

13. Concordância entre os modelos (descritivo, pós-hoc)

`[MEDIDO — memes com voto dos dois anotadores; κ de Cohen; McNemar exato bilateral; b = só o 1º diz YES, c = só o 2º diz YES]`

grupo	par	n	acordo	κ	os dois YES	b	c	os dois NO	McNemar p
1Y5N	GLM off × Claude	388	0,531	0,210	104	**175**	7	102	$4{,}0{\cdot}10^{-43}$
1Y5N	GLM on × Claude	388	0,657	0,320	88	110	23	167	$8{,}4{\cdot}10^{-15}$
1Y5N	GLM off × GLM on	388	0,724	0,443	185	94	13	96	$2{,}6{\cdot}10^{-16}$
3Y3N	GLM off × Claude	518	0,716	0,203	333	123	24	38	$3{,}2{\cdot}10^{-17}$
3Y3N	GLM on × Claude	518	0,755	0,394	310	80	47	81	$4{,}3{\cdot}10^{-3}$
3Y3N	GLM off × GLM on	518	0,830	0,448	379	77	11	51	$2{,}4{\cdot}10^{-13}$
5Y1N	GLM off × Claude	644	0,896	0,010	575	47	20	2	$1{,}3{\cdot}10^{-3}$
5Y1N	GLM on × Claude	644	0,871	0,108	552	40	43	9	0,83
5Y1N	GLM off × GLM on	644	0,922	0,290	582	40	10	12	$2{,}4{\cdot}10^{-5}$

grupo	par	n	acordo	κ	os dois YES	b	c	os dois NO	McNemar p
todos	GLM off × Claude	1 550	0,745	0,291	1 012	345	51	142	$9{,}8 \cdot 10^{-55}$
todos	GLM on × Claude	1 550	0,779	0,451	950	230	113	257	$2{,}6 \cdot 10^{-10}$
todos	GLM off × GLM on	1 550	0,842	0,480	1 146	211	34	159	$2{,}2 \cdot 10^{-32}$

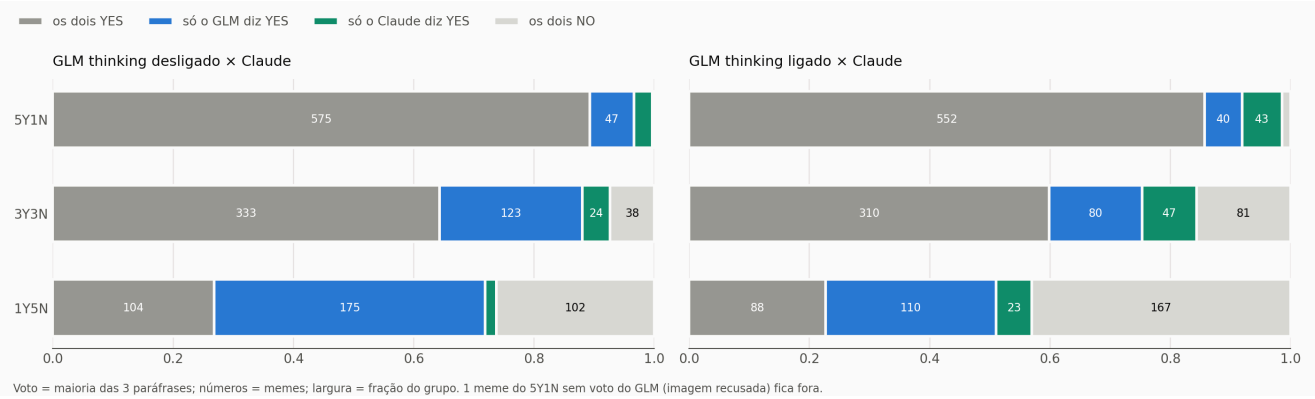


Figura R7 — Votos cruzados, GLM × Claude, por grupo. Fonte: `reports/doc31_cruzamento.png`.

Leitura.

- No 1Y5N, quando os dois discordam, é quase sempre o GLM dizendo YES sozinho: 175 contra 7 casos frente ao GLM off.
- O Claude raramente diz YES onde o GLM off diz NO (51 de 1 550). Ele se comporta como um subconjunto mais conservador do GLM, e não como um anotador com outro critério.
- O κ baixo no 5Y1N (0,010) é efeito da prevalência (quase tudo é YES), e não de discordância real: o acordo bruto é 0,896.
- `[LIMITAÇÃO]` São doze testes de McNemar sem correção para comparações múltiplas. São descritivos, e nenhum deles era regra de decisão. Mesmo com Bonferroni (×12), só o 5Y1N GLM on × Claude (p = 0,83) e o 3Y3N GLM on × Claude (p = 0,0043 → 0,052) deixariam de ser significativos.

14. Qualidade operacional e custo

item	GLM off	GLM on	Claude (`think_off`)
parse nos extremos	0,999 (3 chamadas sem resposta: 1 meme do 5Y1N)	0,999	**1,000** (4 652 `plain` + 1 `single_token`)
recusas	0	0	**0**
erros de imagem	5 memes no treino (cache de encoder)	idem	21 memes "Could not process image" → resolvidos por 1 reenvio em PNG (desvio datado)
tokens gerados por resposta	mediana 4	mediana 169 (máx. 2 084)	média 4,0 (máx. 70)
tempo	0,66 s por chamada; 0,78 h por 9 438 chamadas	16,0 s por chamada; 12,7 h por 9 438	lotes de 3 min a 4,1 h; ~4 h no total (1 551 memes)
custo	servidor do grupo	servidor do grupo	**≈ US$ 5,31** (4 653 pedidos, preço *batch*)

O único `single_token` é o meme 111129 na P2: o Claude respondeu "YES" e acrescentou uma explicação de duas frases (o meme critica chamar mulheres adultas de "niñas"). O parser extraiu YES corretamente.

Estimativa para o treino completo com o Claude (não executado): faltariam 1 835 memes = 5 505 pedidos ≈ US$ 6,3 a mais (≈ US$ 11,6 no total), em 2–4 h, reaproveitando os 4 653 pedidos já feitos.

15. Contexto: o GLM no treino completo (não comparável diretamente)

anotador	memes	YES (paráfrases)	humanos	fonte
GLM off	3 381	0,804	0,555	doc 30
GLM on	3 381	0,711	0,555	doc 30
Claude	—	não rodou no treino completo	—	—

Nos extremos, o GLM off dá 0,821 de YES nas paráfrases, o GLM on 0,728 e o Claude 0,678, contra 0,555 dos humanos (média dos três grupos, ponderada pelo tamanho). Quanto o Claude daria no treino completo só a rodada completa (opção A, §18) diria.

Parte III — Interpretação, limitações e pendências

16. Interpretação

1. **O viés de YES é, em grande parte, do GLM-4.6V-Flash** `[MEDIDO]`. Com os mesmos prompts, imagens e textos, o Claude reduz o falso YES no 1Y5N de 72 % para 29 %, e as discordâncias entre os dois são quase todas "o GLM diz YES sozinho". O raciocínio ligado no GLM corrige só metade dessa distância (0,510).
2. **Mas não é só do GLM** `[MEDIDO]`. O Claude também fica acima dos humanos no 1Y5N (0,286 contra 0,167) e no 3Y3N (0,689 contra 0,5). `[HIPÓTESE]` Uma causa comum aos dois modelos é a própria definição do EXIST embutida nos prompts: "descrever uma situação sexista" ou "criticar um comportamento sexista" conta como YES, e os prompts reforçam isso ("*A meme that condemns or reports sexism is still YES*"). Um modelo que aplica essa regra ao pé da letra diz YES em memes que muitos anotadores humanos, que viram outra instrução, chamaram de NO. A revisão manual no visualizador (os 104 memes do 1Y5N em que os dois modelos dizem YES) é o caminho para checar isso qualitativamente.
3. **A dependência de redação é sobretudo um traço do GLM** `[MEDIDO]`. A concordância entre paráfrases nos extremos sobe de 0,698 (GLM off) para 0,836 (Claude), e a P3 deixa de concentrar as discordâncias. A conclusão do doc 25 ("a verdade do modelo é, em parte, um artefato do prompt") vale para o GLM, e é mais fraca para o Claude.
4. **Para a tese:** os resultados negativos dos docs 25, 27 e 28 se referem a **esta** referência (GLM-4.6V-Flash FP8, thinking desligado). Eles não autorizam concluir que "LLMs em geral" falham como referência. O doc 31 mostra que outro modelo tem um perfil de viés bem diferente. Se a ponderação ou a mistura com o Claude produziria outro resultado no modelo de memes é uma pergunta nova, que exigiria a referência no treino completo e um pré-registro próprio.

17. Limitações

- `[LIMITAÇÃO]` **Sem seeds no Claude.** A API não aceita `seed` nem temperatura fixa nos modelos 5.5. A estabilidade entre execuções não foi medida. As respostas de 4 tokens sugerem baixa variabilidade, mas isso é `[HIPÓTESE]`.
- `[LIMITAÇÃO]` **Escopo do Claude:** só os 1 551 extremos e só o braço `think_off`. Não há números do Claude no treino completo, nos grupos 0, 2, 4 e 6 YES, nem com o raciocínio ligado.
- `[LIMITAÇÃO]` **Um modelo de cada família:** GLM-4.6V-Flash FP8 e Claude Sonnet 5.5. Nenhum modelo GPT, Gemini ou DeepSeek foi testado.

- `[LIMITAÇÃO]` **Imagens:** 1 meme reduzido (limite de 5 MB) e 21 reconvertidos para PNG no Claude; 5 memes de treino sem resposta do GLM (1 deles no 5Y1N).
- `[LIMITAÇÃO]` **Prompts:** as diretrizes reais dos anotadores de memes do EXIST não são públicas. Os prompts são uma aproximação, e o viés medido é relativo a eles.
- `[LIMITAÇÃO]` **Métricas pós-hoc:** só o voto YES no 1Y5N (e o 3Y3N como secundária) foi pré-registrado no doc 31. O resto é descritivo.
- `[LIMITAÇÃO]` **Retreinos (docs 27–28):** 3 seeds (df = 2). "Efeito não detectado" não é "efeito zero".

18. Pendências e próximos passos possíveis (nenhum autorizado ainda)

opção	o que mede	custo estimado	pré-requisito
A. Claude `think_off` no treino completo	taxa de YES, Spearman e acerto comparáveis ao doc 30	≈ US$ 6,3 · 2–4 h	seção datada no SPEC_31 + `--scope train` no script
B. Repetir o piloto do Claude (180 pedidos)	estabilidade entre execuções (substitui o teste de seeds)	≈ US$ 0,2 · minutos	seção datada
C. Claude `think_on` nos extremos	o raciocínio muda o viés no Claude?	maior (raciocínio cobrado como saída)	medir o custo no piloto antes
D. Revisão manual no visualizador dos 104 memes 1Y5N com os dois YES	a hipótese da definição EXIST (§16, item 2)	tempo do autor	—
E. Doc 29	a mistura corrigida ajuda o modelo de memes?	6 runs de GPU	aprovação do orientador

Todos os números deste relatório vêm dos artefatos citados. O doc 26 não tem resultado, e o doc 29 é rascunho: nenhum dos dois deve ser apresentado como experimento concluído.