Dar pesos aos anotadores usando um modelo de linguagem como referência: resultados

EXIST 2026 · Task 2.1 (o meme é sexista? SIM/NÃO) · docs 27, 28 e 33 · versão de 2026-10-29 · Jonathan Santos da Silva

Resumo

Os termos técnicos (seed, Δ, p-valor, ICM, eval_loss…) estão explicados na p. 2; a conta do peso está na p. 3.

A pergunta. Cada meme de treino foi rotulado por 6 pessoas, que muitas vezes discordam. A ideia testada: dar **mais peso** às pessoas que concordam com um modelo de linguagem usado como **referência**, recalcular os rótulos de treino com esses pesos e treinar o modelo de memes de novo. Ele fica melhor do que o mesmo modelo treinado com os rótulos originais (o **BASE**)?

DOC 27
GLM · peso r
Referência: o modelo GLM-4.6V-Flash. Peso r = 1 − D (D = quanto o anotador discorda da referência).

DOC 28
GLM · peso r^4
Mesma referência e mesmo r do doc 27, elevado à 4ª potência: quem já tinha peso baixo quase some (dose maior).

DOC 33
Persona · peso r
Referência: o modelo Claude Sonnet 5.5 no papel de anotador (Persona). Peso r = 1 − D, como no doc 27.

O critério, fixado antes de qualquer treino: o método só "funciona" se as três condições abaixo valerem juntas. Cada método foi treinado 3 vezes (3 seeds) e comparado com o BASE na mesma seed.

condição	🔵 GLM · peso r doc 27	🟠 GLM · peso r^4 doc 28	🟢 Persona · peso r doc 33
1. A métrica principal subiu? Δ médio de ICM-Soft-Norm > 0	✓ +0,0074	✗ −0,0247	✓ +0,0118
2. A diferença passa no teste? p-valor < 0,05	✗ p-valor = 0,107	✗ p-valor = 0,209	✓ p-valor = 0,023
3. A eval_loss não piorou? Δ médio de eval_loss ≤ 0	✗ +0,0093 (p-valor = 0,105)	✗ +0,0988 (p-valor = 0,029)	✗ +0,0088 (p-valor = 0,039)
Critério (as 3 juntas)	✗ não satisfeito	✗ não satisfeito	✗ não satisfeito

Resposta curta: nenhum método mostrou melhora. Nenhum dos três cumpriu o critério; cumprir duas condições em três não basta.

Persona (doc 33): melhorou a métrica principal (+0,0118, p-valor = 0,023), mas também piorou a eval_loss nas 3 seeds (+0,0088, p-valor = 0,039). As duas diferenças passam no teste e vão em direções opostas. A regra fixada antes classifica esse caso como "efeito não detectado com 3 seeds", o que não é o mesmo que "efeito zero".

Doc 27: nenhuma diferença passa no teste (efeito não detectado). **Doc 28:** a eval_loss piorou (+0,0988, p-valor = 0,029): um efeito negativo, registrado como resultado.

Para dar escala: na época E, o BASE marca 0,464 na ICM-Soft-Norm e 2,666 na eval_loss (média das 3 seeds). O ganho da Persona na ICM equivale a 2,5 %; a piora da eval_loss foi de 0,3 % na Persona e de 3,7 % no doc 28. Os três docs são exploratórios: o doc 28 testou uma dose maior do peso sem apostar antes se ia melhorar ou piorar.

Como ler: o que cada termo significa

Dados e rótulos	
Task 2.1	Pergunta do EXIST 2026 (competição de detecção de sexismo): o meme é sexista? Resposta SIM ou NÃO.
anotador	Pessoa que rotulou o meme. Cada meme foi rotulado por 6 pessoas; no treino são 887 pessoas diferentes.
treino / validação	3386 memes usados para treinar o modelo; 598 memes separados só para medir o resultado. Os rótulos da validação são sempre os originais, em todos os métodos.
rótulo suave (soft label)	Fração dos 6 anotadores que disse SIM. Ex.: 4 de 6 → 0,667. Escrevemos **p_old** (original), **p_new** (com os pesos) e **p_ref** (da referência). Não confundir com o p-valor, explicado abaixo.
rótulo final	SIM se a fração de SIM passa de 0,5; NÃO se fica abaixo; empate se é exatamente 0,5 (3 × 3).
Referências (os modelos que servem de régua)	
LLM	Modelo de linguagem de grande porte, do tipo do ChatGPT. Os dois usados aqui também leem a imagem do meme.
prompt	A instrução em texto enviada ao modelo junto com o meme. Cada referência responde 3 vezes, com 3 instruções diferentes; cada resposta conta como um voto (p_ref = 0, 1/3, 2/3 ou 1).
GLM	O modelo GLM-4.6V-Flash, com a mesma pergunta feita de 3 jeitos e sem o modo de "pensar por escrito" antes de responder.
Persona	O modelo Claude Sonnet 5.5, com 3 instruções de sistema (S1–S3) que o colocam no papel de um anotador humano cuidadoso.
D e r	D = quanto o anotador discorda da referência (0 a 1); r = 1 − D é o peso do voto dele: 1 = voto inteiro, perto de 0 = quase não conta. A conta passo a passo está na p. 3.
Treino	
BASE	O mesmo modelo de memes treinado com os rótulos originais, em que todos os anotadores valem o mesmo. É contra ele que cada método é comparado.
seed	Número que fixa os sorteios do treino (pesos iniciais, ordem dos memes). Mudar a seed muda o resultado um pouco, só por acaso; por isso cada método foi treinado com 3 seeds (42, 7 e 2025) e comparado com o BASE na mesma seed.
época	Uma passada completa pelos 3386 memes de treino. Cada treino tem 15 épocas.
E	A época em que os resultados são lidos: a de menor eval_loss, escolhida sem olhar a métrica principal, para não pegar a época mais favorável. Foi a 3ª época em 11 dos 12 treinos (4 modelos × 3 seeds); no doc 28 com a seed 42, foi a 2ª.
Métricas (medidas na validação)	
ICM-Soft-Norm	Métrica oficial do EXIST (ICM = Information Contrast Model), de 0 a 1. Compara a probabilidade de SIM que o modelo prevê com a fração de anotadores que disse SIM. **Maior = melhor.** É a métrica principal.
ICM-Norm hard	A mesma métrica usando só o rótulo final (SIM ou NÃO) em vez da probabilidade. Maior = melhor.
eval_loss	Medida de erro do modelo na validação, contra os rótulos originais. **Menor = melhor.** Soma o erro das três perguntas que o modelo responde: 2.1 (é sexista?, conta em dobro), 2.2 (qual a intenção de quem postou?) e 2.3 (que tipo de sexismo?).
Δ	Diferença método − BASE na mesma seed. Δ > 0 na ICM = melhorou; Δ > 0 na eval_loss = piorou.

O que é o p-valor (e o "p-valor < 0,05")? Imagine que o método *não muda nada*. Mesmo assim, as três seeds dariam diferenças pequenas em relação ao BASE, umas para cima e outras para baixo, só por acaso. O **p-valor** é a chance de, nesse mundo "sem efeito", aparecerem três diferenças tão longe de zero, em relação ao quanto variam entre si, quanto as que observamos.

p-valor < 0,05 (menos de 5 %): seria raro só por acaso, então dizemos que a diferença **passa no teste**. **p-valor ≥ 0,05**: o acaso ainda poderia produzir algo assim com alguma frequência, então não dá para afirmar que existe efeito. O limite de 0,05 é uma convenção usada em muitas áreas. O p-valor **não** é a probabilidade de o método funcionar.

Como ele é calculado aqui (teste t pareado). "Pareado" porque cada seed do método é comparada com a mesma seed do BASE: Δ = método − BASE. Com as 3 diferenças, calcula-se `t = média(Δ) ÷ (desvio padrão(Δ) ÷ √3)`, em que o desvio padrão mede o quanto as 3 diferenças se espalham em torno da média, e 3 é o número de seeds. Exemplo da Persona na métrica principal: Δ = +0,00818, +0,01309, +0,01401; média +0,01176, desvio padrão 0,00314 → t = 6,49 → p-valor = 0,023 (tirado da distribuição do teste t para 3 medidas). As três seeds subiram quase o mesmo tanto, por isso o p-valor ficou baixo.

Limite honesto: com só 3 seeds, o p-valor só fica abaixo de 0,05 se t passar de 4,30 (ou ficar abaixo de −4,30). O teste só detecta diferenças grandes e consistentes; uma diferença real, mas pequena, pode passar sem ser detectada. Por isso "não detectado" ≠ "efeito zero".

O que foi feito

1 6 humanos votam SIM/NÃO em cada meme → **2 Referência** (GLM ou Persona) vota 3 vezes no mesmo meme → **3 Peso r** de cada anotador: quanto ele concorda com a referência → **4 Novo rótulo** p_new: votos somados com o peso r → **5 Retreino** com p_new, 3 seeds, e comparação com o BASE

Como o peso de cada anotador é calculado

A conta é a mesma nos três métodos; só muda a referência (GLM ou Persona) e, no doc 28, o peso final é elevado à 4ª potência. Σ quer dizer "soma".

1 Quais memes entram. Só os memes de treino em que os 6 humanos **não** foram unânimes (e a referência respondeu). Memes unânimes não dizem nada sobre quem discorda.

2 Distância no meme: `d = |voto − p_ref|`, com SIM = 1 e NÃO = 0; as barras indicam a distância sem sinal (d = 0: concordou totalmente; d = 1: discordou totalmente). Ex.: o anotador disse SIM e a referência disse SIM em 2 das 3 vezes → d = |1 − 0,667| = 0,333.

3 Importância do meme (w): mede o quanto os **outros 5** anotadores concordam entre si, seja a maioria SIM ou NÃO. 5 a 0 → w = 1; 4 a 1 → w = 0,278; 3 a 2 → w = 0,029. Memes em que os próprios humanos estão divididos quase não contam.

Tecnicamente, w = 1 − H(k), com k = fração de SIM entre os outros 5 e H a entropia binária, que vale 0 quando todos concordam e 1 quando o grupo está dividido ao meio.

4 Desvio e peso: `D = Σ w·d ÷ Σ w`, a média ponderada das distâncias (memes mais importantes contam mais), e `r = 1 − D`. r perto de 1 = concorda com a referência; perto de 0 = discorda. No doc 28, o peso usado é r^4. Anotador sem nenhum meme incluído: r = 1.

5 Novo rótulo do meme: `p_new = (soma dos r de quem votou SIM) ÷ (soma dos r dos 6)`. Se todos tivessem r = 1, isso voltaria a ser a fração original p_old. Os memes unânimes não mudam, e os rótulos da validação também não.

Exemplo real A: o peso do Annotator_456 (7 dos seus 9 memes entram)

meme	voto dele	SIM entre os outros 5	importância w	GLM: p_ref	GLM: d	Persona: p_ref	Persona: d
112030	**NÃO**	2 de 5	0,029	1/3	0,333	1	1,000
112034	**NÃO**	3 de 5	0,029	1	1,000	1	1,000
112026	**NÃO**	2 de 5	0,029	1	1,000	1	1,000
112028	**NÃO**	5 de 5	1,000	1	1,000	1/3	0,333
112032	**SIM**	3 de 5	0,029	1	0,000	1	0,000
112031	**NÃO**	4 de 5	0,278	1/3	0,333	1	1,000
112027	**SIM**	4 de 5	0,278	1	0,000	1	0,000
Σ w e **Σ w·d**			1,672		1,160		0,699
D = Σ w·d ÷ Σ w				1,160 ÷ 1,672 = **0,694**		0,699 ÷ 1,672 = **0,418**	
peso r = 1 – D				**0,306** (r^4 = 0,009)		**0,582**	

Valores arredondados; a conta usa os valores exatos. O mesmo anotador recebe pesos diferentes porque as duas referências discordam em alguns memes. O que mais pesa é o meme 112028, em que os outros 5 concordam entre si (w = 1,000): ele votou NÃO, a GLM deu p_ref = 1 (d = 1,000) e a Persona p_ref = 1/3 (d = 0,333).

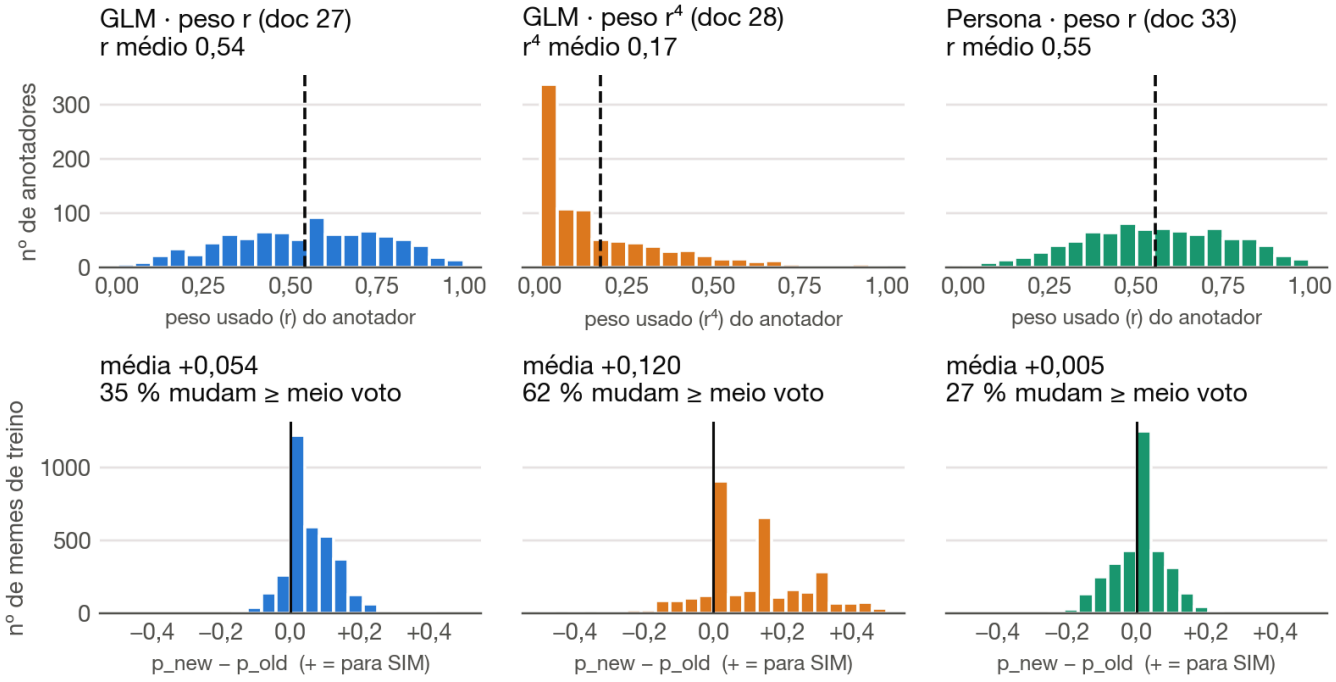
Exemplo real B: o meme 211327, empatado em 3 SIM × 3 NÃO (p_old = 0,500)

A GLM disse SIM nas 3 respostas e a Persona disse NÃO nas 3. Mas o meme não recebe o voto da referência: ele recebe os votos dos 6 humanos, cada um com o peso r que o anotador ganhou nos seus memes incluídos (os não unânimes), não só neste. A barra mostra o peso (escuro = votou SIM).

anotador	voto	peso r com a GLM (doc 27)	peso r com a Persona (doc 33)
Annotator_735	**SIM**	0,154	0,898
Annotator_736	**SIM**	0,884	0,064
Annotator_737	**NÃO**	0,096	0,937
Annotator_738	**NÃO**	0,089	0,934
Annotator_739	**SIM**	0,301	0,642
Annotator_740	**NÃO**	0,112	0,912
p_new = Σ r dos SIM ÷ Σ r		1,339 ÷ 1,636 = **0,818** → SIM	1,604 ÷ 4,387 = **0,366** → NÃO

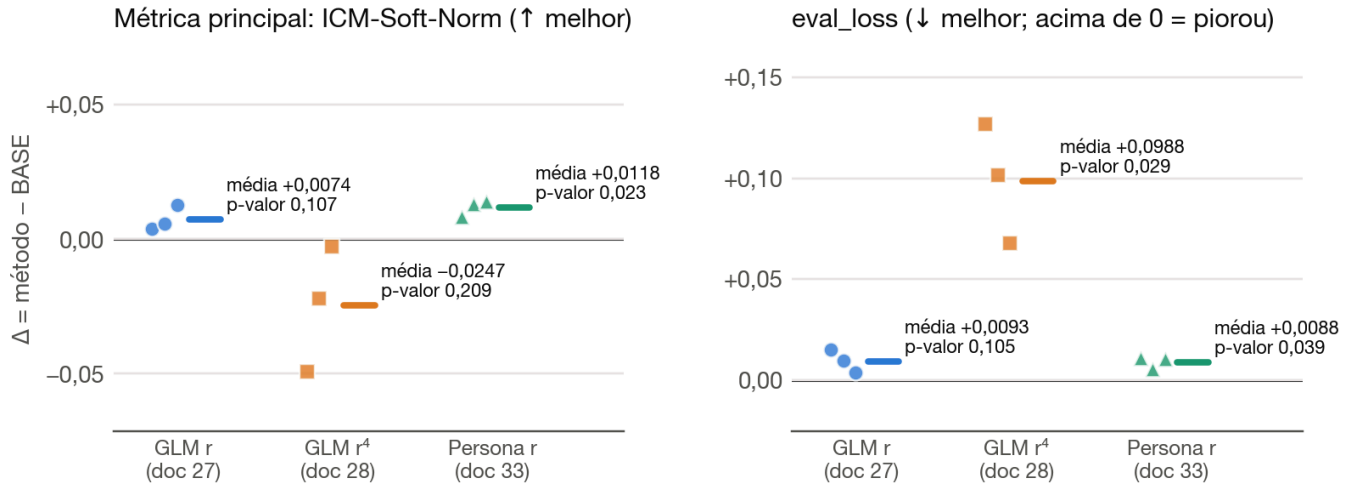
O que cada método fez com os rótulos de treino

método	peso médio usado	deslocamento médio (+ = rumo ao SIM)	mudança média (sem sinal)	memes que mudam ≥ meio voto (1 voto = 1/6)	empates 3 × 3 desfeitos	SIM ↔ NÃO invertidos
GLM · peso r doc 27	0,54	+0,054	0,065	34,6 %	518 de 518	36
GLM · peso r^4 doc 28	0,17 (r^4)	+0,120	0,154	62,5 %	518 de 518	331
Persona · peso r doc 33	0,55	+0,005	0,053	27,4 %	518 de 518	8



Linha de cima: o peso usado para cada um dos 887 anotadores (r; no doc 28, r^4), com a média tracejada. Linha de baixo: quanto o rótulo suave de cada meme de treino mudou (memes unânimes ficam em 0). Com a GLM, os rótulos se deslocam para o SIM, ainda mais com r^4; com a Persona, o deslocamento médio é quase zero, mas um quarto dos memes ainda muda pelo menos meio voto. Todo empate 3 × 3 vira SIM ou NÃO com os pesos; inverter um rótulo que já era SIM ou NÃO é raro, exceto com r^4.

Resultados do retreino (época E)

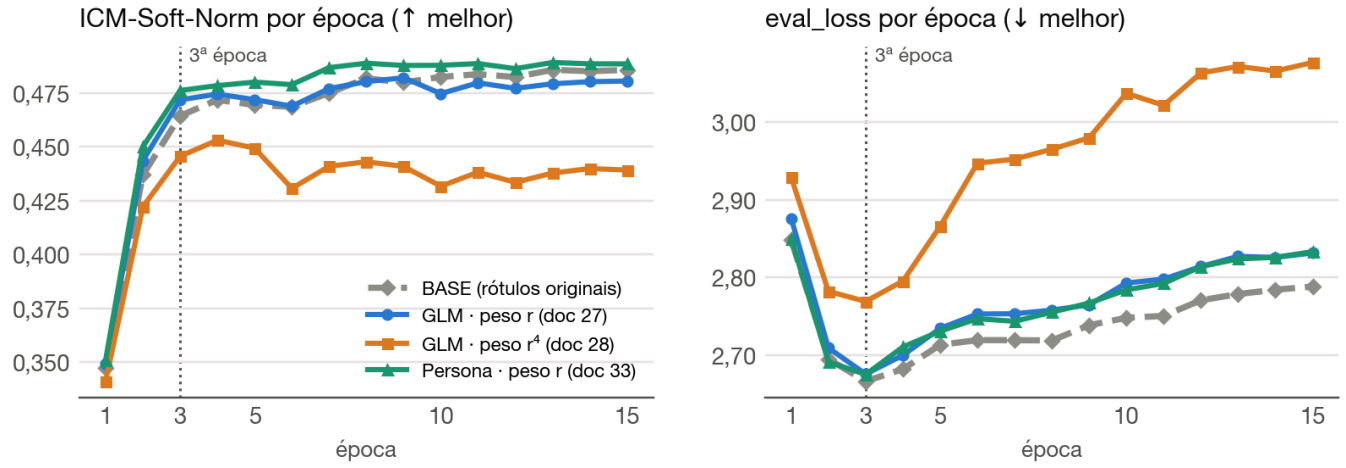


Cada símbolo é uma seed (da esquerda para a direita: 42, 7, 2025); o traço é a média das três. Zero = igual ao BASE. À esquerda, acima de zero é melhor; à direita (eval_loss), acima de zero é pior. Os três métodos pioram a eval_loss nas 3 seeds.

métrica (Δ médio = método − BASE)	GLM · peso r doc 27	GLM · peso r⁴ doc 28	Persona · peso r doc 33
Task 2.1 · ICM-Soft-Norm (principal) ↑	+0,0074 (p-valor = 0,107)	−0,0247 (p-valor = 0,209)	+0,0118 (p-valor = 0,023)
Task 2.1 · ICM-Norm hard ↑	+0,0021 (p-valor = 0,802)	−0,0462 (p-valor = 0,102)	+0,0041 (p-valor = 0,811)
eval_loss ↓	+0,0093 (p-valor = 0,105)	+0,0988 (p-valor = 0,029)	+0,0088 (p-valor = 0,039)
Task 2.2 · ICM-Soft-Norm ↑	−0,0005 (p-valor = 0,781)	−0,0113 (p-valor = 0,337)	−0,0001 (p-valor = 0,928)
Task 2.3 · ICM-Soft-Norm ↑	−0,0004 (p-valor = 0,860)	−0,0157 (p-valor = 0,187)	−0,0046 (p-valor = 0,202)

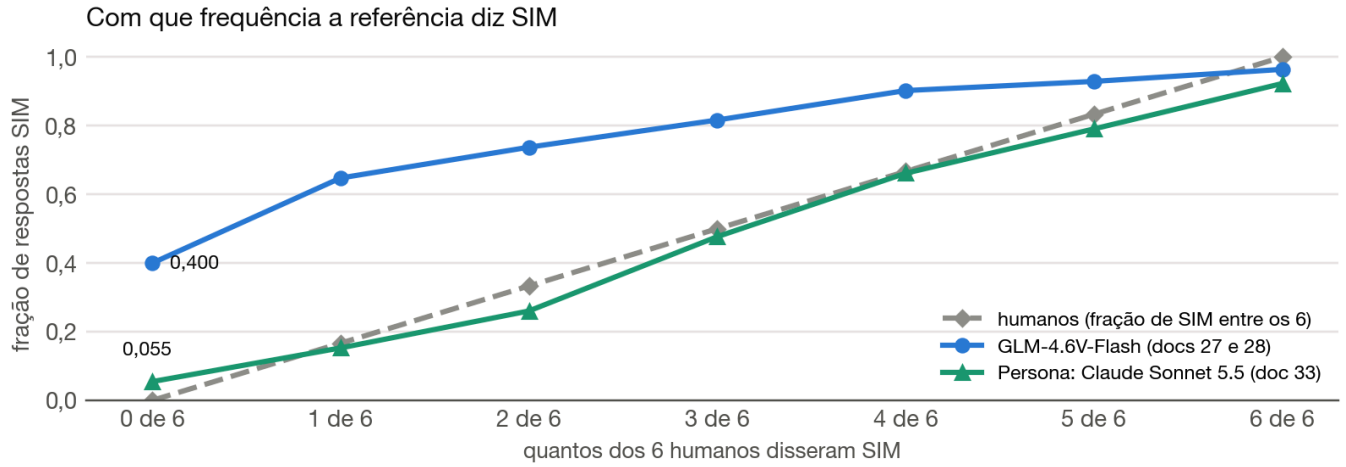
↑ = quanto maior, melhor; ↓ = quanto menor, melhor. Fundo verde = diferença que passa no teste (p-valor < 0,05) para melhor; fundo vermelho = para pior. Tasks 2.2 e 2.3: as outras duas perguntas do mesmo modelo, cujos rótulos não foram mexidos; servem para ver se a mudança na Task 2.1 estragou algo nelas. Nenhuma tem p-valor < 0,05.

Época a época



Média das 3 seeds em cada época. A menor eval_loss (a época E) foi a 3ª época em 11 dos 12 treinos (4 modelos × 3 seeds); no doc 28 com a seed 42, foi a 2ª. Depois dela, a eval_loss sobe, e sobe mais nos métodos com peso, sobretudo no r⁴. As curvas são médias e não substituem o teste feito na época E.

Por que as duas referências dão pesos diferentes



Todos os 3386 memes de treino, agrupados por quantos dos 6 humanos disseram SIM. Linha tracejada = os próprios humanos. Nos memes que **nenhum** humano achou sexista, 40 % das respostas da GLM foram SIM; da Persona, 5,5 %. Os grupos 1, 3 e 5 são os memes em que as instruções da Persona foram escritas e testadas (doc 32); nos grupos 0, 2, 4 e 6, que ela não tinha visto, a diferença para os humanos fica em no máximo 0,08.

Com a GLM, quem diz muito SIM concorda mais com a referência e ganha peso, e os rótulos andam para o SIM. A Persona diz SIM com frequência parecida com a dos humanos e quase não desloca os rótulos na média. Nas checagens do doc 33, o peso da Persona quase não acompanha a taxa de SIM do anotador, mas ainda acompanha em parte o quanto ele é mais ou menos exigente que a Persona para dizer SIM (leitura fixada antes: "parcial").

Conclusão

- **Doc 27 (GLM, r):** ganho pequeno na métrica principal (+0,0074, p-valor = 0,107) e eval_loss um pouco maior (+0,0093, p-valor = 0,105); nenhum dos dois passa no teste. Efeito não detectado.
- **Doc 28 (GLM, r⁴):** a dose maior piorou a eval_loss (+0,0988, p-valor = 0,029): efeito negativo. A métrica principal caiu (−0,0247), mas sem passar no teste (p-valor = 0,209).
- **Doc 33 (Persona, r):** melhora que passa no teste na métrica principal (+0,0118, p-valor = 0,023), positiva nas 3 seeds, e piora que também passa no teste na eval_loss (+0,0088, p-valor = 0,039; cerca de 1/11 da piora do doc 28). O critério exigia as três condições juntas: não satisfeito.

Na métrica principal, a Persona (a referência mais parecida com os humanos) ficou à frente da GLM, mas essa diferença entre as duas não foi testada: é só uma observação. Nenhum método com peso superou o BASE pelo critério combinado. Pela regra fixada antes, esta série de experimentos termina aqui, sem testar novas variantes do peso em busca de um resultado melhor.

Limites

- 3 seeds: o teste só detecta efeitos grandes e consistentes.
- Uma única divisão treino/validação, com 598 memes de validação. A mesma validação e o mesmo BASE foram usados nos três testes (docs 27, 28 e 33), sem correção para comparações múltiplas. Com a correção mais simples (Bonferroni: limite 0,05 ÷ 3 ≈ 0,017), o p-valor = 0,023 da Persona não passaria. Os três docs são exploratórios, não confirmatórios.
- A eval_loss é medida contra os rótulos originais. Um método que muda os rótulos de treino tende a se afastar deles; não medimos quanto da piora vem disso. A condição sobre a eval_loss foi fixada antes, junto com o resto do critério.

Fontes: f5_report*.json (glm_reference/reports), metrics_history/, annotator_weights*.csv, soft_labels_taskA_*.json, glm_votes.csv e persona_votes.csv. Gerado por glm_annotator/relatorio_resultados_pdf.py.