Estimadores de confiabilidade de anotadores na Task 2.1 do EXIST 2026

NUTMEG, agregação de verdade única, desconto de dificuldade, IRT, ablação e camada de confusão: metodologia e resultados

Jonathan Santos da Silva · EXIST 2026 (Task 2.1, memes) · versão de 2026-10-24

Parte A: Metodologia (implementação) · Parte B: Relatório de resultados

Metodologia — estimadores de confiabilidade de anotadores na Task 2.1 (memes)

O que é este documento. É a descrição completa e reprodutível de *como* cada estimador de confiabilidade de anotadores foi construído, validado e (quando chegou a isso) usado para retreinar o modelo de memes do EXIST 2026. Cobre a linha `reliability/` (2026-08-26 a 2026-09-14). Os resultados numéricos estão no documento irmão, `RELATORIO_RELIABILITY.md`; aqui só aparecem os números necessários para descrever o desenho (tamanhos, limiares, parâmetros). A linha do anotador LLM (GLM-4.6V-Flash e Claude, docs 25 a 31) está descrita em `EXIST_MEMES/glm_annotator/METODOLOGIA_GLM_CLAUDE.md` e só é referida aqui.

Este texto serve de insumo para os capítulos de implementação e de resultados da dissertação. Tudo o que é número tem a fonte entre parênteses. Os artefactos citados estão em `reliability/outputs/` salvo indicação em contrário.

---

0. Convenções, escopo e mapa

0.1 Convenções

- `[MEDIDO]`: número observado, com o artefacto que o produziu.
- `[HIPÓTESE]`: interpretação plausível, não testada. Não escrever como facto.
- `[LIMITAÇÃO]`: restrição que o texto da tese tem de declarar.
- `[PÓS-HOC]`: decidido depois de ver um resultado. Nunca tem o estatuto de um resultado pré-registado.
- **Pré-registado** significa: o critério de PASS/FAIL foi fixado em código ou em documento *antes* de a execução que ele julga ter sido corrida. Onde isso não aconteceu, está dito.
- Os números deste documento e do relatório foram **recalculados de forma independente** a partir dos artefactos primários (dataset, ficheiros de θ, soft labels e logs de `EXIST_MEMES/metrics_history/`). Os scripts estão em `reliability/relatorio/verificacao/` (§13).

0.2 As famílias testadas

A pergunta comum a todas: *é possível estimar, a partir dos dados do EXIST, uma confiabilidade por anotador que separe ruído de discordância legítima, e usá-la para construir um alvo de treino melhor?* Sob o paradigma *Learning with Disagreement* (LeWiDi), a discordância é sinal; um estimador útil tem de punir ruído **sem** punir perspectivas minoritárias consistentes.

#	Família	Unidade de estimação	Implementação	Foi a dados reais?	Foi a retreino?
F1	**NUTMEG** (EM com verdade por subpopulação)	célula (item, subpopulação)	`reliability/nutmeg_em.py` (`NutmegEM`, K ≥ 2)	sim: θ em 6 definições de subpopulação	**não**
F2	**Agregação bayesiana de verdade única** (tipo MACE)	anotador, verdade por item	o mesmo `NutmegEM` com K = 1 (`single_truth_K1`)	sim	**sim**: soft labels ponderadas por θ (A1)
F3	**Por anotador com desconto de dificuldade**	anotador (~27 votos)	`reliability/perann_reliability.py`	**não** (reprovado no sintético)	não
F4	**Teoria de Resposta ao Item** (IRT 2PL → 1PL)	anotador + item	`EXIST_MEMES/dataset_verifications.ipynb`	sim (ajuste por painel linguístico)	não
F5	**Ablação de anotadores extremos** (remover, contra controlo pareado)	anotador (regra por `yes_rate`)	`EXIST_MEMES/reliability_tests.ipynb`	sim	**sim**: R1 vs R2
F6	**Camada de confusão** (matriz 2×2 por anotador como perda auxiliar)	anotador, aprendido no treino	`EXIST_MEMES/confusion_core.py` + `memes_confusion.ipynb`	sim	**sim** (Fase 1 e Fase 2, parcial)
—	Diagnósticos descritivos (não são estimadores)	—	`divisiveness.py`, `behavioral_profile.py`, `run_behavioral_diagnosis.py`, `validate_latent_dimension.py`, `EXIST_MEMES/Untitled.ipynb`	sim	não
F7	Referência externa (LLM como anotador)	anotador, referência fora dos votos	`EXIST_MEMES/glm_annotator/`	sim	sim (docs 27, 28) — **fora deste documento**

Mapeamento com o `cap07.tex`. A subsecção do IRT no `cap07.tex` diz que "quatro famílias independentes" foram avaliadas: *a Bayesian aggregation model, a subpopulation model, a heuristic estimator with difficulty discounting, and a psychometric model*. A correspondência é F2, F1, F3 e F4, respectivamente. **Evidência para "Bayesian aggregation model" = F2 (K = 1, tipo MACE):** (i) o mesmo parágrafo lista

"subpopulation model" como item separado, e no texto da tese o NUTMEG é o modelo de subpopulação (`cap02.tex`, parágrafo de `ivey2025nutmeg`); (ii) o `cap02.tex` apresenta o MACE dentro dos "Bayesian models of annotation" (`paun2018comparing`); (iii) o estimador K = 1 usa priors Beta(0,5; 0,5) em θ e Dirichlet(0,5) em ξ e um M-step MAP, ou seja, é um modelo bayesiano de agregação (`em_convergence_diagnosis.md` §0). O autor concorda com o mapeamento (2026-10-24); a evidência acima é a que o sustenta. **Pendência:** com a camada de confusão (F6) as famílias passam a ser cinco, e o `CONFUSION_EXPERIMENT.md` §16 já regista que a frase do `cap07.tex` tem de ser corrigida; com a ablação (F5) e a referência LLM (F7) a contagem depende de como a tese agrupar "estimar" e "usar" uma estimativa (ver relatório §20).

0.3 Estado de cada experimento

Experimento	Data	Pré-registo	Execução	Veredito
F1 · grade de recuperação (sintético)	2026-08-26	limiares em `validate.py`	3 seeds × 5 divisividades × 3 taxas de spam × 2 densidades	fenómeno reproduzido; teto ≈ 0,60 na densidade do EXIST
F1 · preservação de minoria	2026-08-26	sim	3 seeds	PASS
F1 · spammer de viés constante (20%)	2026-08-26	sim	3 seeds × 3 modos × 2 rótulos	PASS (com uma célula de fronteira, §4.6)
F1 · stress-sweep de bloco pequeno	2026-08-26	diagnóstico secundário	6 frações × 3 seeds	**quebra** com 2–3 spammers (estimador legado)
F1 · portões reexecutados com o estimador corrigido	2026-10-24 (esta revisão)	mesmos critérios de `validate.py`	grade, minoria, viés, sweep	o legado reproduz bit a bit; com o corrigido **a quebra por bloco pequeno desaparece** (relatório §5)
F1/F2 · θ nos dados reais (7 definições)	2026-08-26, refeito 2026-08-30	— (descritivo)	CPU	ver relatório §8
Divisividade empírica	2026-08-26	regra explícita	50 permutações por nulo	estrutura demográfica marginal
F3 · portão sintético	2026-08-27	limiares em `validate.py`	3 seeds	**FAIL** nas duas variantes
F2 · bug da responsabilidade do M-step	2026-08-30	critérios C1–C4	—	corrigido; θ e soft labels regenerados (`_fixed`)
F2 · retreino a 2 épocas (θ legado)	2026-08-30	critério "efeito > ruído de seed"	6 runs	nulo, **subtreinado**
F2 · retreino a 15 épocas (θ corrigido)	2026-08-30/31	t pareado bilateral, E = argmin(eval_loss)	6 runs	**NULO**
F2 · nulo por permutação de θ	2026-08-30	P1–P5	ficheiros gerados	**nunca treinado**
F4 · IRT (sintético + real)	≈ 2026-09-06	limiares no notebook	3 seeds (+30 no controlo)	θ identificável; parâmetros inutilizáveis
F5 · ablação R1/R2	runs 2026-09-05; critério 2026-09-06	decisiva R1 − R2	9 runs	**NULO**
F6 · Fase 1 (controlo + grelha + braço `clr`)	2026-09-06 a 09-09	§6 do protocolo	1 + 3 + 3 runs	grelha incompleta; braço exploratório nulo
F6 · Fase 2, run A (régua de votos)	2026-09-11	§12 do protocolo	1 run	**NULO**
F6 · Fase 2, run B (controlo positivo)	2026-09-11	§12 do protocolo	1 run	**treinada, nunca analisada**
F6 · Fase 2, runs C/D/E (viés congelado)	—	§17 do protocolo	—	não corridas (dependem da Porta 1)
Análise de painéis	2026-09-14	— (descritivo)	CPU	limiar pessoal estável (split-half 0,850)

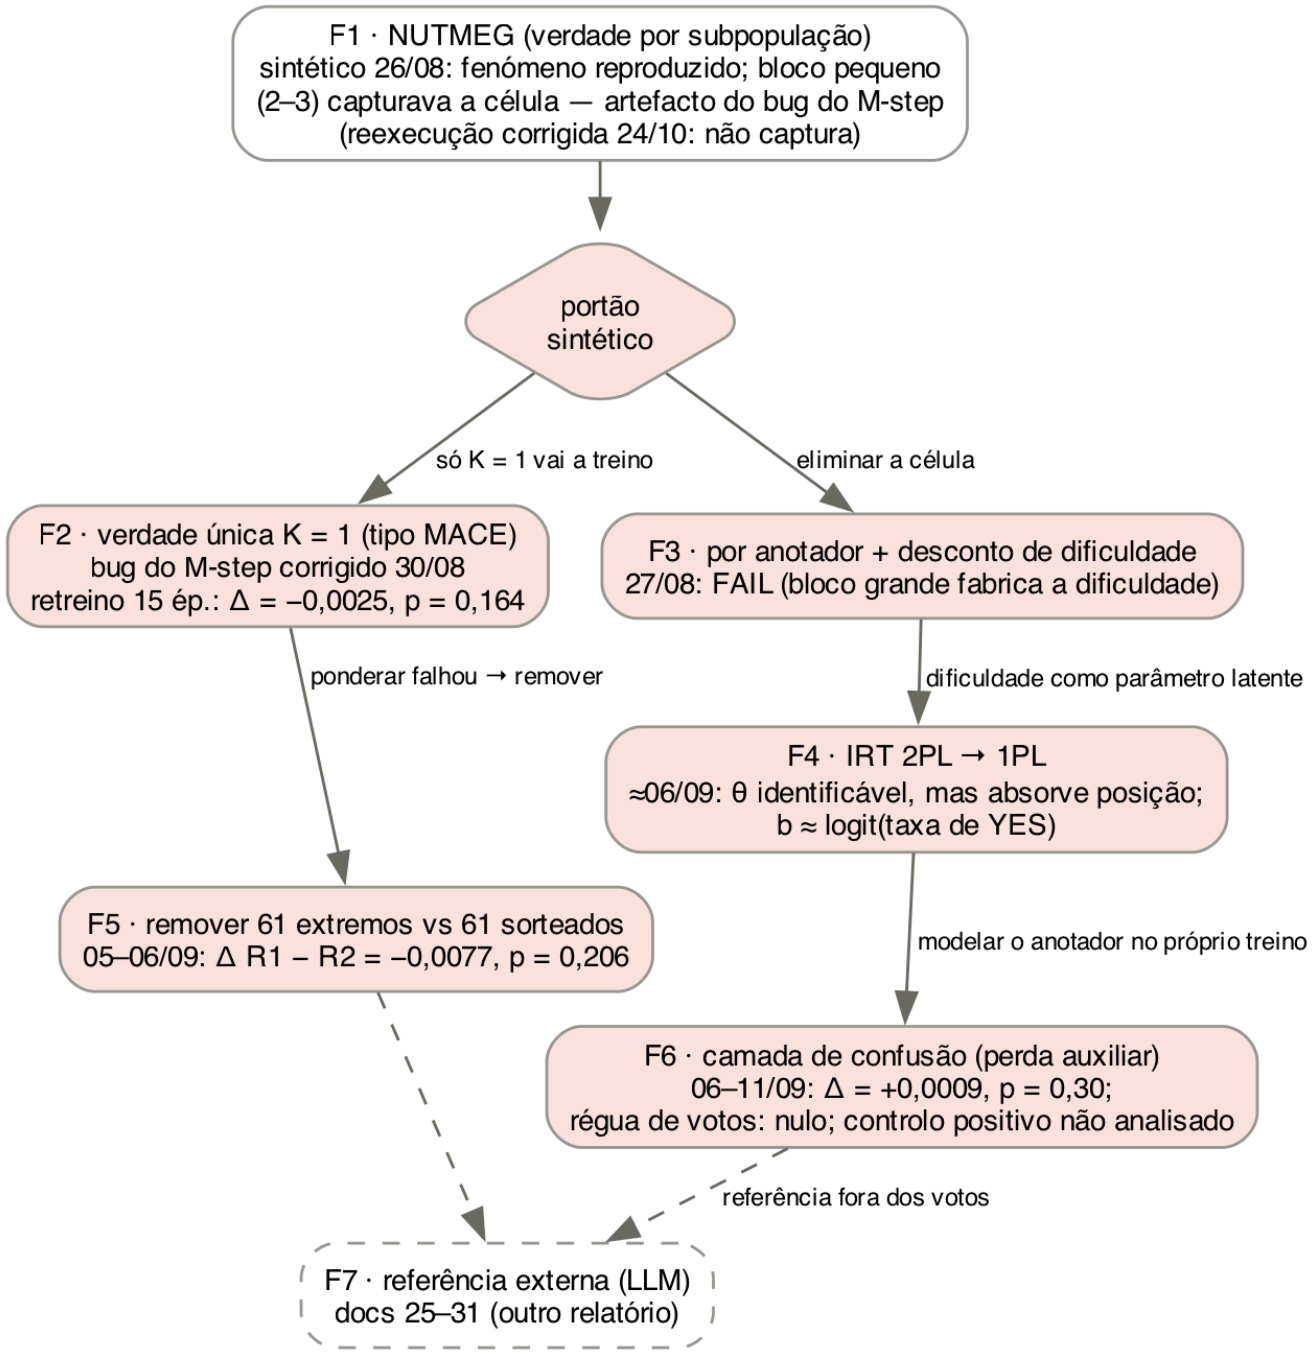


Figura M1 — Ordem em que as famílias foram testadas e porque cada uma levou à seguinte. Losangos = portões; vermelho = reprovado ou nulo.

1. Dados e estrutura de anotação

Todos os números desta secção foram recalculados a partir de `EXIST_MEMES/Dataset/memes/training/EXIST2026_training.json` (`verificacao/verify_part1.py`). **Atenção às populações**: várias grandezas parecidas referem-se a conjuntos diferentes, e a tabela diz sempre qual.

Grandeza	Valor	População
itens (memes)	3 984	treino oficial completo
votos da Task 2.1	23 904 (6 por item, sem excepção)	3 984 itens
anotadores distintos	887	3 984 itens
votos YES	13 286 (fracção **0,5558**)	23 904 votos
votos NO	10 618	23 904 votos
votos `UNKNOWN` na Task 2.1	0	—

Grandeza	Valor	População
itens com 0…6 votos YES	373 / 459 / 535 / 614 / 672 / 759 / 572	3 984 itens
itens unânimes	945 (572 YES + 373 NO)	3 984 itens
itens empatados (3 YES / 3 NO)	614	3 984 itens
itens com maioria estrita YES	2 003 (fracção 0,5028)	3 984 itens
votos por anotador	média 26,95 · mediana 27 · mín. 9 · máx. 54	887 anotadores
anotadores com menos de 15 votos	11	887 anotadores
α de Krippendorff (nominal)	**0,2791**	3 984 itens, todos os anotadores
estratos linguísticos	437 só ES · 431 só EN · 19 bilingues	887 anotadores
painel ES (para o IRT)	1 979 itens · 456 anotadores · 11 874 votos · 474 unânimes · YES 0,573	itens `lang = es`
painel EN (para o IRT)	2 005 itens · 450 anotadores · 12 030 votos · 471 unânimes · YES 0,539	itens `lang = en`
painéis fixos de 6 anotadores	151 (≈ 26,4 itens por painel)	3 984 itens
anotadores num único painel	868 de 887 (19 em dois painéis)	887 anotadores
composição de cada painel	exactamente 1 anotador em cada célula género × idade (F/M × 18-22/23-45/46+) nos 151 painéis	151 painéis

Notas que evitam confusões frequentes:

1. **456 + 450 = 906 > 887** porque os 19 anotadores bilingues entram nos dois painéis do IRT. Os estratos disjuntos usados nas permutações são 437 / 431 / 19.
2. **Taxa base.** 0,5558 é a fracção de YES nos 23 904 votos; 0,5552 é a mesma fracção **só nos itens de treino** do split congelado (é a taxa usada na régua de votos da F6, §10.6); 0,5581 é a média das `yes_rate` dos 887 anotadores (média de proporções, não proporção global).
3. **Unanimidade esperada.** Se os anotadores fossem intercambiáveis com $p = 0{,}5558$, a fracção de itens unânimes seria $p^6 + (1-p)^6 =$ **0,037**. A observada é 945/3 984 = **0,237** (24% em cada painel).
4. **Painéis fixos.** O EXIST não sorteia anotadores por item: cada item é visto por um dos 151 painéis fixos, e 868 anotadores vêem só os ∼27 itens do seu painel. Isto limita qualquer estimador que dependa de anotadores se cruzarem em itens: o grafo de co-anotação tem 132 componentes ligadas, a maior com 16 anotadores (`Untitled.ipynb`, passo 7).

1.1 Split congelado

`reliability/outputs/split_taskA_frozen.json`: **3 386 itens de treino / 598 de validação**, interseção vazia, `train_test_split` com `random_state = 42`, `test_size = 0,15`, estratificado pelo voto maioritário do alvo cru (`p_YES ≥ 0,5`), resolvido **uma vez** a partir do alvo cru (`make_soft_labels_taskA.py`). Todos os braços de todos os retreinos carregam este ficheiro. Razão: se o split fosse refeito a partir de cada alvo, 421 itens mudariam de estrato no braço ponderado e parte de qualquer Δ viria do split, não da intervenção (`soft_labels_taskA_report_fixed.md` §6). Distribuição de votos YES nos 3 386 itens de treino: 316 / 388 / 458 / 518 / 585 / 645 / 476. Os 598 itens de validação somam **3 588 votos** (usados como régua na F6, §10.6).

1.2 Alvo cru

`soft_labels_taskA_raw.json`: `{id_EXIST: [p_YES, p_NO]}` com `p_YES = n_YES / 6`. Verificado igual a `n_YES/6` em todos os 3 984 itens (máx. $|\Delta| = 0$). `soft_labels_taskA_raw_fixed.json` e `soft_labels_taskA_A0_baseline.json` são idênticos a este (o alvo cru não depende de θ).

Convenção de "cruzar 0,5". Em todos os scripts do projecto, um item "cruza 0,5" entre dois alvos a e b quando `(a ≥ 0,5) ≠ (b ≥ 0,5)`. Como 614 itens têm `p_YES = 0,5` exacto no alvo cru, **qualquer** movimento desses itens para baixo de 0,5 conta como cruzamento, embora eles não tenham maioria. O relatório (§13) separa os cruzamentos em "resolve um empate" e "inverte uma maioria".

---

2. Princípios de desenho comuns

Estes princípios foram aplicados em toda a linha e devem ser descritos uma vez no capítulo de método.

1. **Pré-registo em código.** Os limiares de PASS/FAIL dos portões sintéticos são constantes em `reliability/validate.py` (e células do notebook do IRT), escritas antes da execução que julgam. Quando um limiar se revelou mal calibrado depois de visto o resultado, **não foi alterado**: o resultado ficou como FAIL e a má calibração foi registada como erro de desenho (F3 §7.5, F4 §8.4, F6 §10.4).
2. "**Nunca correr nos dados reais um componente que não passou no teste sintético.**" É a razão de `run_perann_exist.py` não existir (F3) e de o NUTMEG com subpopulação nunca ter sido usado num retreino (F1).
3. **Nulos condicionados em vez de permutação ingénua.** Na divisividade, a permutação de anotadores altera a composição dos itens e produz z negativos por geometria; os vereditos usam o nulo condicionado *within-item* (§6). No θ, a permutação é estratificada por painel linguístico (§5.4).
4. **Intervenção só no alvo de treino da Task 2.1.** Em todos os retreinos, só muda `labels_task2_1_soft` dos itens de treino. A validação usa sempre o alvo cru (`raw`), as Tasks 2.2/2.3 não mudam, e o que se observa nelas é *spillover* do encoder partilhado, não efeito directo.

5. **Época reportada E = argmin(`eval_loss`).** Nunca a época de melhor métrica (seria escolher pelo resultado). O estado final (época 15) é reportado também, como secundário, pela **regra de simetria** (não misturar "pico de um lado, fim do outro").
6. **Comparações pareadas por seed** (42, 7, 2025), t de Student bilateral com df = 2, d_z de Cohen e número de seeds para 80% de poder (§12).
7. **Uma métrica decisiva por estudo** (Task A ICM-Soft-Norm na época E); as restantes 5 métricas × 2 pontos de leitura são contexto, e qualquer $p < 0{,}05$ avulso nelas é tratado como multiplicidade.
8. **Determinismo verificado.** Os estimadores CPU dão $\max|\Delta| = 0$ entre duas execuções com a mesma seed (NUTMEG, F3); o A0 re-corrido a 2026-09-06 reproduz o log de 2026-08-31 bit a bit (`CONFUSION_EXPERIMENT.md` §5).
9. **Desvios declarados com data.** Toda a alteração de protocolo depois do início está registada no documento do estudo, com a razão (exemplos: `CONFUSION_EXPERIMENT.md` §13, §5c, §5d).

---

3. O sistema de treino comum aos retreinos (F2, F5, F6)

- **Modelo**: o modelo de memes do sistema (XLM-RoBERTa large + CLIP ViT-L/14, fusão multimodal, três cabeças: A binária, B intenção, C multirrótulo), treinado sobre soft labels (`EXIST_MEMES/memes_core.py`, `memes_model.ipynb`). `memes_core.py` não foi alterado em nenhum destes estudos.
- **Selecção do alvo**: a célula 6 do `memes_model.ipynb` lê `../reliability/outputs/soft_labels_taskA_{ARM}.json`; mudar `ARM` é a única edição entre braços. A validação é sempre remapeada para `soft_labels_taskA_raw.json`.
- **Seeds**: `SEED ∈ {42, 7, 2025}`, que alimenta `seed` e `data_seed` do `TrainingArguments`; o split vem do ficheiro congelado e não depende da seed.
- **Épocas**: 15 nos estudos confirmatórios (F2 a 15 épocas, F5, F6). O estudo F2 a 2 épocas (§5.3) é anterior e foi declarado subtreinado.
- **Hiperparâmetros relevantes** (`CONFUSION_EXPERIMENT.md` §5c, §7, §5c-bis): `learning_rate` = 1e-5, weight decay 0,05, `task_a_weight` = 2,0, fp16, 795 passos de optimizador em 15 épocas.
- **Métricas**: ICM-Norm (hard) e ICM-Soft-Norm (soft) das Tasks A, B e C, via PyEvALL, sobre os 598 itens de validação. **Métrica decisiva: Task A ICM-Soft-Norm (`eval_task_a_icmsoftnorm_soft`) na época E.**
- **Logs**: um JSON por run em `EXIST_MEMES/metrics_history/<timestamp>_<RUN_TAG>_seed<S>.json`, com uma entrada por avaliação. A tabela de ficheiros usados em cada comparação está no relatório (§21).
- **Mínimo de `eval_loss`**: época 3 em todas as runs de 15 épocas, excepto `R2_rem_controle`/2025 e `conf_M1_lam0.1`/42 (época 4). A perda sobe depois: as épocas 4 a 15 são sobreajuste.

---

4. F1 — NUTMEG (`NutmegEM`, verdade por subpopulação)

4.1 Motivação

Um estimador de verdade única (MACE) define competência como concordância com a verdade que ele próprio infere; sob LeWiDi, isso converte discordância sistemática legítima em "incompetência". O NUTMEG (Ivey, Gauch e Jurgens, EMNLP 2025, `ivey2025nutmeg` no `refs.bib`) evita isso postulando uma verdade latente por **(item, subpopulação)**. A implementação do projecto é **própria** (EM com updates fechados), "no espírito do NUTMEG", e não o código dos autores; variational Bayes ficou documentado como extensão, não implementado (`nutmeg_em.py`, docstring). `[LIMITAÇÃO]` Antes de citar, conferir na fonte primária se o modelo do artigo coincide com o modelo abaixo.

4.2 Modelo

Para o anotador j, da subpopulação k = subpop[j], no item i:

```
T[i, k] ~ Uniforme({0, …, L−1})                        (L = 2 na Task 2.1)
voto_ij = T[i, k]                 com probabilidade θ_j   (não está a "spammar")
voto_ij ~ Multinomial(ξ_j)        com probabilidade 1 − θ_j
P(v | T = l) = θ_j · 1{v = l} + (1 − θ_j) · ξ_j[v]
```

θ é a probabilidade de **não spammar**, não a probabilidade de o voto coincidir com a verdade (é um modelo de spam ao estilo MACE, não Dawid-Skene simétrico). Com `subpop = zeros` (K = 1) a mesma classe é o baseline de verdade única (F2): sem segundo estimador, a comparação K = 1 contra K ≥ 2 é feita no mesmo código.

4.3 Estimação

- **E-step**: posterior de T[i, k] dados θ e ξ. Células (item, subpopulação) sem votos ficam no prior uniforme e não contribuem para a verosimilhança.
- **M-step**: responsabilidade de spam por voto → θ_j e ξ_j. Priors Beta(0,5; 0,5) em θ e Dirichlet(0,5) em ξ, logo o M-step é MAP (codificado como **média posterior** `(Σr + a)/(n + a + b)`, não o argmax `(Σr + a − 1)/(n + a + b − 2)`).
- **Inicialização** determinística: θ = 0,8 e ξ uniforme, o que faz o primeiro E-step colapsar no voto maioritário suavizado por célula; `n_restarts = 1`, nenhum RNG consumido.
- **Paragem**: $|\Delta LL| < 1e\text{-}6$ na log-verosimilhança. `n_iter` máximo era 200 até 2026-08-30 e passou a 5 000.

- **Clip**: θ ∈ [0,001; 0,999] (nunca atingido nos dados reais).

4.4 O bug da responsabilidade do M-step (corrigido a 2026-08-30)

Diagnóstico em três etapas, todas sem alterar o estimador até à última (`em_convergence_diagnosis.md`, `monotonicity_alignment_report.md`, `mstep_responsibility_diagnosis.md`):

1. **Não-convergência.** O θ K = 1 original tinha `converged = false` em 200 iterações. Com `n_iter = 5000` converge na iteração **462**, e o θ convergido difere do interrompido em média 0,0011 (r = 0,9991); a não-convergência era cosmética.
2. **Quebras de monotonicidade.** A log-posterior, que o EM MAP garante não-decrescente, caía **273** vezes (a partir da iteração 83). Priors, clip, EPS e *label switching* foram excluídos como causa; ler a série no fim da iteração em vez do início não muda nada (274 quebras).
3. **Causa.** Marginalizando T, a responsabilidade correcta de "não-spam" é `r = p_true · θ / (θ + (1−θ)·ξ[v])`. O código calculava `r = θ·p_true / (θ·p_true + (1−θ)·ξ[v])`, que só é correcto se `p_true` for o posterior *leave-one-out*. Alimentado com o posterior completo, **conta o voto do próprio anotador duas vezes** e enviesa θ para cima, de forma não uniforme. Com a responsabilidade corrigida: 0 quebras em 291 transições, convergência em **292** iterações.

Critérios pré-registados do diagnóstico (`mstep_responsibility_diagnosis.md` §2): C1 (corrigir não piora o RMSE sintético em mais de 0,005) **FAIL** — os dois estimadores enviesam θ para baixo e o legado cancela parte desse viés por acaso; a correlação com o θ verdadeiro é igual nas duas variantes. C2 (zero quebras com a responsabilidade corrigida, variante ML-argmax) **PASS**; C2b (o controlo com a responsabilidade do código quebra) **PASS** (90 quebras). C4 (o deslocamento das soft labels é material, > 0,0072) **MATERIAL** (0,0246). Decisão do autor: regenerar θ e soft labels com o estimador corrigido. **Os ficheiros legados não foram tocados**; os novos têm sufixo `_fixed`, e o estimador legado continua acessível por `NutmegEM(responsibility="legacy")`.

Os portões sintéticos do F1 (§4.6) foram corridos a 2026-08-26, com o estimador legado, e nunca tinham sido repetidos depois da correcção. Nesta revisão (2026-10-24) foram reexecutados com o mesmo código e os mesmos critérios de `validate.py`, mudando só a responsabilidade do M-step (`verificacao/verify_nutmeg_gates.py`): primeiro com `responsibility="legacy"` e `n_iter = 200`, que reproduz **bit a bit** os ficheiros de 2026-08-26 (máx. |Δr| = 0 nas 180 linhas das duas grades; minoria, spammer e sweep idênticos), depois com `responsibility="fixed"`. Um controlo 2 × 2 (responsabilidade × `n_iter` ∈ {200, 5 000}) mostra que o número de iterações não altera nada; a diferença vem só da responsabilidade (`verificacao/verify_sweep_2x2.py`). Resultado no relatório §5: **uma das conclusões do F1 não sobrevive à correcção** (a captura por bloco pequeno). Esta reexecução não estava pré-registada; está datada e separada dos resultados originais. Os portões do F3 e do F4 não são afectados (código diferente).

`[LIMITAÇÃO]` Se a tese escrever "MACE", deve dizer que o estimador é **do tipo MACE** (modelo de spam com priors), implementado de raiz, e não o MACE de Hovy et al. (2013) tal como publicado; a correspondência exacta do M-step com o artigo não foi verificada (`mstep_responsibility_diagnosis.md` §7).

4.5 Definições de subpopulação (dados reais)

`run_exist.py`, KMeans determinístico (`n_init = 10`, seed fixa), K ∈ {4, 8}:

- `demo_base`: etnia + escolaridade + país, one-hot de 66 dimensões.
- `demo_extended`: + género + idade, one-hot de 71 dimensões.
- `behavioral`: perfil de voto em 6 dimensões (`yes_rate`, desvio médio do consenso, |desvio| médio, concordância com a maioria, desvio em itens contestados, fracção de votos contestados), padronizado. **Circular**: os clusters saem dos mesmos votos que o EM usa.
- `single_truth_K1`: K = 1 (F2).

Demografia inconsistente entre itens foi resolvida pela moda (2 anotadores). Duas tentativas de definição comportamental foram rejeitadas por evidência: concordância par-a-par (com painéis fixos a sobreposição esperada é ∼0,15 itens por par) e `TruncatedSVD(32)` dos resíduos + KMeans, que deu clusters degenerados [883, 2, 1, 1] (K = 4) e [873, 2, 2, 2, 2, 2, 2, 3] (K = 8).

4.6 Validação sintética (`validate.py --all`, `--bias-spammer`)

Gerador `synthetic.generate_synthetic`: K = 2 subpopulações (minoria 25%), "divisividade" = fracção de itens em que as verdades das duas subpopulações diferem; θ ∼ Beta com média `1 − spam_rate` e concentração 8; 6 votos por item; seeds 42, 7, 2025.

Teste	Desenho	Critério pré-registado
Grade de recuperação	divisividade ∈ {0; 0,15; 0,30; 0,50; 0,70} × spam ∈ {0,15; 0,30; 0,45} × 3 seeds; densidade confortável (800 itens, 60 anotadores, 80 votos/anotador) e densidade do EXIST (3 984 itens, 887 anotadores, 26,9 votos/anotador)	descritivo: Pearson r($\hat{\theta}$, θ) por estimador
Preservação de minoria	minoria 25% com θ fixo 0,90, divisividade 0,70, spam médio 0,35 na maioria	$\hat{\theta}$ minoria ≥ 0,70; gap (maioria − minoria) ≤ 0,10; separação contra spammers ≥ 0,25
Spammer de viés constante	3 populações explícitas: fiáveis, 20% spam uniforme (θ = 0,25), 20% "vota sempre o mesmo rótulo" (θ = 0,25); divisividade 0,30; rótulo YES e rótulo NO; modos `subpop_aware`, `subpop_adversarial` (os enviesados recebem uma subpopulação só deles, um oráculo do que um clustering comportamental faria) e `single_truth`	c1 $\hat{\theta}$ enviesado ≤ 0,60; c2 $\hat{\theta}$ fiável − $\hat{\theta}$ enviesado ≥ 0,20; c3 |$\hat{\theta}$ enviesado − $\hat{\theta}$ uniforme| ≤ 0,15
Stress-sweep	modo `subpop_adversarial`, fracção de enviesados ∈ {0,03; 0,05; 0,10; 0,20; 0,35; 0,50}	diagnóstico secundário (não altera o veredito); comparado com o teto 0,60

4.7 Execução nos dados reais

`python -m reliability.run_exist` (CPU): θ para as 7 definições (6 com subpopulação + K = 1), com diagnósticos de cobertura de células, votos por célula, flags de degenerescência (`CÉLULAS_QUASE_SINGULARES` abaixo de 1,5 votos por célula) e ρ de Spearman contra duas métricas descritivas com viés de consenso conhecido (concordância com a maioria e Δα de Krippendorff *leave-one-out*). Estas métricas **não** são critério de correcção do θ: penalizam por construção a minoria que o método quer proteger; o árbitro é o teste sintético de preservação de minoria (`summary_taskA_fixed.md` §1).

---

5. F2 — Agregação de verdade única (tipo MACE) e soft labels ponderadas por θ

5.1 Estimador

`NutmegEM` com K = 1 sobre os 23 904 votos (§4.2–4.4). θ corrigido: `theta_taskA_single_truth_K1_fixed.json` (887 anotadores, convergido em 292 iterações, θ ∈ [0,0294; 0,9521], mediana 0,4861, média 0,4826). θ legado: `theta_taskA_single_truth_K1.json` (média 0,5352).

5.2 Construção do alvo (`make_soft_labels_taskA.py`)

```
p_YES_ponderado(i) = Σ_j θ_j · v_ij / Σ_j θ_j        (v_ij = 1 se YES; soma sobre os 6 anotadores do item)
```

Seguida **literalmente**, sem clip nem piso (decisão do autor): um anotador com θ < 0,5 é atenuado mas o voto dele nunca é invertido. Verificações obrigatórias (todas PASS): identidade do alvo cru, domínio [0, 1] sem NaN, Σ dos pesos normalizados = 1 por item (máx. desvio 2,2e-16), 0 anotadores sem θ, split a particionar os itens. Verificado nesta revisão que `soft_labels_taskA_weighted_fixed.json` é exactamente Σθv/Σθ com o θ **corrigido** (máx. |Δ| = 2,2e-16) e `soft_labels_taskA_weighted.json` o mesmo com o θ **legado** (3,3e-16). `[NOTA]` O §2 de `soft_labels_taskA_report_fixed.md` escreve o nome do ficheiro de θ sem o sufixo `_fixed`; os números desse relatório (0,0617; 421) são os do θ corrigido. É um erro de texto, não de dados.

5.3 Braços e protocolo

Estudo	Braços (RUN_TAG)	θ	Épocas	Critério
A0/A1 a 2 épocas (2026-08-30)	`raw` vs `weighted`	legado	2	efeito na primária > ruído de seed do baseline (amplitude entre seeds); t pareado como secundário
A0/A1 a 15 épocas (2026-08-30/31)	`raw` vs `weighted_fixed`	corrigido	15	t pareado bilateral sobre 3 seeds na primária em E

O estudo a 2 épocas foi declarado **subtreinado** depois de corrido: em todas as 6 runs a `eval_loss` ainda descia da época 1 para a 2 e a métrica primária ainda subia ∼+0,03 por época; o "2" do `memes_model.ipynb` era resquício dos smoke tests de 2026-08-04, e o sistema real treinava com 30 (`theta_arms_comparison.md` §5). **Os dois estudos não são medições do mesmo alvo** (θ legado vs corrigido) **nem com o mesmo critério**; o de 2 épocas fica como registo, não como referência.

5.4 Nulo por permutação de θ (gerado, nunca treinado)

`make_permuted_soft_labels.py`: θ corrigido permutado entre anotadores **dentro de três estratos disjuntos** (437 só ES, 431 só EN, 19 bilingues), seeds 101, 202, 303, 404, 505; o alvo é reconstruído com Σθv/Σθ. Razão da estratificação: permutar entre línguas destruiria estrutura que não é confiabilidade e daria um nulo fácil de bater. Critérios: P1 multiconjunto de θ idêntico por estrato; P2 sem fuga entre estratos; P3 fracção de pontos fixos < 0,05 (estratos com n ≥ 20); P4 estratos particionam os anotadores; P5 (descritivo) magnitude da perturbação contra a do A1 real. Os cinco ficheiros `soft_labels_taskA_permuted_seed*_fixed.json` existem e passam P1–P4, mas **nenhum retreino os usou**.

---

6. Divisividade empírica (diagnóstico, `divisiveness.py`)

Pergunta: as subpopulações explicam a discordância melhor do que uma partição ao acaso? Três indicadores por definição de subpopulação:

- **A.1 Item divisivo**: existe uma subpopulação com taxa de YES > 0,5 e outra < 0,5 no item (empates exactos não contam). Subconjunto "confiável": itens com ≥ 2 subpopulações com ≥ 2 votos cada.
- **A.2 Decomposição**: por item, `SS_total = Σ_j (v_ij − m_i)²`, `SS_between = Σ_k n_ik (m_ik − m_i)²`; rácio entre/total agregado sobre itens com ≥ 2 votos.
- **A.3 α de Krippendorff intra-subpopulação**, ponderado.

Dois nulos, 50 permutações cada: **Nulo A** (permuta anotadores entre clusters, mantendo tamanhos) e **Nulo B** (condicionado *within-item*: mantém partição e composição de cada item e permuta só os votos entre os anotadores do item). O Nulo A está confundido: altera o número de subpopulações distintas por item (2,77 observado contra 3,13 permutado em `demo_base_K4`), e menos células dão menos divisividade espúria. **Os vereditos usam o Nulo B**; o z-score é a grandeza que interessa.

7. F3 — Competência por anotador com desconto de dificuldade (`perann_reliability.py`)

7.1 Motivação

Eliminar a célula como unidade: agregar os ~27 votos de cada anotador (1–2 ordens de grandeza mais dados por parâmetro do que o F1). Para não colapsar em MACE ingénuo, descontar a discordância em itens genuinamente divididos.

7.2 Estimador (determinístico, não iterativo)

```
dificuldade(i) = H(p_i) / log 2          p_i = fracção de YES no pool do item i (votos crus)
peso(i)        = 1 − dificuldade(i)
competência(j) = Σ_i peso(i) · 1[voto_j(i) = maioria(i)]  /  Σ_i peso(i)
```

Votos em itens empatados (e pools LOO pares ou vazios) são excluídos do numerador e do denominador em todas as configurações, para que a linha de base sem desconto seja comparável.

7.3 Configurações comparadas

Nome	`discount`	`leave_one_out`	O que é
`mace_naive`	não	não	concordância com a maioria, mesmo caminho de código
`discount_raw`	sim	não	**literal da especificação**: o voto do próprio anotador entra na dificuldade
`discount_loo`	sim	sim	variante acrescentada (não estava na especificação): dificuldade e maioria vistas por j excluem o voto de j

Razão da variante LOO: na forma literal, um dissidente num item unânime de 6 votos dá $p = 1/6$, dificuldade 0,65 e peso 0,35 em vez de 1,0, ou seja, infla com o próprio voto a dificuldade do item que o vai julgar. Reportada ao lado, não em substituição.

7.4 Portão sintético (`validate.py --perann`)

Gerador `generate_difficulty_synthetic`: item **fácil** tem verdade única e o pool concorda; item **difícil** tem convicção Bernoulli(0,5) independente por anotador (ambiguidade genuína com anotadores competentes); voto = convicção com prob. θ, ruído com prob. $1 - \theta$. Seeds 42, 7, 2025.

Teste	Desenho	Critério pré-registado
2.1 Recuperação	`hard_frac` ∈ {0; 0,2; 0,4; 0,6} × densidade confortável (80 votos/anotador) e do EXIST (27,1)	r(hard = 0,4, confortável) ≥ 0,60 **e** vantagem sobre `mace_naive` ≥ 0,05 em todo `hard_frac` ≥ 0,4
2.2 Minoria, braços *matched*	mesma fracção (0,25), θ (0,95) e nº de itens de discordância (30%); braço `hard` (minoria discorda em itens ambíguos: deve ser protegida) e `easy` (discorda em itens de consenso: é ruído, deve ser punida)	hard: $\hat{\theta}$ minoria ≥ 0,70 e gap ≤ 0,10; easy: $\hat{\theta}$ minoria ≤ 0,60 e gap ≥ 0,20
2.3 Spammer de viés constante	20% sempre YES	$\hat{\theta}$ enviesado ≤ 0,60 e gap ≥ 0,20
Sweep de bloco (diagnóstico)	fracção do bloco ∈ {0,03; 0,08; 0,15; 0,25; 0,35}, braço easy e braço spammer	descritivo

7.5 Escala dos limiares (erro de desenho declarado)

Os limiares absolutos (teto 0,60, piso 0,70) foram herdados do F1, onde θ tem chão 0. A competência do F3 é uma taxa de concordância com chão de acaso ≈ 0,5: um spammer com θ real 0,25 tem concordância esperada $0{,}25 + 0{,}75 \times 0{,}5 = 0{,}625$, acima do teto **por construção**. Os limiares não foram alterados; o relatório separa este FAIL "de escala" do FAIL "de fundo" (comparação de gaps).

---

8. F4 — Teoria de Resposta ao Item (`dataset_verifications.ipynb`, células 2–13)

8.1 Motivação

Nos estimadores anteriores a dificuldade do item (quando existe) é uma estatística dos votos, logo capturável por um bloco. No IRT a dificuldade b_i é um **parâmetro latente** estimado em conjunto com a competência θ_j, o que remove a circularidade competência → dificuldade por construção.

8.2 Modelo e estimação

```
2PL:  P(voto_ij = YES) = σ( a_i · (θ_j − b_i) )        1PL (Rasch): a_i = 1
```

Máxima verosimilhança marginal por EM (MML-EM) com quadratura de Gauss-Hermite de 21 pontos (`hermegauss`, pesos normalizados), $\theta_j \sim N(0, 1)$ como distribuição de integração; competência final por EAP (`θ̂ = post @ nós`). M-step por item com L-BFGS-B, limites a $a \in [0{,}05; 5]$, $b \in [-10; 10]$; no 2PL, prior log-normal em a com $\sigma = 0{,}5$. Paragem $|\Delta LL| < 1e\text{-}5$, até 200 iterações. A monotonicidade da log-verosimilhança marginal é verificada em cada iteração como teste de implementação. Estimação conjunta (JML) foi evitada porque enviesa os parâmetros de item com poucas respostas por pessoa.

8.3 Ordem dos testes

1. **Sondagem de implementação** (densidade confortável: 1 000 itens, 200 anotadores, 50 votos/item, seed 42), critério $r \geq 0{,}80$ nos três parâmetros. Só serviu para verificar o código; **não** podia informar os limiares da densidade real. Três diagnósticos para o FAIL em a: exclusão de itens no limite do optimizador, alinhamento linear da escala, e varrimento da dispersão verdadeira de a ($\sigma \in \{0{,}3; 0{,}6; 1{,}0\}$).
2. **Recuperação na densidade do EXIST** (1 000 itens, 220 anotadores, 6 votos/item → mediana 27 votos/anotador; seeds 42, 7, 2025), critério pré-registado: $\theta \geq 0{,}60$, $b \geq 0{,}50$, $a \geq 0{,}40$. Segundo o `cap07.tex`, o limiar de θ (0,60) foi escolhido para igualar a recuperação "do estimador de ponderação de votos" na mesma densidade; o valor medido que lhe corresponde é o do NUTMEG com subpopulação na densidade do EXIST ($r = 0{,}599$, §4.6), não o do $K = 1$ (0,473). `[AMBIGUIDADE]` Rever a expressão "vote weighting estimator" no `cap07.tex`: o estimador que pondera votos no retreino é o $K = 1$.
3. **Decisão pré-registada 2PL → 1PL**: se a falhar, adoptar o 1PL, desde que θ e b não piorem mais de 0,01.
4. **Bloco correlacionado** (critério fixado antes do gerador): $k \in \{5, 20, 60, 120\}$ de 220 anotadores (2,3%, 9,1%, 27,3%, 54,5%) com a **mesma** distribuição de competência mas dificuldade deslocada por $\delta \in \{0; 1; 2\}$ em todos os itens (diferença consistente de limiar, não incompetência); 1PL; 3 seeds. Métrica: gap = θ médio do bloco − θ médio da maioria (valor esperado 0 num estimador que não confunda posição com capacidade). Critério: controlo ($\delta = 0$) com $\max|gap| < 0{,}10$, senão "bug"; tratamento: $\max|gap| < 0{,}20$ RESISTE, $\geq 0{,}50$ CAPTURA, entre os dois PARCIAL.
5. **Seguimento do controlo k = 5** (30 seeds, 1000–1029), depois de o controlo falhar: IC 95% do gap.
6. **Ajuste aos dados reais**: 1PL separado por painel linguístico (ES e EN), porque os painéis são quase disjuntos e, sem itens comuns, não há base para pôr as duas escalas na mesma métrica. Itens unânimes retidos na estimação (informam a competência de quem os viu), excluídos da análise de b.

8.4 Notas de estatuto

- O controlo do bloco **falhou** em $k = 5$ pelo critério pré-registado ($|gap| = 0{,}449$); a reclassificação dessa célula como "sem poder" (o critério foi fixado sem calcular o erro-padrão esperado por tamanho de bloco) é **pós-hoc** e está declarada como tal no `cap07.tex`. O critério não foi alterado; a célula foi excluída.
- O limiar da sondagem para a (0,80) estava alto demais; registado como erro de desenho, não como propriedade dos dados.
- A Task 2.2 foi avaliada só quanto a viabilidade: mediana de 15 votos por anotador na B contra 27 na A, 65,7% dos anotadores com menos de 2 observações por parâmetro num modelo de 9 parâmetros (`dataset_verifications.ipynb` célula 14). Não foi ajustado nenhum modelo na B.

---

9. F5 — Ablação de anotadores extremos (`reliability_tests.ipynb`, células 2–15)

9.1 Definição dos extremos

`yes_rate_j = n_YES_j / n_votos_j` sobre os 23 904 votos. Extremo: `yes_rate > 0,90` (lado alto) ou `< 0,10` (lado baixo). Resultado: **61 anotadores**, 40 altos e 21 baixos; por língua, EN 19 altos + 16 baixos, ES 21 altos + 5 baixos, nenhum bilingue; votos por anotador dos extremos: mediana 27, mín. 12. Plausibilidade: com $p = 0{,}5558$ e os n de cada anotador, uma simulação binomial (seed 42) dá sd de `yes_rate` 0,0971 contra 0,2132 observado, e **0 anotadores esperados** acima de 0,90 ou abaixo de 0,10 contra 40 e 21 observados (célula 3). Os extremos são desviantes **face aos itens que viram** (desvio médio contra os outros 5 do item: altos +0,32 a +0,36; baixos −0,41 a −0,46; célula 6), não um artefacto do painel.

9.2 Braços

Braço	RUN_TAG	Alvo de treino da Task A
A0	`raw`	os 6 votos de cada item (reutiliza as runs A0 do F2)
R1	`R1_rem_extremos`	média dos votos **sem** os 61 extremos
R2	`R2_rem_controle`	média dos votos sem **61 anotadores sorteados** entre os não extremos

Sorteio do controlo (`sortear_controle(42)`): para cada estrato (língua, `n_votos`) dos extremos, sorteiam-se tantos não extremos do mesmo estrato quantos os extremos nele, sem reposição (`default_rng(42)`); se o estrato exacto não chega, relaxa-se para `n_votos ± 3` mantendo a língua. Resultado: 61 anotadores, 35 EN e 26 ES (igual aos extremos), `yes_rate` média 0,559 (mín. 0,148, máx. 0,833). Os dois braços removem exactamente o mesmo número de votos (**1 597**). Os anotadores removidos saem **só** do alvo da Task A; continuam a contar em B e C.

Também foram construídos, e **nunca treinados**, dois braços de substituição: S1 (voto dos 61 extremos trocado pela maioria dos outros 5 do item) e S2 (o mesmo para o controlo); mantêm 6 votos por item e a grade de 7 valores (célula 9).

Verificado nesta revisão: recalcular R1 e R2 a partir do dataset com o código do notebook reproduz os ficheiros `soft_labels_taskA_R1_rem_extremos.json` e `soft_labels_taskA_R2_rem_controle.json` **exactamente** (máx. $|\Delta| = 0$), o que confirma que o sorteio do controlo é o de `default_rng(42)`.

9.3 Critério (fixado a 2026-09-06, antes de qualquer métrica de R1/R2 ser lida)

Decisivo: R1 − R2, Task A ICM-Soft-Norm, época E. R1 − A0 e R2 − A0 são contexto: misturam o critério de remoção com a perda de densidade (e com a fragmentação da grade do alvo, que passa de 7 para 13 valores distintos). Em R1 − R2 a remoção de votos está nos dois lados e cancela no pareamento. As verificações feitas antes de 2026-09-06 foram só de integridade das runs e do deslocamento do alvo, nenhuma métrica ICM (`experiment_taskA_ablation_report.md` §0). Cada braço é lido no seu próprio E (forçar a mesma época nos dois lados seria escolher a época por conveniência).

---

10. F6 — Camada de confusão como perda auxiliar (`CONFUSION_EXPERIMENT.md`)

10.1 Intervenção

```
L = L_soft(A, B, C) + λ · L_aux(A)
p_latente(i) = [P(YES), P(NO)] = [1 − σ(logit_a), σ(logit_a)]      (convenção do baseline: σ(head_a) = P(NO))
C_a[i, j] = P(voto = j | latente = i)    linhas normalizadas por softmax
p_voto(a, i) = p_latente(i) @ C_a
L_aux = CE(p_voto(a, i), voto observado), MÉDIA sobre os pares (anotador, item) com voto no batch
```

Duas correcções ao *handoff* original, declaradas: `C_a @ p` com linhas normalizadas não devolve uma distribuição (usa-se `p @ C`), e usa-se a média em vez da soma para λ ficar na escala da `L_soft`. A auxiliar entra **só no treino**: a validação nunca recebe votos, `eval_loss` continua a ser a `L_soft` pura, e E = argmin(`eval_loss`) é o mesmo selector nos dois lados.

10.2 Métodos (pesos de regularização fixados a priori, um valor cada, sem grelha)

id	Referência (a verificar na fonte primária)	`C_a`	Regularização
M1	Chu et al., AAAI 2021, **adaptado** (decomposição comum + individual; não é o CoNAL com portão dependente da instância)	`row_softmax(L_comum + Δ_a)`, `L_comum` com init 3·I	L2 em Δ_a, peso 0,01
M2	Tanno et al., CVPR 2019	individual completa	traço, peso 0,01
M3	Rodrigues e Pereira, AAAI 2018 (*crowd layer*)	individual completa	nenhuma

A regularização é multiplicada por λ: com $\lambda = 0$ o mecanismo inteiro está desligado. Os parâmetros de confusão estão fora do weight decay. Todos os *lookups* são comparação + matmul (determinísticos em CUDA); a auxiliar corre com autocast desligado. O split é por item, não por anotador: os anotadores de treino aparecem na validação, o que **favorece** o método (limitação declarada).

10.3 Fase 1 — ordem de execução pré-registada

1. **Controlo** M1, $\lambda = 0$, seed 42 (obrigatório antes de tudo).
2. **Grelha** M1 × $\lambda \in \{0{,}1; 0{,}3; 1{,}0\}$ × seeds {42, 7, 2025} (9 runs).
3. Δ_null: $\lambda = 0$ nas seeds 7 e 2025 (recomendado).
4. **Paragem antecipada**: se o M1 falhar em todos os λ, não correr M2 nem M3.
5. **Critério do resultado** (§6 do protocolo, "não alterar"): por método, Δ = método − A0 no melhor λ (escolha pós-hoc, declarada), t pareado bilateral; PASS da família se algum método tiver $\Delta > 0$ e $p < 0{,}0167$ (Bonferroni, 3 métodos).

Critério do controlo (recalibrado a 2026-09-07, depois de ver o controlo, declarado): matrizes congeladas, A0 reproduzível, |Δ primária em E| < 1 sd do A0 entre seeds e Δ `eval_loss` em E dentro da amplitude entre seeds. A versão inicial exigia reprodução bit a bit da `eval_loss` nas 15 épocas (máx. $|\Delta| < 1e\text{-}3$); foi retirada porque, num sistema caótico, uma perturbação de 1 ulp no passo 1 amplifica para escala macro e esse máximo não distingue 1 ulp de um bug. O mecanismo da perturbação foi isolado num teste de 2 passos: a `loss` do passo 1 é bit a bit igual; a divergência nasce no `grad_norm` devolvido por `clip_grad_norm_` (diferença relativa 6,08e-8), porque dois tensores extra com gradiente zero mudam a árvore de redução.

10.4 Achados de desenho da Fase 1 (que mudam a leitura da grelha)

- **Com o LR do encoder (1e-5) as matrizes não se movem**: 795 passos de AdamW dão no máximo ~8e-3 em logit, $\Delta p \approx 3{,}6e\text{-}4$ no ponto de init; medido 6e-4. E **λ não corrige isto**: o AdamW é invariante à escala do gradiente e a auxiliar é a única fonte de gradiente das matrizes.
- **Com C ≈ I a auxiliar é a própria BCE da Task A** (somar a CE dos 6 votos de um item = CE contra a frequência dos votos). Confirmado no log: `loss` do passo 50 com $\lambda = 0{,}1$ excede a do A0 em $0{,}0767 = 0{,}1 \times 0{,}767$. Logo a grelha pré-registada mede **uma ablação do peso da Task A** (2,0 → 2,1 / 2,3 / 3,0), não modelação do anotador.
- **Braço exploratório `CONF_LR = 1e-2`** (pós-hoc, fora da estatística confirmatória): as matrizes num grupo de parâmetros próprio com lr 1e-2, valor escolhido como "expressividade máxima" (para $\Delta p \approx 0{,}2$ é preciso $\Delta\text{logit} \approx 4{,}4$ em 795 passos), sem grelha.

- **Disco cheio (2026-09-07)**: a partir daí `save_strategy = "no"` e sem modelo final em disco; neutro para a análise porque E é escolhido dos logs por época. Uma escrita truncou o notebook e o protocolo, reconstruídos no mesmo dia; nenhum log se perdeu. Por isso a seed 42 do braço `clr` tem três ficheiros: `20260907_171842` (1 avaliação, interrompida), `20260907_223901` (14 avaliações) e `20260907_234357` (15 avaliações, a usada; idêntica à anterior na época E).

10.5 Fase 2 — porque existiu

Três factos da Fase 1, nas 3 seeds do braço `clr`: as matrizes colapsam no viés marginal (88,7% da variância; `viés = 0,827 · yes_rate − 0,420`, $R^2 \approx 0{,}91$); não movem o ICM; e o sd do A0 entre seeds (0,0059) é 6× o efeito. O ICM compara dois *treinos* e tem o ruído de seed por baixo; faltava uma régua que comparasse *preditores dentro do mesmo treino* e um **controlo positivo**.

10.6 Fase 2 — desenho

Régua: os 3 588 votos individuais dos 598 itens de validação (nunca entraram em `L_soft` nem `L_aux`; pergunta "anotador conhecido, item novo"). Reter votos de itens de treino teria fuga (o alvo de treino é a média dos 6 votos). Implementada como *callback* em `on_evaluate` com loaders próprios; não entra na perda e não é `eval_dataset`.

Preditor	O que usa
`a`	só a probabilidade do item (matriz = identidade)
`b`	a ficha aprendida: probabilidade do item ajustada por C_a
`b_perm`	a ficha de outra pessoa do mesmo estrato linguístico (437/431/19)
`c`	só o histórico: `yes_rate_a` de treino, constante
`d3`	logística em x1, x2, x3
`d4`	logística em x1, x2, x3, x4 — **é quem decide**

`x1 = −logits_a` (logit P(YES) do item); `x2 = logit(yes_rate suavizada)`; `x3 = logit(concordância suavizada com a maioria leave-one-out)`; `x4 = |logit(yes_rate) − logit(taxa base do painel)|`. `yes_rate` recalculada só do treino com Laplace (n_YES + 1)/(n + 2). `d3` / `d4` ajustadas num subconjunto fixo de 600 itens de treino (`default_rng(0)`, "critério") e na própria validação ("oráculo", barra superior).

Armadilha medida (T12): `b` bate `a` já no init (NLL 0,7997 contra 0,8250), por encolhimento da previsão para 0,5 (calibração global, `softmax([3,0])` dá diagonal 0,9526). Por isso `b − a` é só descritivo; o contraste limpo do sinal *individual* é `b − b_perm` (mesma calibração, só muda quem recebe que ficha), e o critério é `b − d4_train`.

Reparametrização `sd` (2 parâmetros por anotador em vez de 4 redundantes): `u_a = s_c + d_c + s_a`, `v_a = s_c − d_c + s_a`; competência = $2\sigma(s_c + s_a) - 1$; no modo congelado, $d_a \equiv 0$ e o invariante é `u_a − v_a = 2·d_c` em espaço de logit. No init as duas parametrizações são numericamente idênticas (T9), mas as runs da Fase 1 não são comparáveis bit a bit com as novas.

Controlo positivo (run B): 120 anotadores (20 por nível) com 0/10/20/30/40/50% dos votos invertidos, seleccionados estratificados por estrato linguístico e por nº de votos, ordem dos níveis sorteada dentro de cada bloco; 828 votos invertidos (3,46%). A run B reconstrói alvo de treino **e** gold de validação a partir da tabela corrompida; **o ICM da run B não se compara com nada**. Manifesto: `corruption_manifest_conf_M1sdcrp_lam0.1_clr0.01_seed2025.json`.

Critério (fixado antes da run A): sensibilidade (run B, Porta 1): competência dos corrompidos a cair monotonicamente com o nível, e o nível ≥ 40% a separar do nível 0%. Sinal (runs C/D/E, viés congelado): extrai sinal se e só se `NLL(b) < NLL(d4_train)`. Vereditos pré-declarados que **não** são passagem: `b > d3` mas `b < d4` ("a matriz aprendeu o U na taxa base"); `b > d_train` mas `b < d_val` (má calibração do ajuste); `b ≈ b_perm` (a vantagem não vem de conhecer a pessoa). Se a run B falhar, nenhum nulo de C/D/E é interpretável.

Plano escalonado (§17): A (viés livre + régua) → B (controlo positivo, Porta 1) → C (congelado, Porta 2) → D, E. Fixos: M1, λ = 0,1, `CONF_LR` = 1e-2, 15 épocas. **Desvio 13:** a run A correu com a seed **2025** (a que estava no notebook), não 42; os braços a comparar passam a partilhar a seed 2025.

Testes que bloqueiam a execução: `EXIST_MEMES/confusion_selftest.py`, 41 verificações em CPU (T1–T14), mais uma guarda de RNG activa em todas as runs (aborta se o *callback* deslocar o gerador).

---

11. Apêndice metodológico — análises descritivas dos anotadores

Não são estimadores de confiabilidade; descrevem a estrutura dos dados que condiciona todos eles.

11.1 Análise de painéis e limiar pessoal (`EXIST_MEMES/Untitled.ipynb`, 2026-09-14)

- **Resíduo por voto**: `resid_ij = v_ij − média dos outros 5 do item` (o item fica controlado); por anotador, `resid_j` = média dos seus resíduos.
- **Nulo de amostragem**: 200 permutações do rótulo de anotador entre votos (`default_rng(42)`); variância de amostragem = sd^2 médio sob o nulo.

- **Decomposição**: variância observada de `resid_j` = amostragem + real entre pessoas; parte real explicada pelos 6 grupos género × idade.
- **Estabilidade split-half**: 25 partições aleatórias dos votos de cada anotador em duas metades (anotadores com ≥ 12 votos), correlação entre metades e correcção de Spearman-Brown `2r/(1 + r)`; nulo por permutação.
- **Viés de painel sem circularidade**: limiar *leave-one-out* de cada anotador, média por item, encolhido pela confiabilidade (0,850).
- **Estrutura de painéis**: painéis distintos, componentes do grafo de co-anotação, composição demográfica, efeito de célula com IC por reamostragem de painéis.
- **Pré-verificação com embeddings** (células 9–11, XLM-R + CLIP congelados, Ridge/boosting com `GroupKFold` por painel): o painel explica resíduo do rótulo fora da amostra? Descrita no relatório só como contexto.

11.2 Perfil e diagnóstico comportamental (`behavioral_profile.py`, `run_behavioral_diagnosis.py`, 2026-08-27/28)

12 features por anotador calculadas sem consenso nem verdade inferida (`yes_rate`, taxas de `UNKNOWN` nas Tasks B e C, nº de categorias distintas, entropia de categorias, rótulos por item, três incoerências hierárquicas, `yes_rate` por língua, `lang_gap`). Critérios pré-registados: feature *dispersa* se ≥ 10 valores distintos, nenhum bin com > 60% e IQR ≥ 10% da amplitude; clustering útil se nenhum cluster < 5% e silhouette > 0,25; KMeans seed 42, K = 2…6, política *complete-case*.

11.3 Dimensão latente (`validate_latent_dimension.py`, 2026-08-29)

Teste, ao nível individual (n = 844), da afirmação de que 4 features formam uma dimensão "expansivo ↔ parcimonioso". Spearman primário; PCA com régua pré-registada (PC1 > 55% e loadings do mesmo sinal = dimensão única; 35–55% estrutura parcial; < 35% nenhuma); controlo do denominador `n_sexist_items` por correlação parcial e por estratificação na banda 12–18.

---

12. Definições estatísticas

- **Δ pareado**: Δ_s = métrica(braço) − métrica(referência) na mesma seed s, cada braço lido no seu próprio E.
- **t pareado**: t = média(Δ) / (sd(Δ)/√n), sd com ddof = 1, n = 3, df = 2; **p bilateral** da t de Student (os analisadores integram a densidade numericamente; recalculado nesta revisão com `scipy.stats.t.sf`, mesmas 3 casas).
- **d_z** = média(Δ)/sd(Δ). **Seeds para 80% de poder** ≈ ⌈(2,802/|d_z|)²⌉ (aproximação normal, α = 0,05 bilateral); ordem de grandeza, não estimativa.
- **sd do A0 entre seeds**: sd (ddof = 1) da primária do A0 em E nas 3 seeds = **0,0059**. "**Spread**" **no estudo a 2 épocas**: amplitude (máx − mín) da primária do baseline entre seeds (0,0107), não um sd (o sd seria 0,0054).
- **Pearson r de recuperação**: entre θ̂ e θ verdadeiro no sintético, média sobre seeds.
- **Krippendorff α nominal** binário, com coincidências por item (6 votos).
- **Wilson, κ, McNemar**: não usados nesta linha (são da linha GLM/Claude).

---

13. Artefactos e reprodução

O quê	Onde
Estimadores e validação	`reliability/nutmeg_em.py`, `synthetic.py`, `validate.py`, `perann_reliability.py`, `divisiveness.py`, `run_exist.py`, `exist_data.py`
Diagnósticos do EM	`diagnose_em_convergence.py`, `diagnose_monotonicity_alignment.py`, `diagnose_mstep_responsibility.py`, `compare_theta_legacy_vs_fixed.py`
Alvos	`make_soft_labels_taskA.py`, `make_permuted_soft_labels.py`; ablação em `EXIST_MEMES/reliability_tests.ipynb`
Análises dos retreinos	`analyze_theta_arms.py` (2 ép.), `analyze_arm_experiment.py` (15 ép.), `analyze_ablation_experiment.py`, `analyze_confusion_experiment.py`, `analyze_votes_experiment.py`, `check_control_trajectory.py`
Camada de confusão	`EXIST_MEMES/confusion_core.py`, `confusion_selftest.py`, `memes_confusion.ipynb`, `memes_confusion_step2.ipynb`, `memes_model_step2.ipynb`
IRT	`EXIST_MEMES/dataset_verifications.ipynb`; figuras `EXIST_MEMES/irt_*.pdf` (no `images/` da tese: `irt_b_vs_yesrate.png`, `block-size-competence.png`)
Painéis	`EXIST_MEMES/Untitled.ipynb` (citado noutros documentos como `panel_analysis.ipynb`)
Verificação desta revisão	`reliability/relatorio/verificacao/verify_part1.py` (dados, alvos, θ, runs), `verify_part2.py` (sintéticos, ablação, Fase 2), `verify_confusion_matrices.py`, `verify_ablation_panels.py`, `verify_irt.py`, `verify_panel.py` (reexecução dos notebooks), `verify_nutmeg_gates.py`, `verify_sweep_2x2.py`, `verify_gates_compare.py` (portões do F1 com os dois estimadores), com os logs `.log` ao lado
Figuras	`reliability/relatorio/plot_relatorio.py` → `reliability/relatorio/figs/`
PDF	`reliability/relatorio/relatorio_pdf.py` → `reliability/outputs/relatorio_reliability.pdf`

Reexecuções desta revisão: `verificacao/gates_legacy/` e `verificacao/gates_fixed/` (grades, minoria, spammer de viés e sweep do F1, por estimador); `verificacao/sweep_2x2.json`. A reexecução do notebook do IRT reproduz todos os números pré-registados com 4 casas; só a sondagem converge em 118 iterações com 10 quebras de monotonicidade, contra 102 e 3 no notebook (diferença de ambiente numpy/scipy; a recuperação é idêntica).

Artefacto órfão: `reliability/outputs/loo_sensitivity.json` (2026-08-29; viés naive/LOO/oráculo por votos por item, seeds 42, 7, 2025, 101, 777). Nenhum script do repositório o produz nem o lê; não é usado neste relatório.

Comandos (da raiz do repositório):

```
python3 -m reliability.validate --all           # F1 sintético
python3 -m reliability.validate --bias-spammer  # F1 spammer de viés
python3 -m reliability.validate --perann        # F3
python3 -m reliability.divisiveness
python3 -m reliability.run_exist                # θ nos dados reais
python3 -m reliability.analyze_arm_experiment   # F2, 15 épocas
python3 -m reliability.analyze_ablation_experiment
python3 -m reliability.analyze_confusion_experiment
python3 -m reliability.analyze_votes_experiment  # ATENÇÃO: sobrescreve experiment_votes_report.* (hoje só com a run A)
python3 reliability/relatorio/verificacao/verify_part1.py .      # e verify_part2.py, verify_confusion_matrices.py,
verify_ablation_panels.py
python3 reliability/relatorio/verificacao/verify_irt.py EXIST_MEMES/Dataset/memes/training/EXIST2026_training.json   #
idem verify_panel.py
python3 reliability/relatorio/verificacao/verify_nutmeg_gates.py . /tmp/gates_fixed fixed   # ou legacy
python3 reliability/relatorio/plot_relatorio.py .
python3 reliability/relatorio/relatorio_pdf.py ""   # depois o Chrome headless (docstring do script)
```

Relatório de resultados — estimadores de confiabilidade de anotadores (Task 2.1, memes)

O que é este documento. Os resultados numéricos de todas as famílias de estimadores de confiabilidade testadas na linha `reliability/` (2026-08-26 a 2026-09-14), com os números verificados de forma independente nesta revisão (2026-10-24). O *como* de cada passo está em `METODOLOGIA_RELIABILITY.md`; as referências "M§x" apontam para lá. A linha do anotador LLM (docs 25 a 31) tem relatório próprio (`EXIST_MEMES/glm_annotator/RELATORIO_GLM_CLAUDE.md`).

Convenções. `[MEDIDO]`, `[HIPÓTESE]`, `[LIMITAÇÃO]`, `[PÓS-HOC]` como em M§0.1. **Decisivo** = a única comparação que o pré-registo do estudo declara como teste; tudo o resto é contexto. Números com 3 ou 4 casas, como nos artefactos. Datas absolutas.

---

0. Sumário

0.1 O que foi testado e o que deu

Família	O que se mediu	Número decisivo	Veredito
F1 · NUTMEG (verdade por subpopulação)	recuperação de θ no sintético e robustez a blocos	densidade do EXIST: r = 0,599 (legado) / **0,638** (corrigido) contra 0,473 / 0,485 do K = 1	fenómeno reproduzido; **nunca foi a retreino** (fragmentação: 1,2 a 2,3 votos por célula nos dados reais)
F1 · captura por bloco pequeno	θ̂ de 2–3 spammers com subpopulação própria	legado: θ̂ = 0,733 (teto 0,60) · **corrigido: θ̂ = 0,147**	**a captura era artefacto do bug do M-step** (§5)
F2 · verdade única K = 1 (tipo MACE) → soft labels ponderadas	Δ ICM-Soft-Norm (A) em E, A1 − A0, 15 épocas, 3 seeds	**Δ = −0,0025**, sd 0,0020, t(2) = −2,16, **p = 0,164**, d_z = −1,25	**NULO**
F3 · por anotador com desconto de dificuldade	portão sintético, 3 testes	vantagem mínima sobre o MACE ingénuo = −0,003 (exigido ≥ 0,05)	**FAIL** nas duas variantes; nunca foi a dados reais
F4 · IRT 2PL → 1PL	recuperação, robustez a bloco, ajuste real	θ recupera a r = 0,877; bloco com a mesma competência recebe gap de −0,85 a −1,79; b vs logit(taxa de YES): r = −0,996 / −0,993	identificável, **inutilizável** para ponderar (absorve posição em θ; b repete a contagem)
F5 · remover 61 extremos contra 61 sorteados	Δ ICM-Soft-Norm (A) em E, R1 − R2	**Δ = −0,0077**, sd 0,0072, t(2) = −1,84, **p = 0,206**, d_z = −1,06	**NULO**
F6 · camada de confusão (Fase 1)	Δ contra A0, braço exploratório `clr = 1e−2`	Δ = +0,0009, sd 0,0011, t(2) = 1,38, p = 0,30	grelha pré-registada incompleta; exploratório **nulo**
F6 · camada de confusão (Fase 2, run A)	NLL nos 3 588 votos retidos: `b − d4_train` em E	**+0,0147** (positivo = a ficha perde)	**NULO**; controlo positivo (run B) **treinado e não analisado**

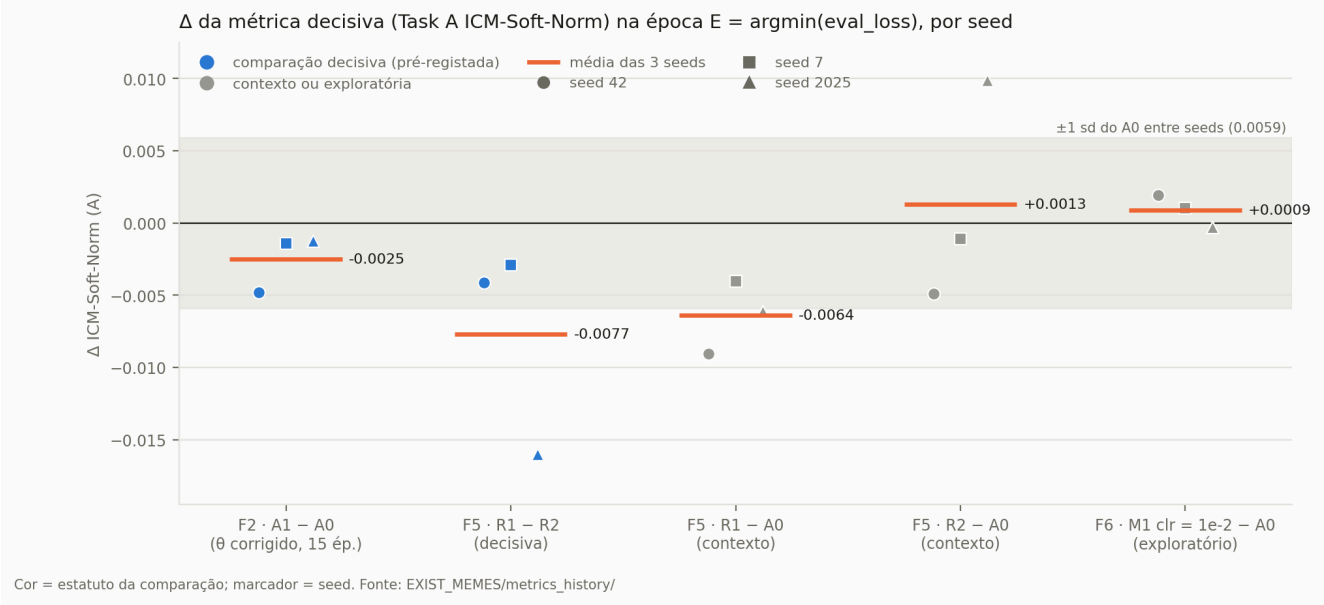


Figura R1 — Δ da métrica decisiva em E por seed (marcador = seed; azul = comparação decisiva pré-registada, cinzento = contexto ou exploratória; traço laranja = média). A faixa cinzenta é ±1 sd do A0 entre seeds (0,0059): nenhuma média sai dela, excepto R1 − R2 (−0,0077) e R1 − A0 (−0,0064), ambas negativas.

0.2 Cinco achados para a tese

1. **Ponderar e remover não rendem.** As duas formas canónicas de usar uma estimativa de confiabilidade para construir o alvo (F2 e F5) dão nulo no regime real de treino (15 épocas, 3 seeds, E = argmin(eval_loss)); nos dois casos a direcção é ligeiramente negativa.
2. **O limite está na informação, não no estimador.** Com ~27 votos por anotador e painéis fixos, qualquer estimador que infira a verdade dos votos tem teto de recuperação ≈ 0,60–0,64 (F1), e os parâmetros que um modelo psicométrico separa (F4) reduzem-se a quantidades que uma contagem já dá.
3. **[Novo nesta revisão] A "captura por bloco pequeno" do NUTMEG não sobrevive à correcção do M-step.** Com o estimador corrigido, 2–3 spammers com subpopulação própria recebem θ = 0,147 (contra 0,733 no legado). Uma das duas pontas da "tese central" das notas de 2026-08-27 cai (§5, §20).
4. **[Novo nesta revisão] A comparação decisiva da ablação tem um resíduo de densidade.** R1 e R2 removem o mesmo nº de votos (1 597) mas distribuem-nos de forma diferente pelos itens: 2 035 itens ficam com densidades diferentes nos dois braços, e só R1 tem itens com 3 votos (80). Era a limitação deixada em aberto no relatório da ablação; fica fechada, e confirma-se (§14.2).
5. **[Novo nesta revisão] "421 itens mudam de lado da maioria" sobrestima a intervenção do F2.** 360 desses 421 eram empates 3/3 no alvo cru, sem maioria; só **61** invertem de facto uma maioria (§13.1).

Parte I — Estimadores no sintético

1. F1 · NUTMEG: recuperação de θ (grade)

`[MEDIDO]` Pearson r(θ, θ verdadeiro), média de 3 seeds × 3 taxas de spam (`recovery_grid*.csv`; verificado: médias recalculadas idênticas às do `stage1_report.md`).

divisividade	confortável: NUTMEG	confortável: K = 1	Δ	EXIST: NUTMEG	EXIST: K = 1	Δ
0,00	0,763	**0,883**	−0,119	0,602	**0,692**	−0,090
0,15	0,768	0,723	+0,045	0,603	0,596	+0,007
0,30	0,757	0,510	+0,246	0,602	0,458	+0,144
0,50	0,765	0,317	+0,448	0,595	0,334	+0,261
0,70	0,754	0,287	+0,467	0,594	0,287	+0,307
global	**0,761**	**0,544**	**+0,217**	**0,599**	**0,473**	**+0,126**

Estimador legado (2026-08-26). Leitura:

- **O fenómeno do NUTMEG reproduz-se**: o modelo de subpopulação fica plano ao longo da divisividade (0,754–0,768) e o de verdade única degrada monotonicamente (0,883 → 0,287). O artigo reporta r ≈ 0,81 contra 0,58 (a confirmar na fonte primária); a ordem de grandeza e a direcção batem.
- **O ganho não é incondicional**: sem divisividade o K = 1 ganha, porque junta os 6 votos numa célula em vez de os fragmentar. O cruzamento fica perto de 0,15 de divisividade.
- **Na densidade do EXIST o teto cai para ≈ 0,60.** É o custo de estimar θ com 27 votos em vez de 80, qualquer que seja o estimador.
- `[LIMITAÇÃO]` **Convergência** (verificado nesta revisão a partir das colunas `converged` / `n_iter`): com o estimador legado e o limite de 200 iterações então em vigor, convergiram 76% das execuções do NUTMEG na densidade confortável e **só 7%** na do EXIST (K = 1: 87% e 36%). Os r da coluna EXIST vêm, na maioria, de execuções interrompidas. A conclusão de que interromper o EM era "cosmético" (M§4.4, item 1) foi medida só para o K = 1 nos dados reais (Δθ médio 0,0011); para estas execuções sintéticas do NUTMEG o efeito da interrupção não foi medido em 2026-08-26. Com o estimador corrigido convergem 100% e r sobe até 0,638 (§5); a diferença é um limite para o custo conjunto de interrupção e bug, não uma atribuição a um dos dois (o 2 × 2 do §5 mostra que, no sweep, `n_iter` não muda nada).

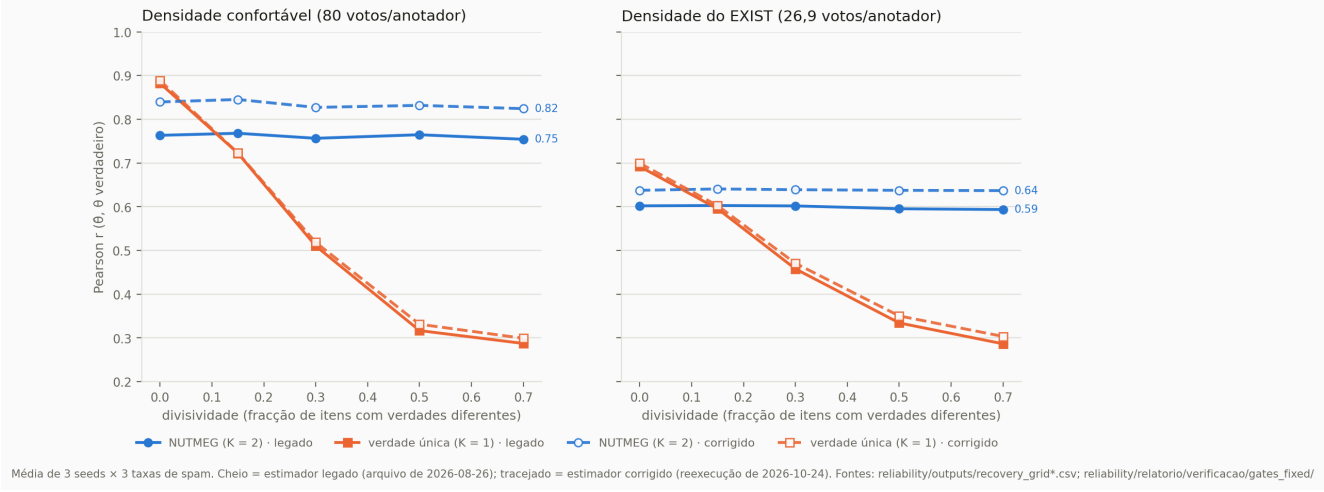


Figura R2 — Linha cheia: estimador legado (arquivo de 2026-08-26). Tracejado: estimador corrigido (reexecução de 2026-10-24, §5).

2. F1 · Preservação de minoria

`[MEDIDO]` Minoria de 25% com θ = 0,90 fixo que discorda da maioria em 70% dos itens; densidade confortável (`minority_preservation.json`).

seed	θ minoria	θ maioria fiável	θ spammers	gap (maioria − minoria)	separação	veredito
42	0,955	0,890	0,521	−0,065	+0,434	PASS
7	0,960	0,874	0,509	−0,086	+0,451	PASS
2025	0,921	0,885	0,419	−0,036	+0,501	PASS

Critérios: θ minoria ≥ 0,70, gap ≤ 0,10, separação ≥ 0,25. **PASS** nas 3 seeds: a minoria consistente fica **acima** da maioria fiável; o modelo não pune discordância legítima por desenho. O `stage1_report.md` §5 reporta também PASS na densidade do EXIST (θ minoria 0,921–0,927, gap −0,051 a −0,067); esses números não têm ficheiro próprio em `outputs/` e não foram recalculados.

3. F1 · Spammer de viés constante (20% do painel)

`[MEDIDO]` θ médio dos spammers enviesados (θ real = 0,25), por modo e seed; estimador legado (`bias_spammer_test_label*.json`).

modo	sempre YES: θ enviesado (42/7/2025)	sempre NO: θ enviesado (42/7/2025)	veredito (YES / NO)
`subpop_aware`	0,246 / 0,247 / 0,222	0,231 / 0,244 / 0,221	PASS / **FAIL**
`subpop_adversarial` (oráculo: subpopulação própria)	0,298 / 0,379 / 0,306	0,312 / 0,365 / 0,247	PASS / PASS
`single_truth`	0,252 / 0,234 / 0,224	0,225 / 0,245 / 0,215	PASS / PASS

c1 (θ ≤ 0,60) e c2 (gap para os fiáveis ≥ 0,20) passam nas 18 linhas. O único FAIL é de c3 (|θ enviesado − θ uniforme| ≤ 0,15) em `subpop_aware`, sempre NO, seed 2025: |Δ| = **0,1504**, exactamente na fronteira (no braço sempre YES a mesma célula dá 0,1496 e passa). É ruído de fronteira num critério secundário; o `stage1b_report.md` reporta-o assim. Dar aos enviesados uma subpopulação própria empurra o θ para cima em +0,05 a +0,13, mas a 20% do painel não chega para inverter o veredito.

4. F1 · Stress-sweep: blocos pequenos com subpopulação própria (estimador legado)

`[MEDIDO]` Modo `subpop_adversarial`, θ médio dos enviesados por fracção do painel (diagnóstico secundário; reproduzido nesta revisão, idêntico ao `stage1b_report.md`):

fracção	θ médio	por seed (42 / 7 / 2025)	contra o teto 0,60
0,03 (≈ 2 pessoas)	**0,733**	0,611 / 0,607 / 0,981	acima
0,05 (3 pessoas)	**0,663**	0,742 / 0,740 / 0,507	acima
0,10	0,478	0,483 / 0,445 / 0,505	abaixo
0,20	0,328	0,298 / 0,379 / 0,306	abaixo
0,35	0,326	0,301 / 0,385 / 0,293	abaixo
0,50	0,310	0,316 / 0,325 / 0,289	abaixo

Lido em 2026-08-26 como "a vulnerabilidade é inversa ao tamanho do grupo: com 2–3 pessoas numa célula, a verdade da célula é o voto delas". A secção seguinte mostra que este resultado depende do bug do M-step.

5. [2026-10-24] F1 reexecutado com o estimador corrigido

O que se fez (M§4.4): os portões do F1 foram reexecutados com o código e os critérios de `validate.py`, mudando apenas a responsabilidade do M-step. Com `legacy` e `n_iter = 200` os ficheiros de 2026-08-26 reproduzem-se **bit a bit** (verificação PASS). Depois correu-se com `fixed`. Um controlo 2 × 2 mostra que `n_iter` (200 ou 5 000) não muda nenhum número; a diferença é só da responsabilidade. **Não estava pré-registado**; fica como resultado datado desta revisão.

5.1 O que muda

Teste	Legado (2026-08-26)	Corrigido (2026-10-24)
Grade, confortável: NUTMEG / K = 1 (global)	0,761 / 0,544	**0,834 / 0,552**
Grade, EXIST: NUTMEG / K = 1 (global)	0,599 / 0,473	**0,638 / 0,485**
Grade: execuções convergidas (NUTMEG, confortável / EXIST)	76% / 7%	**100% / 100%**
Minoria: θ̂ minoria / maioria (42, 7, 2025)	0,955/0,890 · 0,960/0,874 · 0,921/0,885	0,890/0,811 · 0,883/0,799 · **0,829/0,828**
Minoria: veredito	PASS	PASS (margem da seed 2025 cai para gap −0,001)
Viés, `subpop_adversarial`: θ̂ enviesado sempre YES (42/7/2025)	0,298 / 0,379 / 0,306	0,152 / 0,205 / 0,155
Viés, `subpop_adversarial`: veredito (YES / NO)	PASS / PASS	**FAIL / FAIL** (c3, na direcção contrária: ver abaixo)
Viés, `subpop_aware`: veredito (YES / NO)	PASS / FAIL (fronteira)	PASS / PASS
Sweep, 3% do painel: θ̄ enviesado (42/7/2025)	**0,733** (0,611 / 0,607 / 0,981)	**0,147** (0,157 / 0,113 / 0,171)
Sweep, 5%	0,663	0,151
Sweep, 10% / 20% / 35% / 50%	0,478 / 0,328 / 0,326 / 0,310	0,136 / 0,171 / 0,190 / 0,205

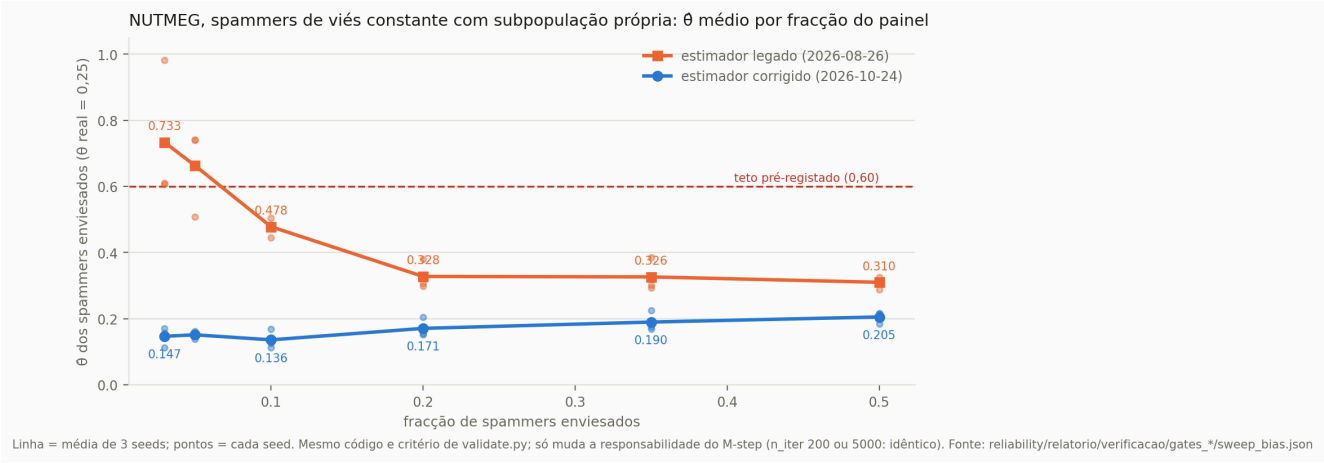


Figura R3 — θ̄ dos spammers de viés constante com subpopulação própria. Laranja: estimador legado; azul: corrigido. O teto pré-registado é 0,60. Mesmo código e critério de `validate.py`; só muda a responsabilidade do M-step (com `n_iter` = 200 ou 5 000 os números são idênticos).

O novo FAIL do `subpop_adversarial`. c1 e c2 passam em todas as linhas; c3 falha na seed 2025 (|Δ| = 0,151 no braço sempre YES, 0,171 no sempre NO), mas **na direcção contrária à captura**: os enviesados recebem θ (0,135–0,205) **abaixo** do dos spammers uniformes (0,273–0,306). O estimador corrigido pune mais o spammer enviesado do que o uniforme; o critério pedia que os dois fossem tratados de forma parecida. É um FAIL pelo critério pré-registado e fica escrito como tal, mas não é uma vulnerabilidade.

5.2 Porquê `[HIPÓTESE apoiada na derivação]`

A responsabilidade legada conta duas vezes o voto do próprio anotador (M§4.4). O excesso é máximo quando o posterior da verdade da célula é quase só o voto do anotador, ou seja, exactamente em células com 2–3 anotadores que votam igual. Nesse regime o legado infla o θ do bloco; o corrigido não. A derivação está em `mstep_responsibility_diagnosis.md` §1; a ligação ao sweep é uma interpretação, consistente com o 2 × 2 (só a responsabilidade muda o resultado).

5.3 O que isto muda e o que não muda

Muda:

- A "tese central" das notas de 2026-08-27 (`reliability/NOTAS_PARA_TESE.md` §1) dizia que a vulnerabilidade a blocos correlacionados existe **nas duas pontas** (bloco pequeno captura o NUTMEG; bloco grande captura o F3). **Com o estimador corrigido, a ponta do bloco pequeno não se verifica.** A ponta do bloco grande (F3, §6) não depende do EM e mantém-se.
- A "regra operacional" do `stage1b_report.md` (clusters de subpopulação ≥ 10% do painel) perde a evidência do sweep. Pode continuar a fazer sentido por outra razão (o KMeans comportamental degenerado [883, 2, 1, 1] deixa células com 1–2 votos, §8), mas já não pode citar o sweep.
- O teto de recuperação na densidade do EXIST passa de 0,599 para 0,638 (NUTMEG) e de 0,473 para 0,485 (K = 1).
- A frase do `cap07.tex` (IRT) "*contradicts the pattern observed for the subpopulation estimator discussed earlier, where the breaking point was the size of the group*" fica sem suporte.

Não muda:

- Os retreinos do F2 já usavam θ corrigido; os θ reais das 7 definições já foram regenerados com o estimador corrigido (`summary_taskA_fixed.md`, §8); a divisividade não usa o EM; F3, F4, F5 e F6 usam outro código.
- O fenómeno qualitativo (NUTMEG plano, K = 1 a degradar de 0,889 a 0,299) fica mais forte; o cruzamento continua entre 0,10 e 0,15.
- **O NUTMEG continua a não poder ir a retreino**, pela razão que já era a principal: a fragmentação dos dados reais (§8).

6. F3 · Por anotador com desconto de dificuldade

`[MEDIDO]` `perann_synthetic_gate.json`, 3 seeds, determinismo max|Δ| = 0. Valores recalculados do JSON, iguais aos do `perann_gate_report.md`.

6.1 Recuperação (Pearson r vs θ real)

densidade	hard_frac	votos/anotador	mace_naive	discount_raw	discount_loo
confortável	0,0	80	**0,893**	0,856	0,865
confortável	0,2	80	0,818	0,810	**0,819**
confortável	0,4	80	0,712	0,730	**0,736**
confortável	0,6	80	0,613	0,696	**0,699**
EXIST	0,0	27,1	**0,711**	0,638	0,658
EXIST	0,2	27,1	**0,629**	0,587	0,604
EXIST	0,4	27,1	0,503	0,500	**0,510**
EXIST	0,6	27,1	0,354	**0,389**	0,389

Critério: r(0,4; confortável) ≥ 0,60 (passa: 0,730 e 0,736) **e** vantagem sobre `mace_naive` ≥ 0,05 em todo `hard_frac` ≥ 0,4 (falha: **−0,003** e **+0,007**). O desconto só compensa quando a ambiguidade genuína domina (+0,083 em 0,6); empata em 0,4 e perde em ≤ 0,2. Na densidade do EXIST todos os r caem ≈ 0,2.

6.2 Minoria (braços *matched*) e spammer

config	hard: minoria	hard: fiáveis	easy: minoria	easy: fiáveis	spammer: θ	spammer: fiáveis	spammer: gap
`mace_naive`	0,940	0,845	0,728	0,851	0,774	0,855	+0,081
`discount_raw`	0,983	0,947	**0,896**	0,945	**0,906**	0,944	**+0,037**
`discount_loo`	0,940	0,842	**0,702**	0,820	**0,733**	0,823	+0,089

- **hard PASSA** nas duas variantes: a minoria em terreno ambíguo fica acima dos fiáveis (gap −0,036 e −0,098). A protecção LeWiDi funciona.
- **easy FALHA** nas duas: a minoria que discorda em terreno de consenso devia cair para ≤ 0,60 com gap ≥ 0,20; fica em 0,896 e 0,702 (gaps +0,049 e +0,118).
- **spammer FALHA** nas duas; e o `discount_raw` dá ao spammer um gap **menor** que a linha de base sem desconto. A hipótese de desenho ("os erros do spammer caem em itens fáceis, logo o desconto não o protege") fica refutada.

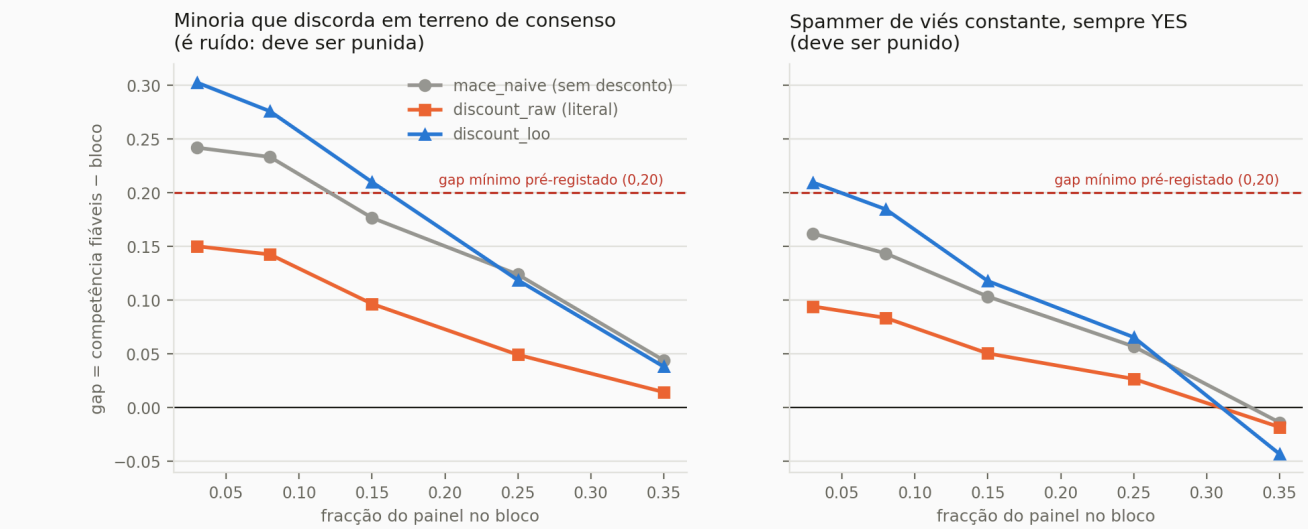
6.3 Sweep do bloco (diagnóstico)

`[MEDIDO]` gap = competência dos fiáveis − do bloco (maior é melhor); densidade confortável, `hard_frac` = 0,4.

fracção	easy: mace	easy: raw	easy: loo	spammer: mace	spammer: raw	spammer: loo
0,03	+0,242	+0,150	**+0,302**	+0,162	+0,094	**+0,209**
0,08	+0,233	+0,142	**+0,276**	+0,143	+0,083	**+0,184**
0,15	+0,176	+0,096	**+0,210**	+0,103	+0,050	**+0,118**
0,25	**+0,124**	+0,049	+0,118	+0,057	+0,026	**+0,065**

fracção	easy: mace	easy: raw	easy: loo	spammer: mace	spammer: raw	spammer: loo
0,35	**+0,044**	+0,014	+0,038	−0,014	−0,018	−0,043

A discriminação cai monotonicamente com o tamanho do bloco nas três configurações; a 35% de spammers sempre-YES o gap é **negativo** em todas (o bloco recebe mais competência do que os fiáveis, porque a essa densidade ele é a maioria em muitos itens). **Mecanismo:** a dificuldade sai dos votos; um bloco grande fabrica a dificuldade dos itens em que discorda, e o desconto passa a protegê-lo. O desconto quebra a circularidade competência → dificuldade, não a circularidade bloco → dificuldade.



Densidade confortável (80 votos/anotador), hard_frac = 0,4, média de 3 seeds. Fonte: reliability/outputs/perann_synthetic_gate.json (density_sweep)

6.4 Escala contra fundo, e a variante LOO

- **Escala (erro de desenho, M§7.5):** os limiares absolutos herdados do F1 não servem para uma taxa de concordância (chão ≈ 0,5); um spammer com θ = 0,25 tem concordância esperada 0,625 > 0,60 por construção. Os limiares não foram mexidos.
- **Fundo (não depende de limiar):** só em gaps, `discount_raw` perde para `mace_naive` em **10/10** linhas do sweep.
- **LOO domina a forma literal:** r maior em 7/8 linhas da §6.1 (na oitava, empate a 3 casas), gap maior em 9/10 do sweep, e continua a passar o braço hard. Contra `mace_naive` ganha 7/10, só em blocos ≤ 0,15.

Estado: portão não passado; pela regra do projecto, `run_perann_exist.py` não foi escrito.

7. F4 · IRT no sintético

`[MEDIDO]` Reexecução de `dataset_verifications.ipynb` nesta revisão: todos os números abaixo reproduzem com 4 casas.

7.1 Sondagem (50 votos/item, só para validar o código)

θ r = **0,978**, b r = **0,915**, a r = **0,526** (critério 0,80: FAIL em a). Diagnósticos: 0 itens no limite do optimizador; o alinhamento linear da escala não muda r; com σ_a ∈ {0,3; 0,6; 1,0} a recuperação de a fica em 0,551 / 0,745 / 0,681. Conclusão registada: limite de informação, não erro de implementação; o limiar de 0,80 para a estava alto demais (erro de desenho, não dos dados).

7.2 Densidade do EXIST (1 000 itens, 220 anotadores, 6 votos/item)

parâmetro	seed 42	seed 7	seed 2025	média	limiar	veredito
competência θ	0,8656	0,8632	0,9028	**0,8772**	0,60	PASS
dificuldade b	0,6092	0,5890	0,6075	**0,6019**	0,50	PASS
discriminação a	0,1362	0,1722	0,1758	**0,1614**	0,40	**FAIL**

Decisão pré-registada: adoptar o 1PL. Com a = 1 fixo: θ = 0,8778 e b = 0,6005 (Δ = +0,0006 e −0,0014 contra o 2PL, abaixo da variação entre seeds). O IRT recupera a competência bem acima do NUTMEG na mesma densidade (0,877 contra 0,599 legado / 0,638 corrigido).

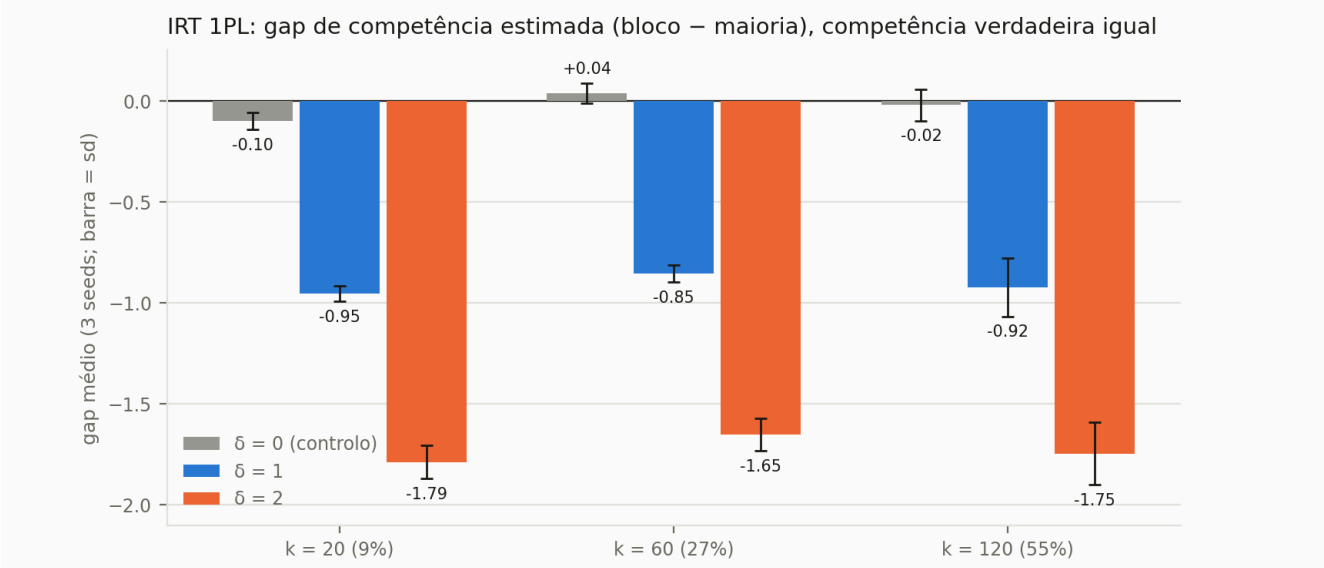
7.3 Bloco correlacionado (1PL)

Gap médio (bloco − maioria) de competência estimada, com competência verdadeira **igual** nos dois grupos; 3 seeds (média, sd).

k (fracção)	δ = 0 (controlo)	δ = 1	δ = 2	r(θ) com δ = 2
5 (2,3%)	**−0,449** (0,381)	−1,217	−1,965	0,854
20 (9,1%)	−0,099 (0,043)	−0,954	−1,789	0,781

k (fracção)	δ = 0 (controlo)	δ = 1	δ = 2	r(θ) com δ = 2
60 (27,3%)	+0,039 (0,049)	−0,855	−1,653	0,666
120 (54,5%)	−0,020 (0,078)	−0,922	−1,745	0,602

- **Critério pré-registado do controlo** (max|gap| < 0,10): **FAIL** por causa de k = 5 (0,449). Seguimento com 30 seeds (`[PÓS-HOC]`): gap médio +0,127, sd 0,436, erro-padrão 0,080, IC95 [−0,030; +0,283], que contém 0. A célula foi excluída por falta de poder (o critério tinha sido fixado sem calcular o erro-padrão esperado por tamanho de bloco); o critério não foi alterado.
- **Tratamento:** max|gap| = 1,965 (≥ 0,50) → **CAPTURA** pelo critério pré-registado; nas células válidas o gap vai de −0,85 a −1,79, 2 a 3 vezes o limiar.
- **A direcção é o achado:** o bloco é **penalizado**, não promovido. O 1PL tem um só parâmetro por pessoa, e uma diferença consistente de limiar não tem onde ser representada a não ser nesse parâmetro: perspectiva sistemática e baixa competência são, para este modelo, a mesma quantidade. O gap acompanha δ e é quase constante em k; a recuperação geral degrada com o tamanho do bloco (0,781 → 0,602 com δ = 2).



k = 5 excluído: controlo falhou (|gap| = 0,449) e o seguimento de 30 seeds dá IC95 [−0,030; +0,283]. Fonte: EXIST_MEMES/dataset_verifications.ipynb, célula 9

Parte II — Dados reais, sem retreino

8. θ do NUTMEG e do K = 1 nos dados reais

`[MEDIDO]` Estimador corrigido (`summary_taskA_fixed.md`, 2026-08-30).

definição	K	cobertura de células	votos/célula	θ médio	θ sd	θ < 0,5	ρ(θ, concordância)	tamanhos dos clusters
`demo_base_K4`	4	69,3%	2,17	0,461	0,206	519	+0,301	253 / 318 / 210 / 106
`demo_extended_K4`	4	85,7%	1,75	0,446	0,192	571	+0,178	232 / 203 / 246 / 206
`behavioral_K4`	4	64,7%	2,32	0,480	0,212	501	+0,457	287 / 69 / 278 / 253
`demo_base_K8`	8	49,6%	1,51	0,429	0,190	634	+0,193	152 / 74 / 123 / 86 / 146 / 30 / 180 / 96
`demo_extended_K8`	8	62,7%	**1,20**	0,395	0,162	742	+0,041	120 / 90 / 144 / 147 / 105 / 93 / 84 / 104
`behavioral_K8`	8	41,1%	1,83	0,461	0,205	560	+0,415	126 / 135 / 68 / 126 / 150 / 22 / 139 / 121
`single_truth_K1`	1	100%	6,00	0,483	0,219	458	**+0,615**	887

- **Fragmentação:** com subpopulação, cada célula (item, subpopulação) tem 1,2 a 2,3 votos. A "verdade da subpopulação" fica praticamente o voto de uma ou duas pessoas. Esta é a razão principal de o NUTMEG nunca ter ido a retreino.
- **O K = 1 é quase uma reexpressão do consenso** (ρ = +0,615 com a concordância com a maioria). As definições com subpopulação descolam dessa métrica (+0,04 a +0,46), o que é o efeito pretendido, mas não prova sucesso: a prova está no sintético (§2).
- **Confound:** o θ médio cai à medida que os votos por célula caem (6,00 → 1,20 votos/célula: 0,483 → 0,395); a dispersão de θ não é comparável entre definições com densidades de célula diferentes.
- Flags do `run_exist`: `demo_extended_K8` tem células quase singulares (< 1,5 votos/célula) e 48 quebras de monotonicidade; `behavioral_K4` 385 quebras; `demo_base_K8` 30 quebras (M-step de média posterior, não argmax).
- α de Krippendorff global: **0,2791**.

9. Divisividade empírica

`[MEDIDO]` `divisiveness_report.md`; vereditos pelo Nulo B (condicionado *within-item*), 50 permutações.

definição	itens divisivos (confiável)	z	rácio entre/total	z	α intra	z	itens no subconjunto confiável
`demo_base_K4`	0,304	−0,08	0,362	**+2,16**	0,288	**+2,03**	2 878 (72,2%)
`demo_extended_K4`	0,329	+0,30	0,499	**+2,09**	0,288	+1,37	3 455 (86,7%)
`behavioral_K4`	0,411	+18,33	0,460	+31,82	0,336	+12,80	2 750 (69,0%)
`demo_base_K8`	0,424	−0,37	0,597	+0,77	0,284	+0,49	2 153 (54,0%)
`demo_extended_K8`	0,467	+1,48	0,802	−0,85	0,285	−0,02	**698 (17,5%)**
`behavioral_K8`	0,459	+13,02	0,591	+31,16	0,355	+14,46	2 071 (52,0%)

- As definições **demográficas**, as únicas não circulares, mostram estrutura no máximo **marginal**: $z \approx 2{,}1$ em 2 de 3 indicadores, só em `demo_base_K4`; nula em $K = 8$. `demo_extended_K8` é inconclusiva por esparsidade.
- As **comportamentais** dão z enormes, mas são circulares (os clusters saem dos mesmos votos) e não são evidência independente.
- O Nulo A (permutar anotadores entre clusters) dava z negativos por **geometria**: os itens reais têm menos subpopulações distintas do que os permutados (2,77 contra 3,13 em `demo_base_K4`), logo menos fragmentação e menos divisividade espúria. Lido ingenuamente, pareceria "menos estrutura do que o acaso".
- Divisividade **acima do nulo** (observada − nula) em todas as definições: entre $-0{,}042$ e $+0{,}075$, longe do cruzamento $\approx 0{,}15$ do sintético. A comparação é direccional (o sintético usa $K = 2$ e verdades limpas).

10. IRT nos dados reais

`[MEDIDO]` 1PL por painel linguístico (reexecutado nesta revisão, idêntico ao notebook).

	painel ES	painel EN
itens · anotadores · votos	1 979 · 456 · 11 874	2 005 · 450 · 12 030
votos/anotador (mín · mediana · máx)	9 · 27 · 27	12 · 27 · 27
taxa de YES	0,573	0,539
iterações · quebras de monotonicidade	32 · 0	32 · 0
itens unânimes · itens com b no limite (|b| ≥ 9,9) · sobreposição	474 · 474 · 474	471 · 471 · 471
itens não unânimes	1 505	1 534
b vs logit(taxa de YES): Pearson · Spearman	**−0,9955** · −0,9766	**−0,9933** · −0,9789
b (não unânimes): média · sd · amplitude	−0,316 · 1,351 · [−2,487; +2,345]	−0,160 · 1,410 · [−2,584; +2,789]

- **Unanimidade**: 24% dos itens em cada painel, contra $\approx 3{,}7\%$ esperado se os anotadores fossem intercambiáveis. Parte grande do corpus produz acordo forte; a discordância concentra-se no resto.
- **Itens unânimes não têm dificuldade finita**; o conjunto de itens no limite do optimizador coincide **exactamente** com o de unânimes (causa única e entendida). Ficam na estimação, fora da análise de b.
- **b é quase colinear com o logit da taxa de YES** (menos de 1% de variância que uma contagem não dê). Razão estrutural: o que distingue uma dificuldade de Rasch de uma proporção é o ajuste pela competência de quem viu o item; com painéis fixos de 6 e competência média quase constante entre painéis, não há variação para esse ajuste exprimir.
- **Task 2.2**: mediana de 15 votos por anotador (A: 27); 125 anotadores (14,1%) com menos votos do que parâmetros num modelo de 9; 583 (65,7%) com menos de 2 observações por parâmetro. Nenhum modelo foi ajustado.

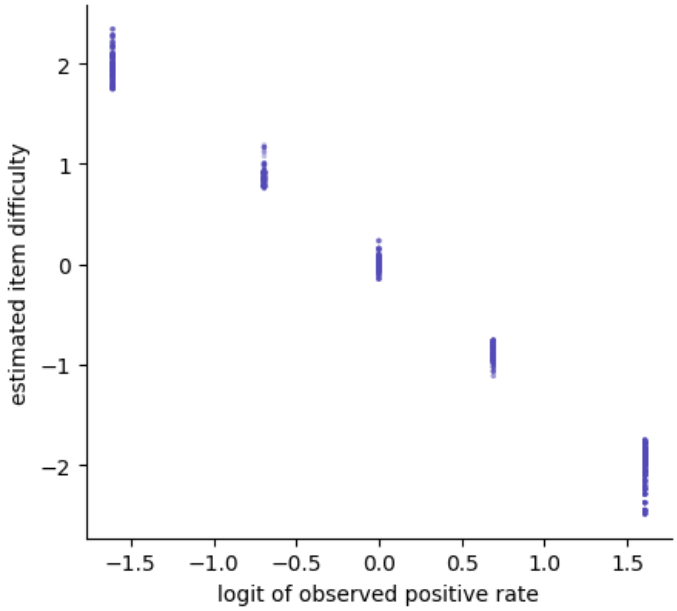


Figura R4 — Painel ES, itens não unânimes (n = 1 505), r = −0,9955. Fonte: `images/irt_b_vs_yesrate.png` *da tese.*

11. O estimador K = 1: convergência e o bug do M-step

`[MEDIDO]` (M§4.4)

	θ legado	**θ corrigido**
iterações até convergir	200 sem convergir; 462 com `n_iter = 5000`	**292**
quebras da log-posterior	273	**0**
θ médio	0,5352	**0,4826**
anotadores com θ < 0,5	—	458 (51,52% dos votos)
Pearson / Spearman (legado × corrigido)	0,8923 / 0,8977	
média · máximo de |Δθ|	0,0794 · 0,7166	
anotadores que cruzam θ = 0,5	95	
anotadores com |Δθ| > 0,05	409 (46,1%)	
θ legado ≥ θ corrigido	74,6% dos anotadores (direcção prevista pela derivação)	

Interromper o legado a 200 iterações em vez de 462 era cosmético (r = 0,9991 com o convergido; deslocamento das soft labels 0,000317). A responsabilidade não era: o deslocamento das soft labels entre θ corrigido e legado é 0,0246 em média (77 vezes o da convergência), 134 itens cruzam 0,5 entre os dois alvos ponderados (Pearson 0,9893), e a intervenção do F2 encolhe de 0,0720 para 0,0617.

Parte III — Retreinos do modelo de memes

12. F2 a 2 épocas (θ legado, 2026-08-30) — registo, não referência

`[MEDIDO]` `theta_arms_comparison.md`; recalculado.

seed	**raw**	**ponderado**	**Δ (época 2)**
42	0,4239	0,4269	+0,0031
7	0,4203	0,4301	+0,0099
2025	0,4309	0,4314	+0,0005
média			**+0,0045** (sd 0,0048, t = 1,604, p = 0,250)

Critério do estudo: efeito maior que o "spread" do baseline entre seeds. O spread usado é a **amplitude** (máx − mín = 0,0107), não um sd (o sd seria 0,0054). Veredito do estudo: nulo. **Subtreinado**: a `eval_loss` ainda descia e a primária ainda subia ∼+0,03 por época nas 6 runs. Alvo diferente do de 15 épocas (θ legado) e critério diferente; não comparar os dois Δ.

13. F2 a 15 épocas (θ corrigido, 2026-08-30/31)

13.1 Tamanho da intervenção no alvo

`[MEDIDO]` `weighted_fixed` contra `raw`, 3 984 itens (recalculado):

grandeza	valor
média · sd · p50 · p90 · p99 · máx de |Δp_YES|	0,0617 · 0,0656 · 0,0445 · 0,1511 · 0,2638 · 0,3525
itens com |Δ| > 0,05 · > 0,10	1 861 (46,7%) · 934 (23,4%)
Pearson (raw, ponderado)	0,9661
itens que "cruzam 0,5" (convenção do código, `≥ 0,5`)	421 (10,6%)
… dos quais eram **empates 3/3** no alvo cru	**360**
… que **invertem uma maioria** estrita	**61** (1,5%)
peso normalizado de um voto (uniforme = 0,1667)	mín 0,0084 · mediana 0,1655 · máx 0,4445

`[LIMITAÇÃO]` O relatório original escreve "421 itens mudam de lado da maioria". 360 deles não tinham maioria (614 itens estão em 3/3 no alvo cru; qualquer descida abaixo de 0,5 conta como cruzamento). A intervenção continua material (média $|\Delta| = 0{,}0617$, 23,4% dos itens movem mais de 0,10), mas a frase deve dizer "resolve 360 empates e inverte 61 maiorias". O mesmo vale para o alvo legado (443 = 353 empates + 90 inversões).

13.2 Resultado decisivo

`[MEDIDO]` E = época 3 nas 6 runs. Ficheiros na §21.

seed	A0 (raw)	A1 (ponderado)	Δ = A1 − A0
42	0,4711	0,4663	−0,0048
7	0,4610	0,4596	−0,0014
2025	0,4608	0,4595	−0,0013
média			**−0,0025**

$\mathrm{sd}(\Delta) = 0{,}0020 \cdot t(2) = -2{,}16 \cdot$ **p = 0,164** $\cdot\ d_z = -1{,}25 \cdot$ mesmo sinal em 3/3 $\cdot \approx 6$ seeds para 80% de poder. **Veredito: NULO.**

13.3 As seis métricas, em E e no estado final

métrica	Δ em E (42 / 7 / 2025)	média	p	Δ final (ép. 15)	p
A ICM-Norm hard	−0,0025 / −0,0075 / −0,0256	−0,0118	0,234	−0,0238	0,009
A ICM-Soft-Norm soft	−0,0048 / −0,0014 / −0,0013	**−0,0025**	**0,164**	−0,0066	0,111
B ICM-Norm hard	−0,0063 / −0,0043 / +0,0122	+0,0006	0,933	+0,0079	0,459
B ICM-Soft-Norm soft	−0,0039 / −0,0007 / −0,0048	−0,0031	0,126	−0,0001	0,987
C ICM-Norm hard	−0,0036 / +0,0012 / +0,0057	+0,0011	0,719	+0,0066	0,486
C ICM-Soft-Norm soft	−0,0029 / −0,0048 / −0,0133	−0,0070	0,160	−0,0035	0,304

`[LIMITAÇÃO]` O p = 0,009 de "A ICM-Norm hard, estado final" ($d_z = -6{,}02$) é uma célula entre 12 e lê-se como multiplicidade: a época 15 está em sobreajuste profundo (a `eval_loss` sobe desde a época 3 nas 6 runs). B e C não mudaram de alvo; o que se vê nelas é *spillover* do encoder.

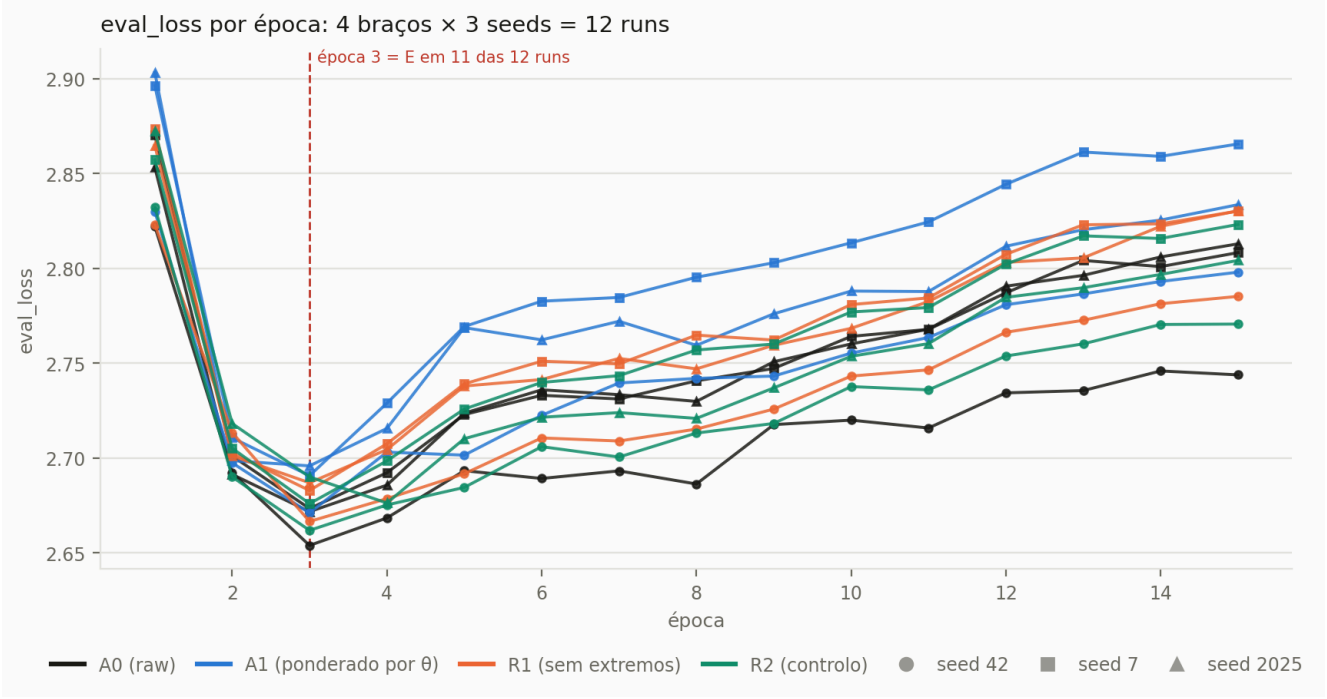


Figura R5 — `eval_loss` por época nos 12 retreinos de 15 épocas: 4 braços (cor: A0, A1, R1, R2) × 3 seeds (marcador: ○ 42, □ 7, △ 2025), uma linha por run. Mínimo na época 3 em 11 de 12 runs (época 4 em R2/2025).

13.4 Nulo por permutação de θ (preparado, nunca treinado)

`[MEDIDO]` P1–P4 PASS nas 5 permutações (fracção máxima de pontos fixos 0,0046). P5: |Δp_YES| médio das labels permutadas contra a crua = 0,0510 a 0,0531 (média 0,0514), contra 0,0617 do A1 real: **razão 0,832**. O nulo perturba o alvo quase tanto quanto a intervenção real, o que o tornaria um controlo forte; mas as 5 runs nunca foram feitas.

14. F5 · Ablação de anotadores extremos

14.1 O alvo, antes do treino

`[MEDIDO]` (recalculado; os dois ficheiros de alvo reproduzem-se exactamente a partir do notebook)

grandeza	R1 (sem 61 extremos)	R2 (sem 61 sorteados)
votos removidos	1 597	1 597
itens afectados	998	1 054
|Δ| médio (afectados) · (todos)	0,1023 · 0,0256	0,0866 · 0,0229
itens que cruzam 0,5 (convenção `≥ 0,5`) · dos quais empates 3/3 no cru	150 · 128	114 · 103
valores distintos no alvo (A0 tem 7)	13	13
média · P(p_YES > 0,5)	0,5504 · 0,5168	0,5561 · 0,5251

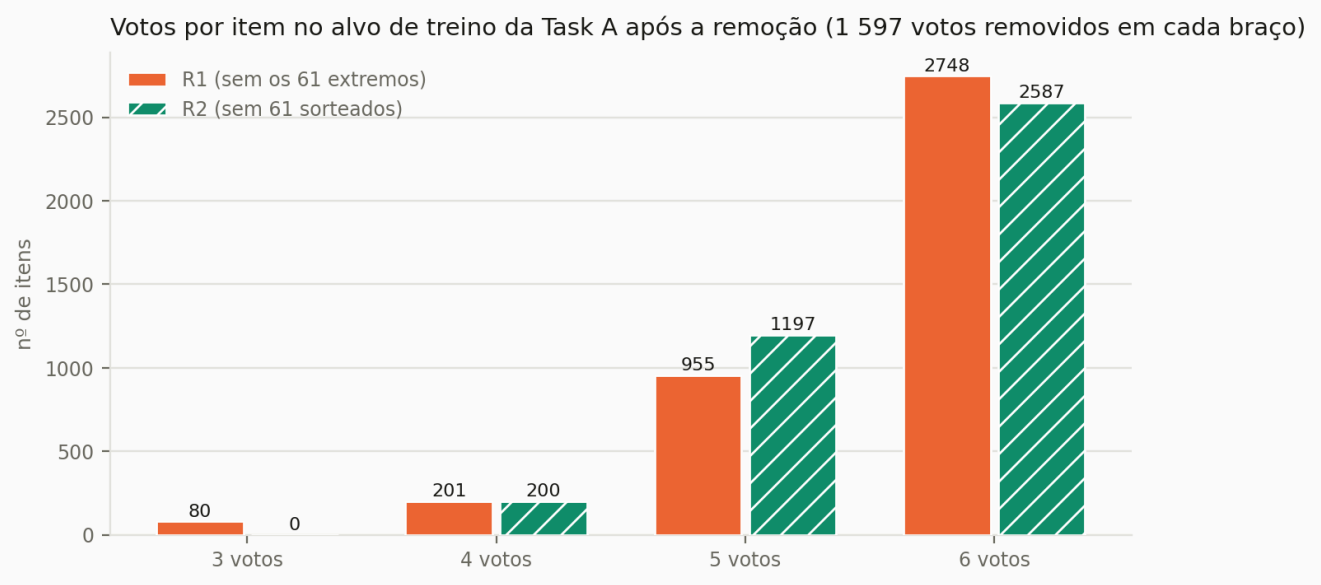
Distância directa R1 ↔ R2: diferem em **1 653** itens, |Δ| médio 0,0445 (todos) e 0,1073 (afectados), **232** itens cruzam 0,5 entre eles: mais do que R1 ou R2 contra o A0. A intervenção era grande à entrada.

14.2 [2026-10-24] Densidade dos votos por item: o resíduo que ficava em aberto

O relatório da ablação deixou por verificar se R1 e R2 removem votos na mesma distribuição de itens (`experiment_taskA_ablation_report.md` §3.1). Verificado nesta revisão:

votos por item no alvo	R1	R2
3	**80**	0
4	201	200
5	955	1 197
6	2 748	2 587

2 035 itens ficam com densidades diferentes nos dois braços. Os extremos estão mais concentrados nos painéis: os 61 extremos caem em 47 dos 151 painéis (36 painéis com 1 extremo, 8 com 2, **3 com 3**), os 61 sorteados em 53 painéis (45 com 1, 8 com 2, nenhum com 3). Por isso R1 tira os mesmos 1 597 votos de menos itens (1 236 itens perdem pelo menos um voto, contra 1 397 em R2), e os ~80 itens dos 3 painéis com 3 extremos ficam com metade dos votos. O sorteio do controlo estratificou por língua e nº de votos, não por painel (M§9.2). **A comparação decisiva R1 − R2 controla o número de votos removidos, mas não a sua distribuição por item.** Há portanto um resíduo de densidade dentro do teste decisivo. A direcção do viés que ele introduz não é óbvia (itens com 3 votos dão um alvo mais ruidoso a R1, o que tende a prejudicar R1, mas também são itens onde o voto removido era extremo). `[LIMITAÇÃO]` a declarar junto do resultado.



14.3 Resultado decisivo — R1 – R2 em E

`[MEDIDO]` E = 3 em todas as runs excepto R2/2025 (E = 4); cada braço lido no seu E.

seed	R1	R2	Δ = R1 – R2
42	0,4621	0,4662	–0,0041
7	0,4570	0,4599	–0,0029
2025	0,4546	0,4706	–0,0160
média			**–0,0077**

sd(Δ) = 0,0072 · t(2) = −1,84 · **p = 0,206** · d_z = −1,06 · mesmo sinal em 3/3 · ≈ 7 seeds para 80% de poder. **Veredito: NULO.**

14.4 As três comparações na métrica decisiva

comparação	Δ por seed (42 / 7 / 2025)	média	sd	p (E)	p (final)
R1 – R2 (decisiva)	–0,0041 / –0,0029 / –0,0160	**–0,0077**	0,0072	**0,206**	0,128
R1 – A0 (contexto)	–0,0090 / –0,0041 / –0,0061	–0,0064	0,0025	0,048	0,040
R2 – A0 (contexto)	–0,0049 / –0,0011 / +0,0099	+0,0013	0,0077	0,799	0,339

- O p = 0,048 de R1 − A0 **não é um achado**: foi declarado contexto antes de os números serem lidos (mistura critério, perda de densidade e fragmentação da grade), é uma célula entre 36 (3 comparações × 6 métricas × 2 pontos), e o teste que isola o critério não o sustenta.
- **Porque os dois p diferem com médias quase iguais:** o denominador. R1 e A0 sobem e descem juntos entre seeds (sd(Δ) = 0,0025); R2 não acompanha nenhum dos dois (sd(Δ) = 0,0072, 2,9×). A dispersão entre seeds em nível é comparável nos três braços (A0 0,0059; R1 0,0038; R2 0,0054). A instabilidade introduzida por remover anotadores **ao acaso** é da mesma ordem do deslocamento causado por remover os extremos.
- `[HIPÓTESE]` As três leituras apontam no mesmo sentido: remover a densidade sozinha não custa nada (R2 − A0 = +0,0013), remover os extremos custa um pouco. A magnitude está dentro do ruído a n = 3; mais seeds podiam, no melhor caso, estabelecer um custo pequeno, nunca um ganho.
- A régua favorece o A0 por construção (o gold de validação é o alvo cru, com 6 votos); essa desvantagem cancela em R1 − R2.

Tabela completa das 6 métricas × 3 comparações × 2 pontos: `experiment_taskA_ablation_report.md` §5–§6 (todas recalculadas nesta revisão, sem diferenças).

15. F6 · Camada de confusão, Fase 1

15.1 Controlo (M1, λ = 0, seed 42, 2026-09-06)

quantidade	valor	régua
Δ primária em E	–0,0017	sd do A0 entre seeds = 0,0059
Δ `eval_loss` em E	+1,8e-3	amplitude entre seeds = 1,94e-2
E	3 nos dois	—
matrizes: max|C – C_init|	7e-9 (arredondamento do softmax)	congeladas

PASS pelo critério recalibrado (M§10.3). O λ = 0 só correu na seed 42: o Δ_null nas seeds 7 e 2025, recomendado no protocolo, **não foi corrido**.

15.2 Grelha pré-registada (só a seed 42 correu)

λ	E	A ICM-Soft-Norm	A0	Δ	peso efectivo da Task A
0,1	4	0,4716	0,4711	+0,0005	2,1
0,3	3	0,4715	0,4711	+0,0003	2,3
1,0	3	0,4727	0,4711	+0,0016	3,0

A grelha ficou **incompleta** (seeds 7 e 2025 não correram) e por isso **o teste pré-registado (t pareado, Bonferroni p < 0,0167) nunca foi calculado**. `[NOTA]` O `experiment_confusion_report.md` imprime "Veredicto da família: NULO" com todas as linhas "não corrido"; a formulação correcta é "teste não executado". Mais importante: com o LR partilhado as matrizes moveram-se no máximo 6e-4 e ficaram presas perto da identidade, onde a auxiliar é a própria BCE da Task A; a grelha mede uma ablação do peso da Task A (2,0 → 2,1/2,3/3,0), não modelação do anotador (M§10.4).

15.3 Braço exploratório `CONF_LR = 1e–2` (3 seeds)

seed	ficheiro	E	A ICM-Soft-Norm	A0	Δ
42	`20260907_234357_…_clr0.01_seed42`	3	0,4730	0,4711	+0,0019
7	`20260908_192123_…_clr0.01_seed7`	3	0,4620	0,4610	+0,0010
2025	`20260909_225545_…_clr0.01_seed2025`	3	0,4605	0,4608	–0,0003

Média **+0,0009**, sd 0,0011, t(2) = 1,38, p = 0,30. Exploratório e pós-hoc; fora da estatística confirmatória. **Nulo.**

15.4 O que as matrizes aprenderam (época E = 3; recalculado)

seed	viés = a·yes_rate + b	R^2	fracção da variância das off-diagonais na direcção do viés	sd da competência	r(competência, |yes_rate – 0,55|)	r(competência, yes_rate)
42	0,827·yes_rate – 0,420	0,910	0,887	0,066	–0,758	–0,155
7	0,771·yes_rate – 0,391	0,906	0,888	0,061	–0,731	–0,162
2025	0,794·yes_rate – 0,406	0,908	0,886	0,064	–0,747	–0,146

Viés = C[NO→YES] − C[YES→NO]; competência = C[YES,YES] + C[NO,NO] − 1. As matrizes **colapsam no viés marginal** do anotador (a taxa de YES dele), e a competência aprendida é em grande parte o **desvio à taxa base** (forma em U), não algo linear na taxa de YES. `[NOTA]` O *handoff* escreve "viés = 0,827·yes_rate − 0,420" como se fosse comum às três seeds; é a recta da seed 42. A "fracção da variância" de 88,7% é a variância de $(c_{10} - c_{01})/\sqrt{2}$ sobre a variância total das duas off-diagonais (definição recuperada nesta revisão; dá 0,887 / 0,888 / 0,886).

16. F6 · Camada de confusão, Fase 2

16.1 Run A (M1sd, viés livre, seed 2025, 2026-09-11)

`[MEDIDO]` NLL nos 3 588 votos retidos, época E = 3 (`experiment_votes_report.json`; recalculado):

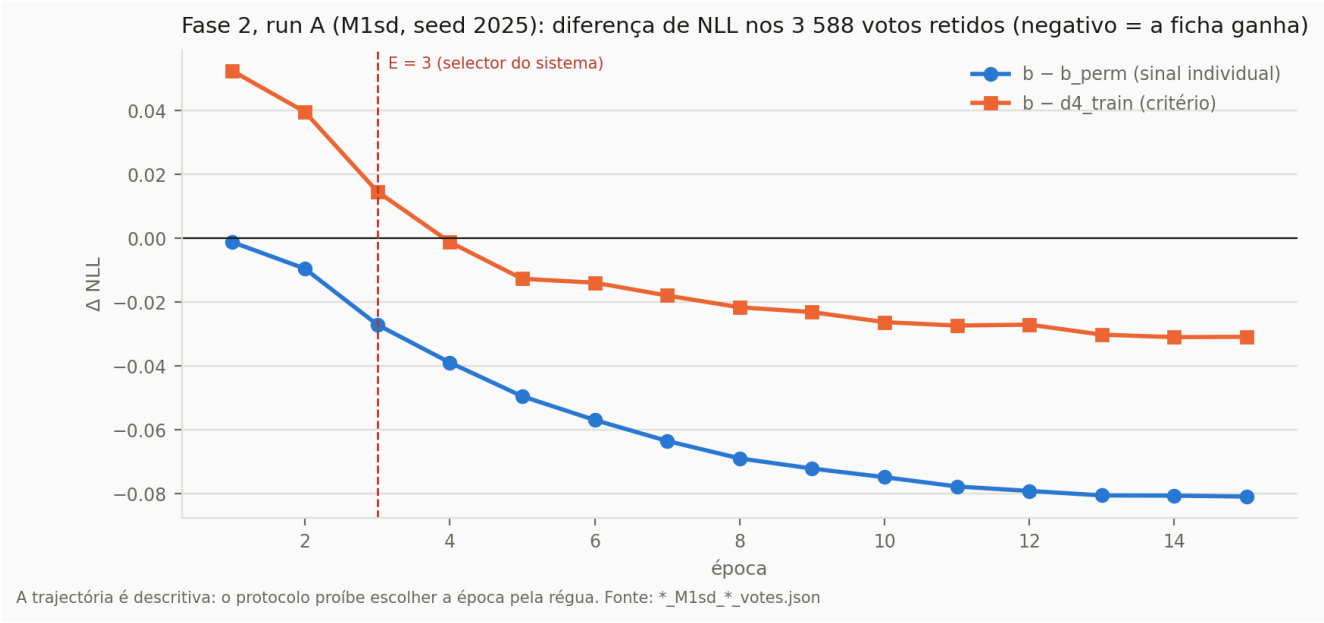
preditor	NLL	acerto
`a` (só o item)	0,6234	65,8%
`b` (ficha aprendida)	0,5989	68,3%
`b_perm` (ficha de outra pessoa)	0,6260	65,0%

preditor	NLL	acerto
`c` (só o histórico)	0,6301	63,2%
`d3_train`	0,5845	68,8%
`d4_train` (critério)	**0,5843**	69,0%
`d3_val` (oráculo)	0,5680	69,0%
`d4_val` (oráculo)	0,5676	68,8%

contraste	valor	leitura
b – a	−0,0244	descritivo (b bate a já no init, por calibração global)
b – b_perm	**−0,0271**	a ficha individual carrega sinal: conhecer *aquela* pessoa ajuda
b – d4_train	**+0,0147**	**critério: a ficha não bate a logística de 4 ingredientes → NULO**

Diagnóstico das fichas em E: competência média 0,768, sd 0,053; r(viés, yes_rate) = +0,975; r(competência, |yes_rate − taxa base|) = −0,519; r(competência, concordância) = +0,574. **Leitura pelos vereditos pré-declarados:** `b` bate `b_perm` (há sinal individual) mas perde para `d4_train`: o que a ficha sabe sobre o anotador é recuperável por uma logística com a taxa de YES, a concordância com a maioria e o desvio à taxa base.

`[MEDIDO, descritivo]` Ao longo das épocas, `b − d4_train` passa a negativo na época 4 (−0,0012) e chega a −0,031 na época 15; `b − b_perm` vai de −0,001 (época 1) a −0,081 (época 15). **Não muda o veredito**: o protocolo proíbe escolher a época pela régua (seria escolher pela métrica reportada), e E = 3 é o selector do sistema. `[HIPÓTESE]` O modelo de anotador e o sistema têm óptimos de época diferentes; testá-lo exigiria um selector próprio, pré-registado.



A trajectória é descritiva: o protocolo proíbe escolher a época pela régua. Fonte: *_M1sd_*_votes.json

16.2 Run B (controlo positivo) e runs C/D/E

- **Run B** (`M1sdcrp`, seed 2025, 120 anotadores corrompidos, 828 votos invertidos): treinada a 2026-09-11, 15 avaliações, E = 3. **Nunca analisada.** O `experiment_votes_report.*` é anterior a ela e só contém a run A. A Porta 1 (a competência dos corrompidos cai com o nível? o nível ≥ 40% separa do 0%?) **não tem veredito**. Por desenho, o ICM da run B não se compara com nada (gold de validação corrompido).
- **Runs C/D/E** (viés congelado): não corridas; dependem da Porta 1.
- Consequência: pelo próprio protocolo, enquanto a run B não for analisada **o nulo da run A não é atribuível** (não se sabe se o mecanismo detectaria um anotador sabidamente diferente).

Parte IV — Verificação desta revisão

17. O que foi recalculado

Scripts e logs em `reliability/relatorio/verificacao/`. Tudo PASS salvo o indicado.

Bloco	Como	Resultado
Constantes do dataset (§1 da metodologia)	recontagem directa do JSON de treino; α recalculado	todas iguais
Split e alvo cru	igualdade com `n_YES/6`; 3 386/598; 3 588 votos de validação	iguais
Alvos ponderados	Σθv/Σθ com θ corrigido e legado contra os ficheiros	iguais a 2e-16 / 3e-16
Estatísticas do alvo F2, θ legado × corrigido, permutações P5	recalculadas	iguais (cruzamentos: ver §13.1)
2 épocas, 15 épocas, ablação (6 métricas × 2 pontos), confusão	recalculados dos logs `metrics_history` com `scipy.stats.t`	iguais a 3–4 casas
Alvos R1/R2	recalculados com o código do notebook	idênticos aos ficheiros; densidade nova (§14.2)
NUTMEG sintético	reexecução com o estimador legado	bit a bit; mais o corrigido (§5)
Por anotador	valores do JSON contra o relatório	iguais
IRT	reexecução do notebook	iguais a 4 casas (sondagem: 118 vs 102 iterações, 10 vs 3 quebras; ambiente)
Painéis	reexecução do notebook (células 1–8, 12)	iguais
Fase 2, run A	contrastes de NLL do JSON	iguais
Matrizes da Fase 1	recalculadas dos *dumps* `_confusion.json`	iguais (com as precisões da §15.4)

Não recalculados: as pré-verificações com embeddings do notebook de painéis (células 9–11; dependem de XLM-R/CLIP), a minoria na densidade do EXIST (§2; sem ficheiro), o diagnóstico comportamental (Apêndice A; só lido).

18. Ambiguidades e erros encontrados nas fontes

#	Onde	O problema	Como fica neste relatório
1	`soft_labels_taskA_report_fixed.md` §1, §8	"421 itens mudam de lado da maioria": 360 eram empates 3/3	"resolve 360 empates e inverte 61 maiorias" (§13.1)
2	`experiment_taskA_ablation_report.md` §3.1	densidade por item de R1/R2 "não verificada"	verificada: 2 035 itens com densidades diferentes (§14.2)
3	`NOTAS_PARA_TESE.md` §1, `stage1b_report.md`	captura do NUTMEG por bloco pequeno	artefacto do estimador legado (§5)
4	`recovery_grid_existdensity.csv`	93% das execuções do NUTMEG não convergiram (limite de 200)	declarado (§1); o corrigido converge 100%
5	`soft_labels_taskA_report_fixed.md` §2	cita o ficheiro de θ sem `_fixed`	os números são do θ corrigido (verificado)
6	`theta_arms_comparison.md`	"spread do baseline 0,0107"	é amplitude, não sd (sd = 0,0054)
7	`HANDOFF_CONFUSION_FASE2.md`	"resultados todos replicados em 3 seeds"	o controlo λ = 0 e a grelha têm só a seed 42; só o braço `clr` tem 3
8	`HANDOFF_CONFUSION_FASE2.md`	"viés = 0,827·yes_rate − 0,420"	é a recta da seed 42 (§15.4)
9	`experiment_confusion_report.md` §5	"Veredicto da família: NULO" com testes "não corridos"	"teste pré-registado não executado; grelha incompleta"
10	`CONFUSION_EXPERIMENT.md` §17	plano com seed 42 na run A	a run A correu com a seed 2025 (desvio 13)
11	`cap07.tex` (IRT)	"four independent families"	são cinco com a camada de confusão (seis com a ablação, sete com o LLM, consoante o agrupamento; §20)
12	`cap07.tex` (IRT)	limiar de 0,60 "to match … the vote weighting estimator"	o 0,599 é do NUTMEG (subpopulação), não do K = 1 que pondera votos; e passa a 0,638 com o estimador corrigido
13	`cap07.tex` (IRT)	"the breaking point was the size of the group"	sem suporte depois do §5
14	`cap07.tex`	figura `block-size-competence.png`	é a figura do notebook `irt_block_gap.pdf` com outro nome; confirmar que é a mesma versão
15	`behavioral_diagnosis.md` §7	correlações com θ do NUTMEG	usam os ficheiros de θ **legados** (sem `_fixed`); as conclusões (|ρ| ≤ 0,28) não foram refeitas com o θ corrigido
16	`reliability/outputs/loo_sensitivity.json`	sem produtor nem consumidor no repositório	órfão; não usado
17	`behavioral_diagnosis.md` §9 vs §7	"todas as associações são fracas (|ρ| ≤ 0,24)"	o máximo da própria tabela do §7 é 0,280

Parte V — Síntese

19. Interpretação

O fio que liga as famílias (revisto nesta data). Todos os estimadores que inferem a verdade de referência a partir dos próprios votos esbarram em dois limites deste dataset, e cada família falha por uma razão específica da sua estrutura:

1. **Densidade.** ~27 votos por anotador e 6 por item em painéis fixos põem o teto de recuperação de θ em ≈ 0,60–0,64 para os estimadores de agregação (F1, F2), e a fragmentação em células de 1,2 a 2,3 votos tira o NUTMEG do jogo nos dados reais, independentemente do bug.
2. **Circularidade com blocos.** Quando a "dificuldade" ou a "verdade" sai dos votos, um bloco correlacionado grande fabrica-a (F3, gap negativo a 35%). Com o estimador corrigido, o NUTMEG **não** é capturado por blocos pequenos com subpopulação própria (§5); a formulação "as duas pontas" deixa de valer, fica a ponta do bloco grande.
3. **Posição absorvida como competência.** Quando o modelo tem um só parâmetro por pessoa e trata a dificuldade como latente (F4), uma diferença consistente de limiar é lida como baixa competência; e com painéis fixos a dificuldade reduz-se à contagem.
4. **Usar a estimativa não rende.** Ponderar (F2: $\Delta = -0{,}0025$) e remover (F5: $\Delta = -0{,}0077$) dão nulo no regime real de treino, com a direcção ligeiramente negativa nos dois casos. Modelar o anotador dentro do treino (F6) aprende sobretudo o viés marginal de cada pessoa, e o que aprende é recuperável por uma logística de 4 ingredientes.

Porque isto é coerente com o resto dos dados. A análise de painéis (Apêndice A.1) mostra que o desvio de cada anotador é sobretudo um **limiar pessoal estável** (split-half 0,850; 81,3% da variância é real entre pessoas; a demografia género × idade explica 11,5% dela). Sob LeWiDi isso é perspectiva, não ruído; um estimador que o trate como incompetência apaga exactamente o desacordo que a tarefa quer modelar. É o mesmo diagnóstico, por outra via, da referência externa por LLM (docs 25–31): o desvio de cada anotador face a uma referência fora dos votos também não se converteu em ganho (relatório GLM/Claude).

20. Limitações e pendências

20.1 Limitações a declarar no texto

- **n = 3 seeds** em todos os retreinos: os testes são fracos por construção; d_z e o nº de seeds para 80% de poder (6 a 7 nas comparações decisivas) são ordens de grandeza.
- **Task 2.1 apenas.** Nenhum estimador foi aplicado às Tasks 2.2/2.3 (a 2.2 tem 15 votos por anotador; a 2.3 é multirrótulo). Um nulo na A não prevê a utilidade em B/C.
- **Split por item, não por anotador** (F6): favorece o método.
- **Ambiguidade genuína não é observável nos dados reais** (F3): só existe a dificuldade empírica, que é a quantidade capturável.
- **O IRT modelou o bloco como deslocamento uniforme** de dificuldade; um bloco que discorda só num subconjunto de itens não foi testado.
- **Resíduo de densidade** na comparação decisiva da ablação (§14.2).
- **O estimador K = 1 é "do tipo MACE"**, implementado de raiz; a correspondência exacta com o M-step de Hovy et al. (2013) não foi verificada.
- **Referências a verificar na fonte primária antes de citar:** NUTMEG (`ivey2025nutmeg`), MACE (`hovy2013mace`), Chu et al. 2021, Tanno et al. 2019, Rodrigues e Pereira 2018 (o projecto já apanhou duas referências fabricadas noutra auditoria).

20.2 O que mudar no texto da tese

1. `cap07.tex`, subsecção do IRT: "four independent families" → contagem actualizada (pelo menos cinco: + camada de confusão).
2. `cap07.tex`, mesma subsecção: retirar ou reformular "where the breaking point was the size of the group" (§5).
3. `cap07.tex`, limiar de 0,60: atribuir ao NUTMEG (não ao estimador de ponderação) e decidir se se cita 0,599 (legado, o que existia quando o limiar foi fixado) com nota do 0,638 corrigido.
4. Qualquer frase que use "421 itens mudam de lado da maioria" → "360 empates resolvidos e 61 maiorias invertidas".
5. Se a tese reproduzir a "tese central" de `NOTAS_PARA_TESE.md` §1: reescrever com uma só ponta (bloco grande, F3) e citar §5 deste relatório.
6. Subsecção da camada de confusão (se existir no texto final): "a competência não correlaciona com nada" → correlaciona $-0{,}73$ a $-0{,}76$ com o desvio à taxa base (já registado em `CONFUSION_EXPERIMENT.md` §16).

20.3 Trabalho que ficou por fazer (não autorizado; só listado)

Pendência	Custo	O que resolveria
Analisar a run B (Porta 1)	CPU, minutos (`analyze_votes_experiment`; sobrescreve o relatório actual da run A)	torna o nulo da run A atribuível ou não
5 retreinos do nulo por permutação de θ	~5 runs de 15 épocas	separaria "θ não carrega informação" de "qualquer perturbação do alvo dá isto"
Δ_null (λ = 0) nas seeds 7 e 2025	2 runs	banda empírica do offset do invólucro
Braços S1/S2 da ablação (substituir em vez de remover)	6 runs	ablação sem perda de densidade nem fragmentação da grade

Pendência	Custo	O que resolveria
Refazer as correlações do diagnóstico comportamental com θ corrigido	CPU	fecha a ambiguidade #15
Nota datada em `NOTAS_PARA_TESE.md` §1 a apontar para §5 deste relatório	texto	evita que a tese cite a versão antiga

21. Ficheiros de log usados em cada comparação

Braço	seed 42	seed 7	seed 2025
A0 `raw` (15 ép.)	`20260831_065521_raw_seed42`	`20260831_075933_raw_seed7`	`20260830_225133_raw_seed2025`
A1 `weighted_fixed`	`20260830_205756_…_seed42`	`20260830_215815_…_seed7`	`20260830_194907_…_seed2025`
R1 `R1_rem_extremos`	`20260905_112128_…_seed42`	`20260905_122152_…_seed7`	`20260905_140756_…_seed2025`
R2 `R2_rem_controle`	`20260905_150442_…_seed42`	`20260905_155802_…_seed7`	`20260905_222414_…_seed2025`
2 ép. `raw` / `weighted`	`20260830_030421` / `20260830_151242`	`20260830_154057_raw_seed7` / `20260830_155444_weighted_seed7`	`20260830_163503_raw_seed2025` / `20260830_162416_weighted_seed2025`
Confusão λ = 0 (controlo)	`20260906_184642_conf_M1_lam0.0_seed42`	—	—
Confusão λ = 0,1 / 0,3 / 1,0	`20260907_084812` / `20260908_080902` / `20260908_175204`	—	—
Confusão `clr = 1e−2`	`20260907_234357`	`20260908_192123`	`20260909_225545`
Fase 2 run A / run B	—	—	`20260911_011116_conf_M1sd…` / `20260911_092137_conf_M1sdcrp…`

`20260906_215142_raw_seed42` e `20260907_083217_raw_seed42` são repetições do A0 (a primeira com curva idêntica, prova de reprodutibilidade; a segunda é o teste de 2 passos). `20260907_083944_conf_M1_lam0.0_seed42` é o teste de 2 passos do invólucro (sem avaliações). `20260907_171842` (1 avaliação) e `20260907_223901` (14 avaliações) são as tentativas interrompidas do `clr`/42 durante o incidente de disco cheio.

Apêndice A — Análises descritivas dos anotadores

A.1 Painéis e limiar pessoal (`EXIST_MEMES/Untitled.ipynb`, 2026-09-14; reexecutado)

Grandeza	Valor
sd do resíduo por anotador: observado · sob o nulo · razão	0,2096 · 0,0905 · **2,32**
variância do resíduo: observada · amostragem · real entre pessoas	0,04393 · 0,00819 (18,7%) · 0,03573 (**81,3%**)
variância entre os 6 grupos género × idade	9,4% da observada · **11,5% da real**
amplitude das 6 médias de grupo · sd individual depois de centrar no grupo	0,178 · 0,200
estabilidade entre metades (881 anotadores com ≥ 12 votos): r · nulo · **Spearman-Brown**	0,739 · 0,001 · **0,850**
"instabilidade" individual: confiabilidade entre metades · Spearman-Brown	0,032 · 0,062 (não é um traço; anotadores acima do limiar simulado: 0 de 881)
viés de painel sem circularidade: sd · encolhido · em votos	0,0069 · 0,0059 · 0,04 de 6 (razão obs/nulo 0,22; 0 itens mudam ≥ 1/12)
painéis · componentes do grafo de co-anotação · maior componente	151 · 132 · 16 anotadores
colegas distintos por anotador (mediana · máx) · densidade do grafo	5 · 10 · 0,58%
painéis com exactamente 1 anotador por célula género × idade	151 de 151
efeito de célula (contraste dentro do painel, IC95 por reamostragem)	M 18-22 −0,112 [−0,137; −0,087] · M 23-45 −0,046 · F 18-22 −0,018 · F 23-45 +0,053 · M 46+ +0,055 · F 46+ +0,068 [0,042; 0,091]
efeito de célula ajustado por etnia + escolaridade	muda ≤ 0,013
mistura gaussiana do resíduo: BIC com 1 · 2 · 3 componentes	−242,3 · −226,3 · −202,6 (unimodal)

Leitura: cada anotador tem um **limiar pessoal estável** para marcar YES (confiabilidade 0,850), que é real (81% da variância) e só em pequena parte demográfico (11,5%). A distribuição é unimodal (não há "tipos"), e os painéis têm todos a mesma mistura de perfis (variância entre painéis / entre pessoas = 0,0015). O efeito de género × idade é consistente (M 18-22 o mais restritivo; mulheres e homens 46+ os mais

permissivos) e sobrevive ao ajuste por etnia e escolaridade.

A.2 Diagnóstico comportamental (2026-08-27/28; lido, não recalculado)

- **Coerência hierárquica perfeita** entre tasks: 0 votos NO na Task A com categoria de sexismo na C ou intenção na B (10 618 NO ↔ 10 618 "-" na B e na C). A família "erro objectivo" não existe neste corpus. `[HIPÓTESE]` imposta pela interface de anotação.
- **Dispersão:** só `yes_rate` (0 a 1) e `category_entropy` (0,15 a 0,99) são dispersas sobre o painel completo.
- **Anomalias:** 66 anotadores (7,4%) disparam pelo menos um critério; 61 por taxa de YES extrema (os mesmos 61 do F5), 5 por `lang_gap` > 0,30 (em 19 bilingues); sobreposição zero.
- **Clustering:** passa o critério pré-registado em K = 2…6, mas o melhor silhouette (K = 2, [792, 52]) separa quem alguma vez usou `UNKNOWN` (3 das 7 features são indicadores binários com ≥ 80% de zeros), não perfis de comportamento. `[PÓS-HOC]` só com as features contínuas: clusters equilibrados, silhouette 0,34, sem proxy demográfico.
- **Relação com θ do NUTMEG:** $|\rho| \leq 0{,}28$ nas tabelas do §7 do relatório (o §9 do mesmo relatório escreve ≤ 0,24; o máximo da tabela é $\rho = -0{,}280$, `yes_rate_es` × θ `demo_extended_K4`), com θ legado (ambiguidade #15).

A.3 Dimensão latente "expansivo ↔ parcimonioso" (2026-08-29; lido)

PC1 das 4 features padronizadas explica **57,1%** (limiar pré-registado 55%, margem +2,1 pontos; loadings todas do mesmo sinal) → "dimensão latente única", com a força a vir das features de categoria (PC1 de 71,3% só com essas três, 70,7% depois de residualizar no denominador). `yes_rate` tem a loading mais fraca (+0,32) e a sua pertença à dimensão fica em aberto (os dois controlos disponíveis são *over-control*: ρ(n_sexist_items, yes_rate) = 0,925). Uma das associações entre features de categoria (ρ = 0,84) é em parte definicional. Nenhuma destas features mede acerto nem justifica *down-weighting*.